

西北工业大学

博士学位论文

水下目标识别的相关技术研究

姓名：余秋星

申请学位级别：博士

专业：信号与信息处理

指导教师：李志舜

20040101

## 摘要

水下目标的识别技术不仅在民用上具有一定的经济价值,而且在国防建设上也具有重要的军事价值,世界各国都很重视。尽管混沌与分形理论、小波分析理论等新方法在目标识别领域的文章日益增多,但基本上都属于起步阶段;同时由于种种原因,我们很难从国外获得其关键技术。本文对混沌与分形信号处理技术以及小波分析理论在水声信号的特征提取、分类识别中的应用进行了较深入的研究。主要包括:

1. 详细介绍了混沌与分形理论、小波变换理论以及目标识别的相关理论知识。介绍了混沌的数学定义,以及描述混沌的两个基本参数:Lyapunov 指数和分形维数;由于小波分析在时域和频域同时具有良好的局部化性能,得到了广泛的应用,文中介绍了离散小波变换、小波多分辨分析以及小波包分析的概念和原理;详细阐述了目标识别的问题描述,介绍了目标识别系统的 5 个组成部分。

2. 对混沌理论进行了系统的阐述,对混沌理论的形成历史和发展概况作出了全面的总结,而在对混沌特性进行定量分析时着重探讨了吸引子的分形维数和 Lyapunov 指数的定义与计算。

3. 对混沌信号处理的基本方法——状态空间重构技术作了详细地分析,并对涉及的参数进行了选择与确定;讨论了主元分析方法 (PCA) 在抑制噪声方面的分析原理和实现算法,利用 Lorenz 模型作为研究对象进行了仿真,不同信噪比 (SNR) 下的仿真结果说明了 PCA 方法从能量的角度出发,在一定程度上抑制了噪声、突出了混沌性态。利用 PCA 方法对实测回波数据进行了分析,估算并提取五类回波的混沌特征参数。

4. 提出了基于状态空间重构与 K-L 变换相结合的特征提取方法,对文献 [12] 中的方法进行了改进,提取了相对稳定有效的特征,仿真结果表明该方法具有较好的分类识别效果。

5. 利用小波理论对小波域的特征提取方法进行了研究。分析了基于多分辨分析和小波包分析的特征提取,提出了特征向量的构造方法,讨论了分解层数、使用的小波函数以及特征维数降低这几个因素对识别结果的影响。

6. 提出了基于小波和分形理论的特征提取方法,比较了基于小波变换提取的多尺度空间能量特征、基于小波和分形理论方法提取的特征,仿真结果表明,考虑关联维特征后,平均识别率从 91.67% 提高到了 95.14%, 识别效果得到了较大的改善。

7. 探讨了小波多分辨分析与分形理论相结合,应用分形的思想,提取水下回波信号的广义分形维特征——小波多分辨分形特征,并对五类回波信号

进行了特征提取和分类识别，仿真的结果说明了提取的特征参数是合适的、可行的，从而为水下回波的特征分类识别提供了新的特征提取方法和新的特征参数。

8. 介绍了小波神经网络的概念，分析了小波神经网络的原理及其算法，讨论了如何确定小波神经网络的初始化参数，并将其用于水下回波信号的特征提取。

**关键词：**混沌，分形，小波分析，非线性，水声信号处理，特征提取，目标识别，分类，状态空间重构，主元分析方法，分形维，广义分形维，小波神经网络

## ABSTRACT

Recognition technique on underwater targets has important value not only in economic field, but also in military field. Most countries in the world pay much attention to it. Although more and more novel methods are proposed and employed in this field, such as chaos theory, fractal theory, and wavelet theory, most of them are nearly on the beginning stage. The key of the recognition technique can hardly be obtained from abroad for some reasons. This dissertation focuses on extracting features from underwater acoustic signals and classifying them based on chaos & fractal signal processing and wavelet theory. Following are the primary contributions.

1) The theories of chaos & fractal, wavelet and involved concepts of target recognition are discussed in detail. The mathematical definition of chaos and the two parameters that can describe chaotic behavior are introduced. And wavelet analysis is widely used for its good localization both in time domain and in frequency domain, thus the concepts and principles of discrete wavelet transform, multi-resolution analysis (MRA) and wavelet packet analysis (WP) are presented. Finally, the process of target identification is depicted, which includes five parts.

2) Chaos theory is systemically expounded and its forming and development are summarized. Meanwhile, the definitions and computation of strange attractor's fractal dimension and the Lyapunov exponent are discussed when the chaotic property is quantitatively analyzed.

3) State space reconstruction, which is an essential method in chaos signal processing, is analyzed in detail, and involved parameters are seriously selected. Then the principle and algorithm about reducing noise by principal component analysis (PCA) are discussed, and the simulations in different signal-noise-radio (SNR) show that PCA can effectively reduce add-in noise. At the same time, some features are extracted from five kinds of real echoes by PCA.

4) A novel method based on state space reconstruction and K-L transform is proposed, which improves the method in reference 12. The simulation results show that the extracted features are robust, and the recognition accuracy is satisfied.

5) Applying wavelet theory to feature extraction in wavelet domain is studied. The methods based on MRA and WP are discussed, and the ways to form the feature vectors are proposed. The influence of scales, mother wavelet, and

dimensions of features is discussed.

6) A feature extraction approach based on wavelet and fractal theory is developed. Compared the feature extracted by MRA with that by the approach, the simulation results that average correct recognition rate rises from 91.67% to 95.14% show that recognition accurate is improved.

7) The combination of MRA and fractal theory is studied. Inspired by the fractal idea, wavelet multi-resolution fractal features, which belong to the generalized fractal dimension feature, are obtained. Extracting the features from five kinds of real echoes and classifying them are accomplished, and the results demonstrate that the features are feasible. Therefore, a new method and new features are acquired, which are helpful to recognize the echoes.

8) The concept, principle and algorithm of wavelet neural network are explained. And the method to select the initial parameters is developed. Meanwhile, the wavelet neural network is employed to compress and classify the underwater echoes.

**Key words:** chaos, fractal, wavelet analysis, nonlinear, acoustic signal processing, feature extraction, target recognition, classification, state space reconstruction, principal component analysis (PCA), fractal dimension, generalized fractal dimension, wavelet neural network.

## 第一章 绪论

### § 1.1 本文研究的背景及意义

未来的战争是高技术的较量,代表武器性能的重要指标已不仅仅是弹药的威力,而是武器的智能化程度,只有准确地发现目标、识别目标乃至精确地命中目标才能实施有效的杀伤,这一趋势在一些运用了大量高科技武器的现代战争中已得到越来越明显的体现,比如海湾战争中,具有目标识别能力的“爱国者”防空导弹与“飞毛腿”地对地导弹的较量;科索沃战争中,各种新式精确制导武器的使用。因此必须大力发展高技术武器装备,尤其是要提高武器的电子对抗能力,以加强军队的战斗力和武器本身的生存能力,海战也不例外。

我国是一个海洋大国,拥有着 1.8 万公里长的海岸线和 300 万平方公里的海洋国土,海军担负维护国家安全与统一的重任。而在这些我国海域却面临不少挑战,菲律宾、越南等国先后声称对南沙拥有主权,并相继派兵抢占南沙岛屿。目前,除我国控制的 6 个礁和台湾驻守的太平岛外,共有 39 个岛礁被其他国家侵占。在东海,有中日“钓鱼岛”之争。因此,在近期和未来的海战中,要求我们必须树立全新的信息致胜的观念,把战争准备的立足点放在打赢现代海战,尤其是高科技的海上局部战争上,并以此来规划我海军的现代化建设。现代战争正从人力密集型向科技密集型转变,现在武器系统应具备新式化、智能化、一体化的特征,要建立海军一体化的 C<sup>3</sup>I 体系,需要把信息采集、信息处理、信息利用和信息保护作为重要的环节,其中通过战场信息系统收集、处理、分发和利用是夺取信息优势,是打赢海战场信息战的基础。

现代海战可以说是一场围绕对抗与反对抗技术的较量,如英阿马岛之战,双方都使用了大量的水下电子对抗。据报道,阿根廷“圣路易斯”号潜艇对英国舰船进行了三次鱼雷攻击,但是由于英国舰船装有拖曳式声诱饵,采用了相应的对抗措施,使得鱼雷攻击无一命中目标。可以看出,由于水下环境本来就非常复杂,存在各种各样自然界的随机干扰,再加上水下电子对抗技术的发展,目标可能采取各种人为欺骗和干扰措施,使得现代水下武器系统对于目标检测和目标识别的要求越来越高,因此有必要研究水下目标识别技术,以提高水中兵器的各种复杂环境下的作战能力。

在海洋背景中,信息的获取主要靠声探测器材,尽管近几年各种非声探测器材,如超导磁探仪、激光探测仪、红外线探测仪等受到了普遍重视,但是在可以预见的将来,声学探测器设备在现代海战,尤其是在反潜战争中仍将占据着主要的地位,这是因为相对于其它载体而言,声波是目前唯一能够

进行水下远程探测、通讯的手段。声学探测器材主要是声纳，声纳是利用声波对水下物体进行探测、定位和识别方法及所有设备的总称。世界各国都在致力于水下目标的降噪和吸声措施的研究，并取得了长足的进展。比如美国，经过三十多年的努力，潜艇噪声级已经降低了 40 分贝左右。为了对付广泛使用的安静型潜艇，满足加大水下精确制导武器的作用距离这一迫切要求，各国都在大力发展声纳新技术。其中，拖曳式线列阵声纳成为目前潜艇声纳探测距离最远的被动式声纳；广泛使用的声纳信号处理技术有数字多波束技术、自适应波束形成技术、低频线谱技术和信道匹配技术等。

虽然现代声纳的新技术的使用，为及时准确发现远程小信噪比目标提供了必要的技术保障，然而，水下目标的自动识别是实现水下武器装备智能化的关键技术之一。目标识别是声纳后置数据处理的一个重要环节，分为主动和被动。主动声纳目标识别是利用主动声纳发射脉冲声信号，根据接收到的回波信号特性对目标类属性作出判决；被动声纳目标识别则是利用被动声纳接收到的水下目标辐射噪声特性进行分类判决。

目标识别是水声对抗的一个环节，利用目标信息的多种参数作为特征量，如主动目标识别中，目标反射回波是目标类型、距离、方位等的函数，包含了诸如回波展宽、幅度、相位、反射系数、目标尺度、能谱等表征目标的特征信息；被动目标识别中，目标辐射噪声包含了目标的转速、螺旋桨的桨叶数、发动机的汽缸数等表征目标的特征。目标识别的主要作用有：一是识别真假目标，二是对于多个目标进行分类。由于水下环境的复杂性，对于水中兵器（主要是鱼雷）最基本的要求是能够区分人造目标与自然界存在的“假目标”，如鱼群等。另一方面，在发现多个目标的情况下，能识别出各个目标的类型，进行有选择的攻击，优先攻击敌方战斗力最强的目标，如对于各种舰船混合编队。

随着科技的迅猛发展，迫切需要进行机器自动识别，对于无人值守或控制的水中兵器，这种需要尤为迫切。另外，探测系统的逐渐成熟使得用于分析处理的数据信息显著增加，多种传感器的综合应用使数据的融合越来越复杂；未来水下载体的辐射噪声的降低，需要在极低的信噪比下对目标信号进行检测和分类；加之实际需要分类的细化等，这些因素都使声纳员的工作负荷显著增加，已无法应付日益复杂的水下电子和恶劣的自然环境。因此发展机器自动识别技术变得非常重要。

现代战争是高科技的战争，世界各国都在竞相研制高性能的武器装备，而识别技术对于改进武器性能，提高武器的命中率，无疑具有巨大的军事价值。目前世界各先进国家海军都十分重视水下目标识别技术的研究工作，并且将许多技术成功地应用于实践。美国曾将自动目标识别技术列为十大关键技术之一，而且投入了大量的人力和物力，其意义是明显的。由于我国在这

方面起步晚,技术还比较落后。声纳目标识别技术由于涉及到军事,保密程度极高,有关技术进口极其困难。但近年来提高我国海军战斗力的客观需求却急剧增加,因此更增加了声纳目标识别的重要性和紧迫性。近年来,随着海洋开发活动的日益增多,对海洋的探索已不仅仅只限于军事目的,而转向商业和民用目的,如海底资源开发、石油勘探、自动绘制海底地形地貌图和探测鱼群等等,为了适于水下环境作业,国际上还开展了智能水下机器人的研究(用于铺设海底电缆、水下排雷等任务)。由于目前对声纳设备智能化的要求越来越高,而且水下目标识别技术的应用也越来越多,因此,无论是在军用或民用领域,水下目标的特征提取及识别技术都将是未来船舶与海洋工程所要研究的主要技术之一。由此可见,声纳目标识别技术的研究对我国国防事业和国民经济的发展都具有十分重要的理论意义和工程应用价值。

本课题来源于国防重点预研项目。

## § 1.2 目标识别的研究现状

### § 1.2.1 水下目标识别的特殊复杂性

水下目标识别技术之所以发展比较缓慢,除了由于涉及到军事,各国保密程度极高之外,还在于极其复杂的水下背景环境,而这些环境干扰对水下武器系统工作性能以及水下目标识别的影响不可忽视。

#### (1)传输信道多且复杂

由于海水是一种非均匀有损介质,对声能的吸收和声传播的扩展效应,造成声信号的衰减或畸变;海洋信道海面、海底以及温度梯度,声波的传播是多途径的;另外,由于海面波浪、海底粗糙不平、海水介质起伏、内波以及传感器载体的运动,使得这些多途信号产生随机性时变,从而使得信号持续时间弥散、频率弥散、入射角弥散、起伏、空间相关性下降等;加上目标距离、深度、航速不同造成的信号传输变化,使得水中目标识别变得困难。

#### (2)混响的影响

在海洋中,除了来自目标的反射信号之外,还有其它散射体的存在,如海洋中大量存在的悬浮物、鱼群、海底的山峦等。声信号在传播时有扩展效应,声信号碰到这些散射体会产生杂乱无章的反射信号,来自所有这些杂乱反射体的散射成分的总和就是混响。

#### (3)目标的辐射声场和受激产生的散射声场十分复杂

对于一般的水中目标,即使不考虑水文、水声信道传输条件与目标多普勒的影响,其噪声及回声特性也随目标状况剧烈变化,从而导致传统方法提取的目标特征不稳定,甚至演变成某种混沌的甚至随机的矢量。同一目标特



征间的差别有时候甚至比不同目标特征间的差异还大,从而导致分类决策过于复杂,甚至无法确定。

#### (4)系统的自噪声与环境噪声的影响

对于鱼雷系统,系统的自噪声是一种主要的干扰源,而且在混响较弱的情况下是目标检测的主要干扰。鱼雷的自噪声主要包括机械噪声、螺旋桨噪声和水动力噪声,其形成机理与舰船噪声的形成机理非常类似。环境噪声的噪声源主要有:潮汐、海浪、地震和火山活动,海洋湍流、其它船只的辐射噪声以及生物噪声等。

### § 1.2.2 混沌与分形的发展及其在目标识别中的应用

在经典的欧几里德几何中,我们可以用直线、圆锥、球等这一类规则的形状去描述诸如墙、车轮、建筑物等人造物体,这是极自然的事情,因为这些物体本来就是根据欧氏几何的规则图形生成的。然而在自然界中,却存在着许许多多极其复杂的形状,如山不是锥,雪花边缘也不是圆,这一大类奇形怪状已不是经典理论所能描述的<sup>[1]</sup>。

分形理论是非线性科学研究中十分活跃的一个分支,它的研究对象是自然界和非线性系统中出现的不光滑和不规则的几何形体<sup>[2][3]</sup>。分形的概念是由Mandelbrot在1975年首次正式提出,分形(Fractal)含有“破碎的、不规则的”之意。许多自然物体如树、海岸线、云等,现在看来都具有分形的性质。

分形理论的数学基础是分形几何,它起源于对传统的欧氏几何所不能描述和刻画的一些“病态”几何的研究。分形理论的发展大致可以分为三个阶段:第一阶段为1875年至1925年,在此阶段,人们已认识到几类典型的分形集,并且力图对这类集合与经典几何的差别进行描述、分类和刻画,如Weierstrass函数、Von Koch曲线、Peano曲线以及Cantor三分集等。第二阶段为1926年到1975年,在此阶段分形的研究取得了丰富的成果,如曲线的维数等,但这些研究局限于纯数学理论。第三阶段为1975年至今,是分形几何在各个领域的应用取得全面发展的阶段。Mandelbrot的专著《分形:形状、机遇和维数》标志着分形几何作为一个独立学科的产生,分形理论在数学基础和应用方面都有了快速发展。

混沌现象是由非线性系统产生的,因而对于混沌的认识也是认识自然的一部分。混沌是指由确定系统产生的、貌似随机的不规则运动。按照传统的观点,当确定性系统的参数不带随机性时,对确定性激励的响应也必然是确定的;但是现实证明,由于系统的非线性,当满足一定条件时,在规则的激励下也会产生看似无规则、不重复的运动。法国数学物理学家Poincare在研究天体力学的三体问题时发现了混沌现象,到1975年华人学者李天岩和他的

导师 Yorke 发表了论文《周期三意味着混沌》，并在动力学研究中首先引入混沌 (Chaos) 一词。80 年代初，混沌已发展成为一个具有明确研究对象和独特方法体系的新兴学科。

混沌和分形的起源不同，发展过程也不相同。但这两门学科的本质与内涵决定了它们必然会紧密地联系在一起。它们的研究内容，从本质上讲，存在着极大的相似性。混沌主要研究过程的行为特征，分形更侧重于吸引子本身结构的研究。混沌事件在不同的时间标度下表现出相似的变化模式，这与分形在空间标度下表现的相似性十分相象。混沌主要讨论非线性动力学系统的不稳定的发散过程，但系统状态在相空间中总是收敛于一定的吸引子，这与分形的生成过程十分相象。混沌与分形的一致性并非偶然。这种一致性的背后存在着一种根深蒂固的联系：混沌吸引子就是分形集，分形集就是动力学系统中那些不稳定轨迹的初始点的集合。然而，到目前为止，对分形还没有严格的数学定义<sup>[1][2]</sup>，对混沌也没有一个公认的普遍适用的数学定义<sup>[3]</sup>。

由于海洋环境的复杂性和水声信号的非平稳性、非线性，如何提取稳定的特征一直是目标识别研究的难点。

Abarbanel 在 1996 年发表的文章<sup>[4][5]</sup>指出海洋环境噪声和主动声纳回波具有混沌特征，Haykin 也于 1995 年<sup>[6]</sup>证明了海洋雷达反射杂波是混沌的，章新华等<sup>[7]</sup>发现船舶辐射噪声信号是混沌的。Wright 在 1993 年<sup>[8]</sup>提出基于非线性动态特性和古典概率理论的方法来识别和分类混沌信号；Lo 等<sup>[9]</sup>分析了海杂波的分形维特征，并利用分形维作为特征来检测四类海洋表面目标，得到了最低是 85% 的检测概率而相应的虚警概率低于 5%。

高翔等<sup>[10]</sup>研究了舰船辐射噪声的分形布朗运动模型，并构造了基于分形布朗随机场的分形特征矢量。在分类对比试验中，利用分形特征矢量的方法得到了平均 87.9% 的识别率，高于以功率谱为特征的 84.6% 的识别率，说明了分形特征矢量是有效的。陈向东等<sup>[11]</sup>研究了相空间重构下舰船辐射噪声的非线性特性，提出了相似序列重复度这一特征，并发现可以用相似序列重复度来识别不同的舰船辐射噪声。杨夙提出了基于状态空间重构的舰船噪声和湖底回波的特征提取方法，并进行了分类识别，取得了较好的效果<sup>[12]</sup>。另外，他还提取了舰船辐射噪声微分序列的标准偏差和分形维数作为特征<sup>[13]</sup>。陈捷<sup>[14][15]</sup>利用舰船噪声的多重分形特征与功率谱特征相结合，得到了平均 79.0% 的正确识别率，高于仅采用功率谱特征的识别结果 71.2%；分析了舰船噪声过零点集的多重分形特征，发现其对提高目标识别率有一定的贡献<sup>[14]</sup>。

分形混沌理论应用于其它目标识别的研究取得了很多研究成果，这对我们的水下目标识别也有一定的借鉴和参考价值，国内外这方面的文献近年来逐渐增多。

Tan<sup>[16]</sup>利用分形图像编码进行图像压缩，在脸部识别试验中，取得很好的

识别效果,平均错误率只有 1.75%。Tao 和 Tang<sup>[17][18][19][20]</sup>先通过中心投影方法降低原始二维模式的维数,然后通过小波变换将变换后的模式转变为一系列子模式,最后提取这些子模式的分形维特征。Lang<sup>[21]</sup>将多重分形的概念用于语音信号处理,并提取语音信号的多重分形特征和奇异谱特征。Karanikas 通过 Haar 小波分析了一大类极弱自相似信号的 Hausdorff 维特征<sup>[22]</sup>。Asgari 等综合小波多分辨分析(MRA)和分形的迭代函数系统(IFS),提出基于小波的分形变换(WBFT),用于图像编码,取得较好的效果<sup>[23]</sup>。

刘代志等对地下核爆和天然地震的地震波信号进行了分析和处理,发现时域地震波信号具有统计自仿射分形特征,经小波变换后提取两类分形特征参数,识别结果表明所提取的特征参数是合适的<sup>[24]</sup>。鲜明等统计了五种飞机目标回波信号的 Lyapunov 指数分布的情况,并计算了其多重分形维数,在分类识别的实验中得到了 85.5% 的识别率<sup>[25][26]</sup>。苏菲等利用多重分形特征对雷达目标进行粗检测<sup>[27]</sup>。丁庆海等分析了坦克和直升机的空气动力性噪声信号的混沌特性,提取了 Lyapunov 指数、分形维数和小波域的能量特征,发现在较宽的信噪比范围内保持较高的识别率<sup>[28]</sup>。李后强、汪富泉<sup>[29]</sup>介绍了蛋白质及酶分子链、表面的分形研究,酶分形动力学及酶模型的分形设计,以及用分形方法研究高分子和胶束的一些初步结果。殷志云、梅炽将混沌与分形理论应用于热工过程的研究<sup>[30]</sup>。

### § 1.2.3 小波理论的发展及其在目标识别中的应用

小波分析是时频发展的新理论,是 80 年代后期发展起来的<sup>[31]-[34]</sup>。小波分析方法的出现在数学上源于经典的调和分析。1981 年,由法国物理学家 Morlet 在分析地震数据时首先提出了小波分析的概念。但在这以前,人们已做了大量基础性的工作,如 1910 年 Haar 提出了 Haar 函数,建立了 Haar 函数的规范正交基等。1985 年,法国数学家 Meyer 首先提出了光滑的正交基—Meyer 基。1986 年, Meyer 及其学生 Lemarie 提出了多尺度分析的思想。1988 年,年轻的女数学家 Daubechies 提出了具有紧支集光滑正交基—Daubechies 基,为小波的应用增添了催化剂。后来信号分析专家 Mallat 提出了多分辨分析的概念,并在此基础上建立了 Mallat 塔形快速算法,这一算法的作用相当于 Fourier 分析中的 FFT,它使得小波从理论走向更为广泛的应用研究<sup>[35]</sup>。1992 年, Coifman 和 Wickerhauser 提出了小波包的概念和算法。它推广了 Mallat 的塔形算法,构成了一种更精细的分解方法,并且这种算法对信号的特性具有自适应能力<sup>[36]</sup>。

小波分析是一门新兴的学科,虽然出现不到 20 年,但已经引起了数学界和工业界的普遍关注,它被认为是傅立叶分析的重大突破。由于小波分析在时域和频域同时具有良好的局部化性能,可以聚焦到对象的任意细节,为人

们深入探讨自然科学中的现象与规律提供了一种强有力的新工具,应用的领域涉及图像处理<sup>[37][38][39][40]</sup>, 信号处理<sup>[41][42][43]</sup>, 机械故障诊断<sup>[44][45]</sup>, 医疗上的诊断<sup>[46][47][48]</sup>等。

在目标识别领域,对于舰船辐射噪声的识别,目前主要的特征提取手段集中在功率谱特征的提取,这是因为不同目标辐射噪声的噪声平均功率谱形状上的差异体现了目标的某些本质特征如吨位、航速、类型等,所用的方法有 LOFAR 谱<sup>[49]</sup>、高阶谱<sup>[50][51]</sup>等,而谱特征方法存在一定的局限性<sup>[52][53]</sup>。对于回波信号识别,主要是通过亮点模型方法、共振模态分析方法、频谱分析和小波变换<sup>[54]</sup>,常用的信号特征有:AR 模型参数、傅里叶功率谱、小波变换参数。

小波变换由于其恒 Q 特性、适合分析非平稳信号的特点,在辐射噪声分类识别中也得到了应用<sup>[52][55]</sup>。赵建平提取小波多分辨子带功率谱特征,对三类目标进行分类,识别率达到 85% 左右<sup>[52]</sup>;章新华等提取舰船辐射噪声经小波变换后的功率谱特征,通过分类测试,发现比原始信号的功率谱特征具有更好的类别可分性<sup>[56]</sup>;吴国清等利用小波多分辨分析了舰船辐射噪声,把平稳谱和非平稳谱拆开描述和显示,获得了很好的结果<sup>[57]</sup>;Chen 利用小波变换从舰船噪声平均功率谱 (APSD) 中提取音频特征,正确识别率达到 96% 或 94%,而直接用 APSD 作为特征,正确识别率只有 80%<sup>[58]</sup>。小波变换也应用于回波信号的特征提取。赵建平利用小波变换提取水下回波的边缘特征,能有效的识别四类湖底回波<sup>[52][59]</sup>;张静远等利用基于小波分解的能量特征、基于小波变换的模极大值特征、基于小波包分解的熵特征以及基于小波网络的特征分别对三类湖底回波进行分类,平均识别分别为 85.71%、93.33%、99.05% 和 95.31%<sup>[60]</sup>;马艳分别提取了尺度一小波能量谱、时间一小波能量谱、多分辨子带能量、小波包分析系数、小波包子带代价向量作为回波特征,对四类湖底回波进行了分类识别,并进行了比较<sup>[61]</sup>;Azimi-Sadjadi 利用线性预测编码 (LPC) 模型提取小波包分解后各子带的特征,进行了两类回波的识别<sup>[62]</sup>。

由于小波具有良好的时频局部特性和变焦特性,而神经网络具有自学习、自适应性、强鲁棒性和推广能力,如何将小波和神经网络结合起来,一直是人们关注的问题。两者的结合形式主要有两种:一种是先用小波变换提取信号的特征,再将特征输入神经网络进行处理<sup>[59][62]</sup>;另一种是把小波变换的运算融入到神经网络里,形成所谓的小波神经网络。1992 年 Zhang Qinghua 和 Benveniste 明确提出了小波网络的概念和算法<sup>[63]</sup>;Telfer 等人利用自适应小波网络提高识别率<sup>[64]</sup>;Tollig 等人利用小波网络对瞬时信号进行分类<sup>[65]</sup>;Zhang Jun 等利用小波网络进行函数学习,性能好于 MLP 和 RPF 网络<sup>[66]</sup>;Zhang Qinghua 还将小波网络用于非参数估计<sup>[67]</sup>;张永胜等利用小波网络实现对化

学物质红外光谱的压缩表征和分类,分类准确率达 94%<sup>[69]</sup>;何振亚和何强分别提出用于信号逼近和分类的自适应时延小波网络<sup>[69]</sup>以及自适应周期小波网络<sup>[70]</sup>。由于小波神经网络具有自适应分辨性和良好的容错性,特别适合应用在函数逼近、系统辨识、数据压缩、模式识别等,近几年的研究进展可参阅文献[71]。

### § 1.3 本文研究内容及安排

本文是国防科技重点预研项目的一部分。混沌与分形信号处理方法与非平稳信号处理的有力工具—小波变换相结合,作为本文工作的主要研究方法;用这些方法来研究水下目标的识别技术。同时利用分类器进行分类识别实验,这是检验提取的特征是否有效的重要工具。因此,在特征提取之后进行了分类识别。尽管混沌与分形理论、小波变换等新方法在目标识别中应用的文献日益增多,但基本上属于起步阶段,而且国外的资料也仅仅是透露了一点信息,关键技术仍无法获得,在水下目标识别方面更是如此。所以,对水声信号的特征提取与分类识别是一项富有探索性、也有着实际意义的工作。下面简单介绍一下本文的研究内容及其安排。

第二章详细介绍了混沌与分形理论、小波变换理论以及目标识别的相关理论知识。介绍了混沌的数学定义,以及描述混沌的两个基本参数:Lyapunov 指数和分形维数;由于小波分析在时域和频域同时具有良好的局部化性能,得到了广泛的应用,文中介绍了离散小波变换、小波多分辨分析以及小波包分析的概念和原理;详细阐述了目标识别的问题描述,介绍了目标识别系统的 5 个组成部分。

第三章对混沌信号处理的基本方法——状态空间重构技术进行了详细地分析,并对涉及的参数进行了选择与确定;讨论了主元分析方法 (PCA) 在抑制噪声方面的分析原理和实现算法,利用 Lorenz 模型作为研究对象进行了仿真,在不同信噪比 (SNR) 下的仿真结果说明了 PCA 方法从能量的角度出发,在一定程度上抑制了噪声、突出了混沌性态。利用 PCA 方法对实测回波数据进行了分析,估算并提取五类回波的混沌特征参数。提出了基于状态空间重构与 K-L 变换相结合的特征提取方法,对文献 [12] 中的方法进行了改进,提取了相对稳定有效的特征,仿真结果表明该方法具有较好的分类识别效果。

第四章利用小波分析理论对小波域的特征提取方法进行了研究。①分析了基于多分辨分析的特征提取,以各子带的能量构成信号的特征向量,讨论了多分辨分析的分解层数与使用的小波函数这两个因素对分类效果的影响,分析了五类回波信号的分类以及特征维数的降低对识别结果的影响;②小波

包分析是在多分辨分析基础上对其没有分解的高频部分进一步分解,有更高的频率分辨率,所以接下来研究了基于小波包分析的特征提取,介绍了几种从小波包中构造特征向量的方法:以小波包能量谱为特征、以最佳子空间熵值为特征、以小波包AR谱为特征,讨论了小波包分析的分解层数与使用的小波函数这两个因素对五类回波的识别结果的影响,用以上三种方法提取的特征对五类回波信号进行了分类识别,说明了特征维数的降低对识别结果的影响。提出了基于小波和分形理论的特征提取方法,相对于基于小波变换提取的多尺度空间能量特征,该方法所提取的特征使识别效果得到了一定程度的改善。

第五章探讨了小波多分辨分析与分形理论相结合,应用分形的思想,提取水下回波信号的广义分形维特征——小波多分辨分形特征,并对五类回波信号进行了特征提取和分类识别,仿真的结果说明了提取的特征参数是合适的、可行的,从而为水下回波的特征分类识别提供了新的特征提取方法和新的特征参数。

第六章对小波神经网络进行了研究,分析了小波神经网络的原理及其算法,讨论了如何确定小波神经网络的初始化参数,并将其用于水下回波信号的特征提取。

第七章作为全文的结束,总结全文的研究工作和结果,阐明本文的贡献,最后提出在该领域需要进一步解决的问题。

## 第二章 混沌、分形与小波变换的理论基础

### § 2.1 引言

混沌信号处理方法是混沌理论与信号处理相结合的产物,混沌现象是混沌理论所研究的对象。非线性特性研究是当前信息处理研究的重要新课题之一,混沌现象是非线性系统的一种现象。由于混沌现象的发现,激起了人们对混沌的研究兴趣,促进了混沌科学的发展。在信号处理领域,将混沌理论与信号处理相结合的混沌信号处理是目前的研究热点之一。长期以来,一般将信号分为确定信号和随机信号,确定信号是由确定性系统产生、具有长期可预测性,而随机信号的行为是不可预测的,只能从统计意义上对其进行描述。近年的研究发现<sup>[1][3]</sup>,混沌信号是有别于确定信号和随机信号的一类信号,它是由确定性系统产生,其表现类似于随机信号。

正如前一章所提到的,分形理论与混沌理论的关系非常密切,分形理论是研究混沌现象的有效工具,这为混沌与分形的应用奠定了基础。另外,混沌、分形理论与其它一些理论相结合,如与小波理论相结合<sup>[17]-[19][72]-[75]</sup>,为混沌信号处理提供了崭新的研究途径,更加改善和促进了混沌与分形理论的发展与应用。

水声信号是一种非线性信号<sup>[10]-[12]</sup>。长期以来,一直被当作随机信号处理,对于复杂的实际工程问题,有时候其处理结果并不那么令人满意。近年的研究发现<sup>[6][7][10]</sup>,水声信号具有混沌特性。这就为水声信号处理中难度很大的弱信号检测和识别开辟一条崭新的途径。因此,本章简要介绍一下混沌与分形理论、小波变换理论以及目标识别的相关理论知识。

### § 2.2 混沌特征参数

#### § 2.2.1 混沌的定义

混沌(Chaos)一词首先是李天岩和 Yorke 所提出。他们于 1975 年在美国的《数学月刊》上发表了一篇《周期 3 意味着混沌》的文章,并给出了混沌的一种数学定义,当今科学界称之为 Li-Yorke 定义。这一数学定义叙述如下<sup>[3][29]</sup>:

定义 2.1 设连续映射  $f: I \rightarrow I \subset R$ ,  $I$  是  $R$  中的一个区间,如果存在不可数集合  $S \subset I$  并满足下列条件:

- (1)  $S$  不含周期点
- (2) 任给  $x_1, x_2 \in S (x_1 \neq x_2)$ , 有

$$\limsup_{t \rightarrow \infty} |f'(x_1) - f'(x_2)| > 0 \quad (2.1)$$

$$\liminf_{t \rightarrow \infty} |f'(x_1) - f'(x_2)| = 0 \quad (2.2)$$

这里  $f'(\bullet) = f(f(\dots f(\bullet)\dots))$  表示  $t$  重函数关系。

(3) 任给  $x_1 \in S$  及  $f$  的任意周期点  $P \in I$  有

$$\limsup_{t \rightarrow \infty} |f'(x_1) - f'(P)| > 0 \quad (2.3)$$

则我们称  $f$  为在  $S$  上是混沌的。

系统从简单的周期行为走向复杂的非周期行为, 此时, 决定论和随机性两种因素同时支配着系统的进程。混沌是由系统内部的非线性动力学过程产生的非周期宏观时空行为, 是无周期的有序。混沌的主要特征有: ①随机性。产生混沌的系统, 一般情况下具有整体稳定性而局部是非稳定的; 局部不稳定正是内在随机性的特点, 也是对初始条件敏感性的原因。②混沌是不可长期预测的。由于对初始条件的敏感性, 混沌的长期行为是不可预测的, 而混沌系统内部有着确定的规律性, 因此混沌又是局部可预测的。③自相似性。系统的混沌运动在相空间中无穷的缠绕、折迭和扭结, 构成了具有无穷次的自相似结构, 这种结构称为奇怪吸引子, 可以用分形中的分维来描述。混沌还具有一些其它特征如标度性、普适性、遍历性等等<sup>[1][4][76]</sup>。

Lyapunov 指数和分形维数分别表示了混沌信号的长期不可预测性和混沌吸引子的复杂程度, 是描述信号混沌性态的两个基本参数, 将在下文中进行介绍。

### § 2.2.2 Lyapunov 指数

Lyapunov 指数是度量系统是否有混沌行为的重要指标。

在本论文中, 引用李后强等人对 Lyapunov 指数的定义<sup>[3]</sup>。




图 2-1 Lyapunov 指数的定义



定义如下：若在映射

$$x_{n+1} = f(x_n) \quad (2.4)$$

的作用下邻点变成分离点导致混沌运动, Lyapunov 指数  $\lambda$  就度量了这种分离性 (见图 2-1)。

$$\varepsilon e^{N\lambda(x_0)} = |f^N(x_0 + \varepsilon) - f^N(x_0)| \quad (2.5)$$

在极限  $\varepsilon \rightarrow 0$ ,  $N \rightarrow \infty$  时导出 Lyapunov 指数  $\lambda(x_0)$  的公式

$$\begin{aligned} \lambda(x_0) &= \lim_{N \rightarrow \infty} \lim_{\varepsilon \rightarrow 0} \frac{1}{N} \log \left| \frac{f^N(x_0 + \varepsilon) - f^N(x_0)}{\varepsilon} \right| \\ &= \lim_{N \rightarrow \infty} \frac{1}{N} \log |df^N(x_0)/dx_0| \end{aligned} \quad (2.6)$$

这意味着  $e^{\lambda(x_0)}$  是最近邻点在一次迭代后所延伸的距离的平均因子。Lyapunov 指数度量了一次迭代后信息的平均损失。为此由(2.6)和链规则

$$\begin{aligned} \left. \frac{d}{dx} f^2(x) \right|_{x_0} &= \left. \frac{d}{dx} f[f(x)] \right|_{x_0} = f'[f(x_0)]f'(x_0) \\ &= f'(x_1)f'(x_0) \end{aligned} \quad (2.7)$$

将 Lyapunov 指数记作

$$\begin{aligned} \lambda(x_0) &= \lim_{N \rightarrow \infty} \log \left| \frac{d}{dx_0} f^N(x_0) \right| = \lim_{N \rightarrow \infty} \frac{1}{N} \log \left| \prod_{i=0}^{N-1} f'(x_i) \right| \\ &= \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{i=0}^{N-1} \log |f'(x_i)| \end{aligned} \quad (2.8)$$

将  $\lambda(x_0)$  记为  $\lambda$ 。

可以看出, 当  $\lambda < 0$  时, 轨道对初始条件不敏感, 相空间逐渐收缩, 系统最终趋于稳定; 当  $\lambda = 0$  时, 初始误差不放大也不缩小, 系统处于临界状态; 当  $\lambda > 0$  时, 则相邻轨道间的初始误差将以指数速率放大, 并且迅速分离, 如果轨道是有界的, 只在某个有界空间中演化, 则  $\lambda > 0$  标志着系统的局部不稳定,  $\lambda > 0$  可以作为混沌行为的判据。对于多维系统, 存在多个 Lyapunov 指数, 只要有一个 Lyapunov 指数为正, 就可以判定系统具有混沌行为。因此, 一般情况下所关心的是最大 Lyapunov 指数。

混沌吸引子是混沌的产物, 它是由系统的整体稳定性和局部不稳定性共

同作用产生的。宏观上,系统轨道的演化最终处于一个有界的空间中;微观上,相邻轨道将以指数速率迅速分离。因此,轨道会出现多次拉伸、折叠和扭曲,从而使得混沌吸引子具有非常复杂的几何形态。

### § 2.2.3 分形维数

分形维数可以用于度量混沌吸引子复杂的空间结构。分形维数有多种定义, Hausdorff 维数是最基本的一种。

设  $A$  为欧氏空间  $R^n$  中的一个子集,  $s$  为一非负实数, 对任何  $\delta > 0$ , 定义:

$$H_\delta^s(A) = \inf \sum_{i=1}^{\infty} |U_i|^s \quad (2.9)$$

式中  $U_i$  为  $R^n$  中的集合, 并有  $A \subset \bigcup_{i=1}^{\infty} U_i$ ,  $|U_i|$  表示  $U_i$  的直径, 即:

$$|U_i| = \sup \{ |x - y| : x, y \in U_i \} \quad (2.10)$$

且  $0 < |U_i| < \delta$ ,  $\{U_i\}$  称为  $A$  的一个  $\delta$ -覆盖。(2.9) 式表示在  $A$  的所有  $\delta$ -

覆盖中, 求满足和式的下确界。令  $\delta \rightarrow 0$ , (2.9) 式的极限值  $H^s(A)$  称为集合

$A$  的  $s$  维测度。可以证明, 对于集合  $A$  存在唯一的非负实数, 记为  $D_h(A)$ ,

它满足下列性质:

若  $0 < s < D_h(A)$ , 则  $H^s(A) = \infty$ ;

若  $D_h(A) < s < \infty$ , 则  $H^s(A) = 0$ 。

$D_h(A)$  即称为集合  $A$  的 Hausdorff 维。

Hausdorff 维是最古老的, 也是最重要的一种维数, 它对任何集都有定义。然而, 这种维数在理论上的意义远大于实际应用。对于一个分形集合, 计算其 Hausdorff 维数一般是相当困难的。实际上我们最常用的分数维是关联维、盒子维等。下面介绍一下关联维。

关联维的定义为

$$D = \lim_{r \rightarrow 0} \frac{\log C(r, m)}{\log r} \quad (2.11)$$

公式 (2.11) 中  $C(r, m)$  表示相关积分, 其定义为

$$C(r, m) = \frac{1}{[N(m)]^2} \sum_{i,j=1}^{N(m)} H(r - d_{ij}^{(m)}) \quad (2.12)$$

公式(2.12)中 $m$ 表示嵌入维,  $N(m)$ 表示当嵌入维为 $m$ 时所有重构向量的个数,  $r$ 表示尺度,  $H(\bullet)$ 表示Heaviside函数, 其定义为

$$H(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases} \quad (2.13)$$

公式(2.12)中 $d_{ij}^{(m)}$ 的定义为

$$d_{ij}^{(m)} = \|v_i^{(m)} - v_j^{(m)}\| \quad (2.14)$$

式中 $v_i^{(m)}$ 表示重构向量;  $\|\bullet\|$ 表示范数。

在计算关联维时, 由于受到数据长度的限制, 所能求得的维数有一个上限<sup>[3]</sup>

$$d_{\max} = \frac{2 \log N}{\log(1/\rho)} \quad (2.15)$$

上式中 $N$ 是数据长度,  $\rho = \frac{r}{D}$ 是尺度 $r$ 与吸引子直径 $D$ 的比值, 一般取较小值,  $D$ 也可以理解为分形体的尺寸。公式(2.15)的根据是, 求取关联维时, 一般采用最小二乘法在一定的尺度范围内对 $\log C(r, m)$ 和 $\log r$ 进行拟合, 在较大的尺度范围内,  $\log C(r, m)$ 和 $\log r$ 不能保证线性关系, 所以尺度 $r$ 不宜取较大值,  $r$ 应在相对于 $D$ 较小的一段范围内取值, 一般建议取 $\rho = \frac{r}{D} = 0.1$ , 同时要求, 尺度 $r$ 不宜取过小的值, 在这样一段尺度范围内计算出的关联维, 应满足公式(2.15)给出的上限。

## § 2.3 小波分析理论

### § 2.3.1 小波变换

小波分析是近十几年发展起来的一种数学工具, 是傅立叶(Fourier)分析之后的一个重大突破<sup>[83]~[87]</sup>。小波变换弥补了傅立叶变换只有频域分辨率和窗口傅立叶变换在整个时频域有着相同的分辨率的缺点, 在时域和频域同时具有良好的分辨率(即“变焦性”), 被誉为是“数学显微镜”, 因而得到了

广泛的关注。目前在语言、图像、通信、雷达、水声、地震、生物医学、机械振动、化工等领域都有应用<sup>[31][77]~[87]</sup>。

对于具有有限能量的信号或平方可积的信号  $f(t)$ ，其连续小波变换定义为

$$W_f(a, b) = \langle f(t), \psi_{a,b}(t) \rangle = \int_{-\infty}^{\infty} f(t) \psi_{a,b}(t) dt \quad (2.16)$$

上式中的符号  $\langle x(t), y(t) \rangle$  表示两个函数  $x(t)$  和  $y(t)$  内积，且

$$\psi_{a,b}(t) = |a|^{-1/2} \psi\left(\frac{t-b}{a}\right) \quad (2.17)$$

其中  $a, b \in R$ ， $a$  是尺度参数， $b$  是位置参数， $\psi_{a,b}(t)$  是小波函数，是函数  $\psi(t)$  经过不同的尺度伸缩和平移得到的一系列基函数， $\psi(t)$  称为母小波，它满足可允许性条件，即

$$C_\psi = \int_{-\infty}^{\infty} \frac{|\hat{\psi}(\omega)|^2}{|\omega|} d\omega < \infty \quad (2.18)$$

这里  $\hat{\psi}(\omega)$  是  $\psi(t)$  的傅立叶变换。

在  $\psi_{a,b}(t)$  是复变函数时，式 (2.16) 中要用复共轭函数  $\bar{\psi}_{a,b}(t)$ ；改变  $a$  的值，对函数  $\psi(t)$  具有伸展 ( $a > 1$ ) 或压缩 ( $a < 1$ ) 的作用，对于  $\hat{\psi}(\omega)$  的作用正好相反；改变  $b$  的值，则会影响小波函数在时间轴上的位置，但波形保持不变。小波变换提供了一个可调的频率—时间窗，当观察高频现象时，它自动变窄，以便更精确地确定高频现象；当观察低频信号时，它自动变宽，以便更充分地研究低频特性。

式 (2.16) 所表示的连续子波变换常用于理论分析，在实际应用中，更方便的是采用它的离散形式。令尺度参数  $a$  和位置参数  $b$  的取值分别为  $a = 2^m$  和  $b = n2^m$ ，可以得到二进离散小波

$$\psi_{m,n}(t) = 2^{-m/2} \psi(2^{-m}t - n) \quad (2.19)$$

如果  $\psi_{m,n}(t)$  满足正交条件

$$\int \psi_{m,n}(t) \psi_{p,q}(t) dt = \begin{cases} 1 & m=p, n=q \\ 0 & \text{其它} \end{cases} \quad (2.20)$$

则  $\psi_{m,n}(t)$  为二进正交小波。

### § 2.3.2 多分辨率分析

1988 年 Mallat 引入了多分辨率分析 (Multiresolution Analysis, MRA) 的概念, 并提出了正交小波变换的 Mallat 快速算法<sup>[36]</sup>。

定义 空间  $L^2(R)$  中的一列闭子空间  $\{V_j\}_{j \in \mathbb{Z}}$  称为  $L^2(R)$  的一个多分辨率分析 (MRA), 如果满足下列条件:

(1) 单调性:  $\dots \subset V_{j-1} \subset V_j \subset V_{j+1} \subset \dots, \forall j \in \mathbb{Z}$ ;

(2) 逼近性:  $\bigcap_{j \in \mathbb{Z}} V_j = \{0\}, \overline{\bigcup_{j \in \mathbb{Z}} V_j} = L^2(R)$ ;

(3) 伸缩性:  $f(x) \in V_j \Leftrightarrow f(2x) \in V_{j+1}, \forall j \in \mathbb{Z}$ ;

(4) 平移不变性:  $f(x) \in V_0 \Rightarrow f(x-k) \in V_0, \forall k \in \mathbb{Z}$ ;

(5) Riesz 基存在性: 存在  $g \in V_0$ , 使  $\{g(x-k) | k \in \mathbb{Z}\}$  构成  $V_0$  的 Riesz 基。

设尺度函数为  $\varphi(x)$ , 对应的小波函数为  $\psi(x)$ , 它们应满足尺度方程:

$$\begin{cases} \varphi(x) = \sum_n h(n) \varphi(2x-n) \\ \psi(x) = \sum_n g(n) \varphi(2x-n) \end{cases} \quad (2.21)$$

$$\text{其中} \quad g(n) = (-1)^{1-n} h(1-n) \quad (2.22)$$

对应的 MRA 为

$$\begin{cases} \varphi_{j,k}(x) = 2^{-j/2} \varphi(2^{-j}x - k) \\ \psi_{j,k}(x) = 2^{-j/2} \psi(2^{-j}x - k) \end{cases} \quad (2.23)$$

设信号函数为  $f(x)$ ，则在尺度  $j$ （或  $2^j$ ）下的逼近信号  $A_j f$  为

$$A_j f = \langle f(x), \varphi_{j,k}(x) \rangle = 2^{-j/2} \int f(x) \varphi(2^{-j}x - k) dx \quad (2.24)$$

在尺度  $j$ （或  $2^j$ ）下的细节信号  $D_j f$  为

$$D_j f = \langle f(x), \psi_{j,k}(x) \rangle = 2^{-j/2} \int f(x) \psi(2^{-j}x - k) dx \quad (2.25)$$

信号  $f(x)$  分解的过程是从  $j-1$  尺度到  $j$  尺度的逐步分解过程，即对信号  $f(x)$  是从分辨率高到分辨率低的过程，具体是将  $A_{j-1}f$  分解为  $A_j f$  和  $D_j f$ ，亦即

$$\begin{cases} A_j f = \sum_k h(k-2n) A_{j-1} f \\ D_j f = \sum_k g(k-2n) A_{j-1} f \end{cases} \quad (2.26)$$

式 (2.26) 是一个递推公式，若设原信号  $f(x) \in V_0$  即  $f(x) = A_0 f$ ，则由式

(2.26) 知迭代次数为  $1 \leq j \leq J$ ，也就是说将  $A_0 f$  分解为

$$f(x) = A_0 f = A_1 f + \sum_{j=1}^J D_j f \quad (2.27)$$

由  $A_j f$  和  $D_j f$  又可以重构  $A_{j-1} f$ ，即为

$$A_{j-1} f = \sum_k h(n-2k) A_j f + \sum_k g(n-2k) D_j f \quad (2.28)$$

这就是著名的 Mallat 算法。

设以  $V_j$  表示多分辨分解中的低频部分  $A_j$ ， $W_j$  表示分解中的高频部分

$D_j$ ，则  $W_j$  是  $V_j$  在  $V_{j+1}$  中的正交补，即

$$V_j \oplus W_j = V_{j+1} \quad j \in \mathbb{Z}$$

显然

$$V_j \oplus W_j \oplus W_{j+1} \oplus \cdots \oplus W_{j+m} = V_{j+m}$$

则多分辨分析的子空间  $V_0$  可以用有限个子空间来逼近, 即有

$$\begin{aligned} V_0 &= V_1 \oplus W_1 = V_2 \oplus W_2 \oplus W_1 = \cdots = \\ &V_N \oplus W_N \oplus W_{N-1} \oplus \cdots \oplus W_2 \oplus W_1 \end{aligned} \quad (2.29)$$

多分辨分析的分解结构如图 2-2 所示:




图2-2 小波多分辨分析的分解图

### § 2.3.3 小波包分析

短时傅立叶变换对信号的频带划分是线性等间隔的。多分辨分析可以对信号进行有效的时频分解, 但由于其尺度是按二进制变化的, 所以在高频段其频率分辨率较差, 而在低频段其时间分辨率较差, 即对信号的频带进行指数等间隔划分 (具有等  $Q$  结构)。小波包分析 (Wavelet Packet Analysis) 能够为信号提供一种更加精确的分析方法, 它将频带进行多层次划分, 对多分辨分析没有细分的高频部分进一步分解, 并能够根据被分析信号的特征, 自适应地选择相应频带, 使之与信号频谱相匹配, 从而提高了时-频分辨率, 因此小波包具有更广泛的应用价值。

使用记号

$$\varphi_0(x) = \varphi(x), \quad \varphi_1(x) = \psi(x)$$

则式 (2.21) 的双尺度方程可以写为:

$$\begin{cases} \varphi_0(x) = \sum_k h(k) \varphi_0(2x - k) \\ \varphi_1(x) = \sum_k g(k) \varphi_1(2x - k) \end{cases} \quad (2.30)$$

由

$$\begin{cases} \varphi_{2l}(x) = \sum_k h(k) \varphi_l(2x - k) \\ \varphi_{2l+1}(x) = \sum_k g(k) \varphi_l(2x - k) \end{cases} \quad (2.31)$$

定义的函数  $\varphi_n$ ,  $n = 2l$  或  $2l+1$ ,  $l = 0, 1, \dots$ , 称为关于正交尺度函数  $\varphi(x)$  的小波包。由于  $\varphi(x)$  由序列  $\{h(k)\}$  唯一确定, 所以又称  $\{\varphi_n\}$  为关于序列  $\{h(k)\}$  的正交小波包。

为了表示小波包的空间分解, 引入如下表示符号

$$\begin{cases} U_j^0 = V_j, & j \in Z \\ U_j^1 = W_j, & j \in Z \end{cases} \quad (2.32)$$

这样一来, Hilbert 空间的正交分解  $V_{j+1} = V_j \oplus W_j$  就可以用  $U_{j+1}$  的分解统一起来, 即

$$U_{j+1}^0 = U_j^0 \oplus U_j^1, \quad j \in Z \quad (2.33)$$

并由此推广到  $n \in Z_+$  (非负整数) 的一般情形

$$U_{j+1}^n = U_j^{2^n} \oplus U_j^{2^{n+1}}, \quad j \in Z \quad (2.34)$$

设信号  $f(t)$ , 长度为  $2^J$ , 形成的空间用  $U_0^0$  表示, 则信号空间的  $J$  层小波包的各种分解如下

$$\left. \begin{aligned} U_0^0 &= U_1^0 \oplus U_1^1 \\ U_1^0 &= U_2^0 \oplus U_2^1 \oplus U_2^2 \oplus U_2^3 \\ &\dots \\ U_j^0 &= U_j^0 \oplus U_j^1 \oplus \dots \oplus U_j^{2^{j-2}} \oplus U_j^{2^{j-1}} \\ &\dots \\ U_J^0 &= U_J^0 \oplus U_J^1 \oplus \dots \oplus U_J^{2^{J-2}} \oplus U_J^{2^{J-1}} \end{aligned} \right\} \quad (2.35)$$

可以看出, 信号小波包分解的最高层数为  $J$ , 在第  $j$  层的分解中, 信号空间被分解为  $2^j$  个相互正交的子空间, 信号在该层的小波包系数的个数也为  $2^j$ , 分解过程中的每一个子空间都构成一个节点, 整个分解过程有  $2^{J+1} - 1$  个节点, 分解过程是冗余的, 超完整的。这样分解共得到  $J2^J$  个系数, 最多有  $2^J$  种不同的分解方法。它的分解结构如图 2-3 所示。






图2-3 小波包分析的分解结构图

§ 2.4 目标识别的问题描述<sup>[88]~[90]</sup>

存在于时间和空间中可观察的事物，如果我们可以区别它们是否相同或是否相似，都可以称为模式，但模式指的并不是事物本身，而是我们从事物所获得的信息。有两种基本的模式识别方法，即统计模式识别和结构（句法）模式识别，与此相应的模式识别系统都由两个过程所组成，即设计与实现。设计是指用一定数量的样本（叫做训练集或学习集）进行分类器的设计；实现是指所设计的分类器对待识别的样本进行分类决策，本文所采用的为统计模式识别方法。基于统计方法的模式识别系统主要有如下 5 个部分组成：① 数据获取和预处理；② 特征提取；③ 特征压缩；④ 分类器设计；⑤ 分类及结果解释。如图 2-4 所示。




图 2-4 模式识别系统的基本组成

(1) 数据获取和预处理

为了使计算机能够对各种现象进行分类识别，要用计算机可以运算的符号来表示所研究的对象。通常输入对象的信息有三种类型：二维图象、一维

波形、物理参量和逻辑值。通过测量、采样和量化,可以用矩阵或向量表示二维图象或一维波形,这就是数据获取的过程。在本文中,获取的数据是用向量表示的一维波形。预处理一般有两种情况:一是使数据的质量更好,比如用一些数字信号处理的方法去除信号中的噪声等,需要注意的是要确保这种预处理是有利于后期的模式识别工作的;另一种是样本集的预处理,比如样本集中野值的剔除、类别的合并或分裂等。

### (2) 特征提取

一般不直接采用测量信号进行目标识别,这是因为①由测量获得的样本处于一个高维空间中,而且得到的信息是冗余的,这使得后面分类器的设计和结构非常复杂,而分类效果却不理想;②测量信号中噪声的存在,更是增加了分类识别的难度。因此必须从测量信号中提取出对目标分类最有效的特征,这就是特征提取阶段所要完成的工作。在整个目标识别的过程中,特征提取起着核心的作用,也是模式识别系统中较为困难的工作之一。特征提取的方法有很多,如小波变换<sup>[52]</sup>、时频分析<sup>[91][92]</sup>等等。在本论文中,主要利用混沌分形理论和小波理论对水声信号进行特征的提取,在后续的章节会有详细地介绍。

### (3) 特征压缩

由初始的特征提取方法得到的特征可能依然很多,如果将他们全部作为特征送往分类器,不仅使得分类器的结构复杂,存储特征的空间增大,分类计算判别量大,而且其分类效果不一定好,有必要对原始特征进行判别、选择、变换,得到对分类效果影响较大的特征,这就是特征压缩的过程。特征压缩包括特征选择和特征投影:从一组特征中挑选出一些最有效的特征以达到降低特征空间维数的目的,这个过程就叫特征选择;特征投影就是用映射(或称变换)的方法将原始特征变换为较少的新特征。可见,特征压缩是为了降低特征空间的维数以便有效地设计分类器,同时要兼顾实现尽可能高的分类识别率。

### (4) 分类器设计

分类决策就是在特征空间中用统计方法把被识别对象归为某一类型,基本做法是在样本训练集基础上确定某个判决规则,使按这种判决规则对被识别对象进行分类所造成的错误识别率最小或引起的损失最小。分类器设计方法包括监督学习方法和非监督学习方法。在有已知类别标号的训练样本时的分类器设计方法,即为监督学习方法;样本类别标号未知时的分类器设计方法,即为非监督学习方法,此时用来设计分类器的样本集可能就是我们设计好分类器后要进行分类的样本集。

### (5) 分类及结果解释

对于监督模式识别情况,这一阶段就是用设计好的分类器对新的或者类

别标号未知的样本进行分类；对于非监督模式识别情况，则往往需要将得到的分类进行解释，赋予各类一定的专业含义，同时也判断所得到的分类是否符合问题需要。有些情况下，可能还需要根据所用的分类器给出为什么把某个未知样本或新样本划分为某一类的解释，以利于人们利用这些分类结果进行后续的决策。

下面将分别介绍特征压缩、分类器的基本理论。

## § 2.5 特征压缩

前面提到，由特征提取过程得到的特征维数可能依然很大，如果将他们全部作为特征送往分类器，经常碰到“维数灾难”的问题，不仅使得分类器的结构复杂，存储特征的空间增大，分类计算判别量大，而且其分类效果不一定好。而用少数几个特征进行分类器设计，不仅在样本不多的条件下可以改善分类器的总体性能，而且在很多情况下，能够简化特征获取过程，以降低模式识别系统的代价。

特征压缩，就是为了减少特征维数，其方法有两种：①特征选择，就是从一组特征中挑选出一些最有效的特征以达到降低特征空间维数。②特征投影，就是通过映射（或变换）的方法把高维的特征向量变换为低维的特征向量。

### § 2.5.1 特征选择

特征选择的任务就是从一组数量为  $D$  的特征中选择出数量为  $d$  ( $D > d$ ) 的一组最优特征，为此有二个问题要解决。

一是选择的标准，需要一个定量的标准（或称判据）来衡量特征对分类的有效性。具体说来，从  $D$  个特征中选择出  $d$  个特征的各种可能组合有很多，哪种组合的分类效果最好，这就需要有一个比较标准。另一个问题是要找一个较好的算法，以便在允许的时间内找出最优的那一组特征。既然目的是设计分类器，那么用分类器的错误率作为标准就行了，也就是说，使分类器的错误概率最小的那组特征，就应当是一组最好的特征，从理论上说，这是完全正确的，但在实用中却有很大困难。特征的可分性用类间的离散度  $S_w$  与类内

的离散度  $S_b$  来度量，即  $S_b$  与  $S_w$  之比，若比值较大，则所选特征的可分离性

大，否则所选特征的可分离性小。 $S_b$  和  $S_w$  的表达式如下：

$$S_b = \sum_{i=1}^c P_i (\mu_i - \mu)(\mu_i - \mu)^T \quad (2.36)$$

$$S_w = \sum_{i=1}^c P_i E_i [(\mathbf{x} - \mu_i)(\mathbf{x} - \mu_i)^T] \quad (2.37)$$

其中  $\mu_i$  和  $\mu$  分别表示第  $i$  类目标特征的均值向量和所有各类的总体均值向

量, 且  $\mu_i = E_i[\mathbf{x}]$ ,  $\mu = E[\mathbf{x}]$ 。

在利用特征选择来减少特征维数的过程中, 保留了特征的原始性质, 这利于解释各个特征的物理含义, 但特征选择只保留了信号原始特征的一部分, 而其余的特征被取消, 所以这些特征包含的一些分类信息 (虽然很少) 被全部忽略了, 在信号类分离信息在原始特征空间分布很广的情况下, 特征选择方法得到的特征可能无法得到理想的结果。所以能否将原始特征的分类信息尽可能地集中到特征维数较低的特征空间, 这就是特征投影所要研究的问题。

### § 2.5.2 特征投影

特征投影就是通过某种数学变换, 把  $D$  个特征压缩为  $d$  个特征, 即

$$\mathbf{z} = W^T \mathbf{v} \quad (2.38)$$

其中  $\mathbf{v}$  是  $D$  维的原始特征向量, 变换矩阵  $W$  是一  $D \times d$  阶的矩阵, 经变换后的向量  $\mathbf{z}$  是  $d$  维的 ( $d < D$ )。特征提取的关键是求出最佳的变换矩阵, 使得变换后的  $d$  维特征的类别可分性准则值最大。通过变换, 得到的  $d$  维特征是原来  $D$  个特征的线性组合, 能够尽可能地反映各类模式之间的差异, 又尽可能相互独立, 这比单纯的选择方法更灵活, 效果也更好。一般常采用的变换是 Karhunen-Loeve 变换 (简称 K-L 变换), 是一种正交变换, 是在均方误差最小的意义下获得数据压缩的最佳变换, 且不受模式分布的限制。如采用大本征值对应的本征向量组成变换矩阵, 则能对应地保留原模式中方差最大的成分, 具有减小相关性和突出差异性的效果。

基于 K-L 变换的特征投影步骤如下:

- (1) 计算出  $c$  类目标  $D$  维特征向量空间  $\vec{X}(D, C * n_i)$  的类内离散度矩阵  $\hat{S}_w$ , 并求出其  $D$  个特征值  $\lambda_1, \lambda_2, \dots, \lambda_D$  和特征向量矩阵  $Y = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_D]$ 。 $\hat{S}_w$  可表示为

$$\hat{S}_w = \sum_{i=1}^c p_i \frac{1}{n_i} \sum_{k=1}^{n_i} \left( \left( \vec{X}_k^{(i)} - \vec{m}_i \right) \left( \vec{X}_k^{(i)} - \vec{m}_i \right)^T \right)$$

其中  $p_i$  表示第  $i$  类目标的先验概率,  $n_i$  表示第  $i$  类目标的样本数,  $\vec{m}_i$  表示第  $i$

类的  $n_i$  个样本特征向量集合  $\left\{ \vec{X}_k^{(i)}, k=1,2,\dots,n_i \right\}$  的均值向量;

(2) 计算出类间离散度矩阵  $S_b = \sum_{i=1}^c p_i \left( \vec{m}_i - \vec{m} \right) \left( \vec{m}_i - \vec{m} \right)^T$ , 其中

$\vec{m} = \sum_{i=1}^c p_i \vec{m}_i$  是总体均值;

(3) 计算类间平均距离  $J\left(\vec{X}_j\right) = \frac{y_j^T S_b y_j}{\lambda_j}$ ,  $j=1,2,\dots,D$ ; 并按降序

排列  $J\left(\vec{X}_1\right) \geq J\left(\vec{X}_2\right) \geq \dots \geq J\left(\vec{X}_D\right)$ ;

(4) 若需降到  $d$  维, 则取前  $d$  个较大的  $J\left(\vec{X}_j\right)$  对应的特征向量  $y_j$ ,

$j=1,2,\dots,d$ , 生成变换矩阵  $W = [y_1, y_2, \dots, y_d]$ ;

(5) K-L 投影的结果为  $\vec{X}' = W^T \vec{X}$ 。

这样经 K-L 变换后, 特征向量降为  $d$  维。

## § 2.6 分类器

分类器是目标识别系统一个重要的组成部分, 考虑到本文的重点在于特征提取, 所以仅仅对常用的几种分类器作简单介绍, 其它的分类器参见相关文献。

### § 2.6.1 最小距离分类器

假定有  $c$  个类别的  $w_1, w_2, \dots, w_c$  模式识别问题, 提取的目标特征为  $\mathbf{x}$ ,

每类的聚类中心为  $\mathbf{m}_1, \mathbf{m}_2, \dots, \mathbf{m}_c$ , 定义判别函数为

$$g_i(\mathbf{x}) = \|\mathbf{x} - \mathbf{m}_i\|, \quad i = 1, 2, \dots, c \quad (2.39)$$

按最小距离分类原理, 决策规则可以写为:

$$\text{若} \quad g_j(\mathbf{x}) = \min_i g_i(\mathbf{x}), \quad i = 1, 2, \dots, c \quad (2.40)$$

$$\text{则决策} \quad \mathbf{x} \in w_j \quad (2.41)$$

这一决策方法称为最小距离法。最小距离分类器构造简单, 但分类效果往往不理想, 原因在于仅仅利用了标准样本的信息, 而其它样本的信息则没有利用。

### § 2.6.2 近邻分类器

假定有  $c$  个类别的  $w_1, w_2, \dots, w_c$  模式识别问题, 每类有标明类别的样本

$N_i$  ( $i = 1, 2, \dots, c$ ) 个。规定  $w_i$  类的判别函数为

$$g_i(\mathbf{x}) = \min_k \|\mathbf{x} - \mathbf{x}_i^k\|, \quad k = 1, 2, \dots, N_i \quad (2.42)$$

其中  $\mathbf{x}_i^k$  的角标  $i$  表示  $w_i$  类,  $k$  表示  $w_i$  类  $N_i$  个样本中的第  $k$  个。按照上式, 决策规则可以写为:

$$\text{若} \quad g_j(\mathbf{x}) = \min_i g_i(\mathbf{x}), \quad i = 1, 2, \dots, c \quad (2.43)$$

$$\text{则决策为} \quad \mathbf{x} \in w_j \quad (2.44)$$

这一决策方法称为最近邻法。其直观解释是相当简单的, 就是说对未知样本  $\mathbf{x}$ , 我们只要比较  $\mathbf{x}$  与  $N = \sum_{i=1}^c N_i$  个已知样本之间的欧氏距离, 并决策  $\mathbf{x}$  与离它最近的样本同类。

由最近邻法可以得到  $k$ -近邻法。从字意上看, 这个方法就是取未知样本  $\mathbf{x}$  的  $k$  个近邻, 看这  $k$  个近邻中多数属于哪一类, 就把  $\mathbf{x}$  归为哪一类。

### § 2.6.3 径向基函数网络<sup>[88][93]</sup>

径向基函数 (Radial Basis Function, 缩写为 RBF) 网络不仅具有良好的推广能力, 而且避免了象反向传播那样繁琐、冗长的计算, 使学习可以比通常的 BP 方法快  $10^3 \sim 10^4$  倍。RBF 网络的基本结构如图 2-5 所示。这种网络的特点是: 只有一个隐层, 隐层采用径向基函数作为其输出特性, 输入层到隐层之间权值均固定为 1; 输出节点为线性求和单元, 隐层到输出节点之间的权值可调, 因此输出为隐层的加权求和。




图 2-5 径向基函数网络示意图

所谓径向基函数, 就是某种沿径向对称的标量函数。通常定义为空间中的任一点  $x$  到某一中心点  $x_c$  之间欧氏距离的单调函数, 可记作  $k(\|x - x_c\|)$ , 其作用往往是局部的, 即  $x$  远离  $x_c$  时函数取值很小。最常用的径向基函数是高斯函数, 形式为

$$k(\|x - x_c\|) = \exp\left\{-\frac{\|x - x_c\|^2}{2\sigma^2}\right\} \quad (2.45)$$

其中  $x_c$  为核函数中心,  $\sigma$  为函数的宽度参数, 控制了函数的径向作用范围。在 RBF 网络中, 这两个参数往往是可调的。

## § 2.7 本章小结

本章首先阐述了混沌分形的基本理论。引入了李天岩和 Yorke 所提出关

于混沌的数学定义,介绍了描述混沌的两个基本参数:Lyapunov 指数和分形维数;Lyapunov 指数表示了混沌信号的长期不可预测性,分形维数描述了混沌吸引子的复杂程度;分形维数有多种定义,文中主要介绍了 Hausdorff 维和关联维。接下来本章介绍了小波分析的基本理论。小波分析是傅立叶分析的一大突破,其在时域和频域同时具有良好的分辨率,得到了广泛的应用。文中主要介绍了离散小波变换、小波多分辨分析以及小波包分析的概念和原理。最后本章讨论了目标识别的问题描述,给出了目标识别系统的 5 个组成部分;详细描述了特征压缩的方法:特征选择和特征投影,在本论文中主要采用特征投影方法(K-L 变换)进行特征维数的减少;关于分类器,主要介绍了本论文中要用到的几种分类器;关于特征提取,将要的后面的章节中详细介绍,因此在本章中只作了简单介绍。



## 第三章 状态空间重构技术

### § 3.1 引言

自从 1963 年气象学家 Lorenz 发现“蝴蝶效应”，给出来确定性方程具有混沌解的第一个实例以来，非线性动力学混沌研究取得了长足的进展。从研究方法来看，混沌研究主要有实验研究、计算机模拟和数学分析等等。近年来随着计算机的广泛应用，时间序列分析法在非线性和系统研究中日益受到重视。在许多情况下，人们常难以写出动力系统演化方程的具体形式，而唯一可观测到的是一个或多个时间序列。虽然不能说这一时间序列包含了系统的全部特征，但它确实蕴含了丰富的动力学信息。因此，由观测获得某个物理量的时间序列，对其进行有效分析，成为了解未知系统的动力学性质的重要手段。时间序列分析的首要问题便是状态空间重构。

由时间序列构造一个多维的、确定的状态空间，称作状态空间重构。重构是分析一个时间序列和建立一个预测模型必不可少的步骤。Packard<sup>[94]</sup>、Ruell 以及 Takens<sup>[95]</sup>分别把重构的概念引入动力系统理论，他们用数值和理论的方法说明了重构状态空间能够保持原来动力系统的几何不变性，如吸引子的分形维、轨迹的 Lyapunov 指数等特性。

在水声信号处理中，无论是舰船目标辐射的噪声还是目标在发射波激励下产生的回波，我们所能采集到的只是系统的一个观测变量的输出，表现为时间序列的形式，反映的只是系统的外部特性，如果要观测系统的内部行为，则必须获得系统的状态方程，而这在实际中往往是难以实现的。章新华等<sup>[7]</sup>从相空间轨迹、关联维和 Lyapunov 指数等方面研究了舰船辐射噪声的混沌现象；杨夙<sup>[12]</sup>从分形维和 Lyapunov 指数两方面分析了回波信号，发现了回波信号具有混沌特性，而越来越多的研究<sup>[5]-[15]</sup>也表明了舰船辐射噪声和回波信号具有混沌特性。

在过去的十几年当中，对不同重构方法的研究以及确定合适的重构参数问题的探索，一直是这一领域的焦点。现有的重构方法有延迟坐标（delay coordinates）法、微分坐标（derivative coordinates）法以及主元分析（principal component analysis，简称 PCA）法<sup>[96]</sup>等。微分坐标法首先是 Packard 等人<sup>[94]</sup>用数值方法进行了研究，Takens<sup>[95]</sup>进一步证明了只要嵌入维数足够大，微分坐标能够定义一个嵌入。这种方法由于在噪声存在的情况下受到较大的影响等原因，一般较少讨论。延迟坐标法是一种应用最广泛的重构方法，这种方法的优点是在每个分量上的信噪比能够保持一致，但是重构质量依赖于重构窗口的选择，并且坐标间存在着线性依赖及人为的对称性<sup>[96]</sup>。主元分析法<sup>[96]</sup>是分解多维数据到线性独立的坐标系里的一种方法，其体现出很好的改善信

噪比的特点。但是,由此还不能说明一种方法比其他方法更优越。例如,Fraser<sup>[97]</sup>便提出了在某些情况下延迟坐标法得到的重构比主元分析法得到的质量要好;同样 Casdagli 等人提出了相反的证据<sup>[98]</sup>。由此可见这里的问题较复杂。但是一般而言,在噪声的影响较大时,局部主元分析可能体现出较好的特性;而受短数据影响比较大时,延迟重构可能是更好的选择<sup>[98]</sup>。在本文中,采用延迟重构的方法。

本章将首先讨论状态空间重构方法的理论基础和延迟向量的构造,然后介绍基于状态空间重构的混沌特征参数估计算法,主要是关联维和最大 Lyapunov 指数的算法实现,随后分析了 PCA 在抑制噪声突出混沌性态的理论基础,最后通过 Lorenz 混沌模型和实测回波信号进行了仿真。

## § 3.2 状态空间重构

### § 3.2.1 理论基础

对于两个维数不大相同的状态空间内的动态系统,如果它们的渐进动态关系被限制在相同维的吸引子上,则可以认为它们属于相同的类。这构成了将确定性动力学引入实验技术领域的基础。显然,如果有可能以某种方式从高维相空间中提取出低维流形,就可以避免计算中的许多困难,这样一种提取过程可以通过较低维空间中嵌入一个流形来获得。

$A$  是一个紧的光滑可微流形,如果  $A$  到  $F(A)$  是一个光滑的一对一映射,且具有光滑的逆映射,则称该映射是  $A$  的一个嵌入。应该注意到,嵌入给出了两个流形之间的一个微分同胚,这一事实意味着嵌入建立了一个可微的等价关系。Whitney 关于嵌入在欧几里得空间里普遍存在的定理,证明了一个光滑的 ( $C^2$ )  $n$  维流形 (紧的和 Hausdorff 的) 可被嵌入到  $R^{2n+1}$  中。这一定理成为 Packard<sup>[94]</sup>和 Takens<sup>[95]</sup>提出由时间序列重构相图技术的基础。Takens 证明了流形的相关定理,而这个定理是状态空间重构技术的基础,其表述如下:

**Takens 定理** 设  $M$  是  $n$  维的紧流形,  $F$  是一个光滑的 ( $C^2$ ) 矢量场,  $v$  为  $M$  上的一个光滑函数,则由  $\Phi_{F,v}: M \rightarrow R^{2n+1}$  定义的  $\Phi_{F,v}(z)$  是一个嵌入,

其中  $\Phi_{F,v}(z) = (v(z), v(\varphi_1(z)), \dots, v(\varphi_{2n}(z)))^T$ ,  $\varphi_i$  表示  $F$  的流,  $(\bullet)^T$  表示转置算子。

$v(z)$  对应着系统状态为  $z$  ( $z \in M$ ) 时的观测值,包含  $\Phi_{F,v}(M)$  的空间称

作嵌入空间, 嵌入空间的维数称作嵌入维数。而在实际应用中, 通过延迟向量的构造<sup>[96]</sup>可以将上述内容与系统实测的时间序列 (即  $v_1, v_2, \dots, v_i, v_{i+1}, \dots$ , 其中  $v_i = v(\varphi_i(z))$ ) 联系起来。应用 Takens 定理重构状态空间的方法就是延迟坐标法。

### § 3.2.2 延迟方法

为了便于说明, 我们引入一些概念: 包含  $\Phi_{F,v}$  的映像称为嵌入空间, 嵌入空间的维数称之为嵌入维, 以下用  $m$  表示, 一般说来, 它不等于  $2d+1$ , 这是因为  $M$  的维数  $d$  往往是未知的。但是, 我们一般假定  $m \geq 2d+1$  以满足前边提到的 Takens 嵌入定理。

为了构造延迟向量, 引入 “ $(m, \tau)$  窗口” 这个有用的概念, 其中  $\tau$  表示时间序列的延迟量, 这个窗口使得时间序列中的  $m$  个元素是可见的。当  $\tau=1$  时, 该窗口中的元素是连续的; 当  $\tau>1$  时, 该窗口中的相邻元素之间有  $\tau$  个采样时间间隔。我们把 “ $(m, 1)$  窗口” 称为 “ $m$ -窗口”。在任何情况下,  $(m, \tau)$  窗口中的可见元素都将构成嵌入空间  $R^m$  中某个向量的分量, 当时间序列逐步移动通过这个窗口, 便产生了嵌入空间中的向量序列, 从而形成了离散的轨迹。为了表达, 引入符号:

$$x_i = \Phi_{F,v}(\varphi_i(z)) = (v_i, v_{i+\tau}, \dots, v_{i+(m-1)\tau})^T \quad (3.1)$$

(a) 5-窗口

$$v_1 \ v_2 \ \dots \ v_{i-1} \ \boxed{v_i} \ \boxed{v_{i+1}} \ \boxed{v_{i+2}} \ \boxed{v_{i+3}} \ \boxed{v_{i+4}} \ v_{i+5} \ \dots$$

$$x_i = (v_i, v_{i+1}, v_{i+2}, v_{i+3}, v_{i+4})^T$$

(b) (5,3)窗口

$$v_1 \ v_2 \ \dots \ \boxed{v_i} \ \dots \ \boxed{v_{i+3}} \ \dots \ \boxed{v_{i+6}} \ \dots \ \boxed{v_{i+9}} \ \dots \ \boxed{v_{i+12}} \ \dots$$

$$x_i = (v_i, v_{i+3}, v_{i+6}, v_{i+9}, v_{i+12})^T$$

图 3-1 延迟向量的构造说明

由图 3-1 说明了用  $(m, \tau)$  窗口构造延迟向量。

以目前的形式构造延迟向量还存在一些困难, 这是由于 Takens 定理与测

量过程没有直接联系在一起,存在着没有详细说明了几个时间尺度,最明显的是采样时间 $\tau_s$ 、延迟时间 $\tau_L = J\tau_s$ 和窗口长度 $\tau_w = m\tau_L$ 。在实际中,使用较小的采样时间对平滑轨迹可以产生良好的逼近,但是却会在 $m$ -窗口产生高度相关的样本。另外, Takens 定理看起来对嵌入维 $m$ 的选取提供了信息,即 $m \geq 2d+1$ 。然而,当我们对分析的系统 $M$ 没有任何先验知识时,即 $M$ 的维数 $d$ 往往不能预先知道,因而这一信息并没有多少实用性。有人采用的方法<sup>[99]</sup>是逐渐地增加 $m$ ,直到其轨迹不再交叉,通过这样来确定嵌入维 $m$ ,但这是一个相当主观的标准,在高维空间或是存在噪声干扰的情况下很快变得不能实行。另外的一个难题是以这种方法划分数据将人为的对称性引入到其相图中。从解释多维吸引子结构的观点看,会导致在正交平面的投影是一样的。例如,  $(i, j)$  平面的投影与所有  $(i+k, j+k)$  平面的投影是一样的,只要  $i+k, j+k \leq m$ 。实际上,当增加嵌入维时,在每个新的嵌入空间也就增加了其人为的对称性。

### § 3.3 主元分析方法

如前文所述,实现状态空间重构的方法很多,而其性能的好坏将直接影响混沌特征参数的估计精度。为了克服上文中提到一些缺点,我们引入了主元分析方法(Principal Component Analysis, 简称 PCA)。Broomhead 和 King<sup>[96]</sup>是最早将主元分析用于延迟重构,用以消除坐标间的线性依赖和人为的对称性。由测量所获得的数据不可避免地包含有噪声,而噪声是进行状态空间重构的主要障碍之一,通过以下的分析即将看出,主元分析方法可以降低噪声,从而为在噪声中提取混沌性态提供了可靠的理论基础。

#### § 3.3.1 奇异值分解

主元分析方法的理论基础是 Karhunen-Loeve 变换(简称为 K-L 变换)和奇异值分解(Singular Value Decomposition, 简称 SVD), K-L 变换在第二章介绍过了,在这儿只介绍一下奇异值分解。

矩阵的奇异值具有如下两个特征:①矩阵的奇异值具有非常好的稳定性,当矩阵中的元素发生小的变化时,奇异值的变化很小;②奇异值是矩阵所固有的特征。

下面我们具体讨论矩阵的奇异值及其性质。

定理 1 (奇异值分解)若  $A \in R^{m \times n}$ , 则存在正交矩阵  $U = [u_1, \dots, u_m] \in R^{m \times m}$

和  $V = [v_1, \dots, v_n] \in R^{n \times n}$ , 使

$$U^T A V = \text{diag}(\sigma_1, \dots, \sigma_p) \quad (3.2)$$

其中  $p = \min(m, n)$ ,  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p > 0$ 。此处  $\sigma_i, i = 1, 2, \dots, p$  为矩阵  $A$  的奇异值, 是  $AA^T$  或  $A^T A$  的特征值  $\lambda_i$  的算数根, 即  $\sigma_i = \sqrt{\lambda_i}$ 。

定理 2 (奇异值的稳定性)  $A^{m \times n}, B^{m \times n} \in R^{m \times n}$ , 它们的奇异值分别为  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n, \tau_1 \geq \tau_2 \geq \dots \geq \tau_n$ , 则

$$|\sigma_i - \tau_i| \leq \|A - B\|_2 \quad (3.3)$$

此定理的意义是: 当矩阵  $A$  有微小波动时, 它的奇异值的改变不会大于扰动矩阵的 2-范数。

定理 3 (奇异值的比例不变性) 设  $A^{m \times n}$  的奇异值为  $\sigma_1, \sigma_2, \dots, \sigma_k$ ,  $\alpha A^{m \times n}$  的奇异值为  $\sigma_1^*, \sigma_2^*, \dots, \sigma_k^*$ , 则

$$|(\alpha \cdot A)(\alpha \cdot A)^T - \sigma^{*2} I| = 0$$

$$\text{即} \quad |AA^T - \sigma^{*2} I / \alpha^2| = 0 \quad (3.4)$$

上式中  $I$  为单位阵。

$$\text{故} \quad |\alpha|(\sigma_1, \sigma_2, \dots, \sigma_k) = (\sigma_1^*, \sigma_2^*, \dots, \sigma_k^*) \quad (3.5)$$

即, 经过归一化处理, 可实现奇异值的比例不变性。

定理 4 (奇异值的旋转不变性) 矩阵  $A$  作旋转变换, 相当于左乘一个酉矩阵  $P$ , 旋转后  $A$  变为  $PA$ ,  $PA$  与  $A$  具有相同的奇异值。

从这些定理可以看出, 矩阵奇异值符合模式识别中的特征所要求的稳定性及旋转、比例不变性。它是一个有效的模式特征, 又奇异值是矩阵固有的特征, 能有效地反映矩阵的特征。

### § 3.3.2 奇异系统

将  $(m, \tau)$  一窗口应用于  $N$  个数据点时间序列  $\{v(n), n = 1, 2, \dots, N\}$ , 结果

得到嵌入空间  $R^m$  内的  $M = N - (m-1)r$  个向量序列  $\{x_i, i = 1, 2, \dots, M\}$ , 这些向量构成了  $m$  维嵌入空间的状态转移轨迹。用这样的向量序列来构造一个轨迹矩阵  $X$ , 它包含了在窗口内出现的全部记录:

$$X = M^{-\frac{1}{2}} [x_1, x_2, \dots, x_M]^T = \begin{bmatrix} v_1 & v_2 & \dots & v_M \\ v_{1+r} & v_{2+r} & \dots & v_{M+r} \\ \dots & \dots & \dots & \dots \\ v_{1+(m-1)r} & v_{2+(m-1)r} & \dots & v_{M+(m-1)r} \end{bmatrix}^T \quad (3.6)$$

式中引入  $M^{-1/2}$  作为适当的正则化, 向量  $x_i$  定义如式 (3.1) 所示。轨迹矩阵  $X$  包含了时间序列提供的所有信息, 并且从中可以获得时间序列不易直接观察获得的信息。

轨迹矩阵  $X$  及其转置可以看成是空间  $R^m$  和  $R^M$  之间的线性映射, 嵌入空间  $R^m$  是所有  $m$  元素模式的空间, 是所研究的自然对象。同样地,  $R^M$  也有类似的解释。事实上, 矩阵  $X$  的列和行具有类似的相互关系, 但这儿我们以简单的方式利用  $R^M$  的性质, 即用标准基向量  $e_i$  ( $e_i \in R^M$ ) 标记嵌入空间  $R^m$  内的各点 (其中,  $e_i$  是  $M \times M$  单位矩阵的第  $i$  列)。这样, 我们可以通过左乘运算提取出轨迹矩阵  $X$  的第  $i$  个向量  $x_i$ :

$$x_i^T = M^{-1/2} e_i^T X \quad (3.7)$$

由此直接可推出, 运算一般的向量  $\omega^T = M^{-1/2} \sum_{i=1}^M \omega_i e_i^T$  (其中  $\omega_i$  为权值) 将产生嵌入空间  $R^m$  内对应轨迹的线性组合,  $\omega^T X$  是嵌入空间的平均位置, 它对应于该轨迹的时间加权平均。对于  $(X, R^m, R^M)$  三者之间的关系, 我们可以采用奇异系统进行分析。以下将以延迟向量的构造为基础, 讨论奇异系统分析。

### §3.3.3 独立性与正交性

区别混沌系统和随机布朗系统的主要原理是自由度的数目, 但自由度的定义有很多种, 与出现的上下文有关。例如, 在信号处理领域中, 自由度是

描述一个信号包含显著能量的模式个数；在动态系统中，自由度通常用来定义相空间中吸引流形的维数、吸引子本身的维数或甚至是整个相空间的维数。当自由度在信号处理领域中的定义形式与动态系统解释相关时，就变成了包含嵌入流形的某个子空间的维数。尽管这样得到的自由度不是嵌入过程的一个不变量，但它给出了流形维数  $m$  的一个合理上界。

我们首先计算包含嵌入流形的子空间维数，为此，我们需要知道通过  $x_i$  的线性组合由嵌入空间的轨迹构造的线性独立向量的个数，当  $R^M$  中的向量用于轨迹矩阵时就产生了这种线性组合。考虑向量集  $\{s_i \in R^M\}$ ，我们假定它们作用于  $X$  会产生嵌入空间  $R^m$  的线性独立向量组。不失一般性，我们假定该线性无关向量组已经正交化，因此，它们构成了嵌入空间的一个完备正交基  $\{c_i | i = 1, 2, \dots, m\}$ ，根据以上构造，有以下关系成立：

$$s_i^T X = \sigma_i c_i^T \quad (3.8)$$

式中  $\{\sigma_i\}$  是用来确定两组向量正则化的实常数集。

$\{c_i\}$  的正则化强加了以下条件：

$$s_i^T X X^T s_j = \sigma_i \sigma_j \delta_{ij} \quad (3.9)$$

式中  $\delta_{ij}$  是 Kronecher delta。由于  $M \times M$  矩阵  $\Theta = X X^T$  是实对称的，因此它的特征向量构成了空间  $R^M$  的完备正交基，所以用  $\Theta$  的特征向量求解方程 (3.8) 就可得到：

$$\Theta s_i = \sigma_i^2 s_i \quad (3.10)$$

式中  $\{\sigma_i^2\}$  解释为对应的特征值。注意到形式为  $X X^T$  的矩阵是非负定的，因此

$\{\sigma_i\}$  是实常数，不失一般性，我们将其取为非负的。

式 (3.6) 可以用来说明  $\Theta$  实际上表示了对嵌入空间轨迹上所有的点对作数量积运算所得到的矩阵形式：

$$\Theta = M^{-1} \begin{bmatrix} x_1^T x_1 & x_1^T x_2 & \cdots & x_1^T x_M \\ x_2^T x_1 & x_2^T x_2 & \cdots & x_2^T x_M \\ \vdots & \vdots & & \vdots \end{bmatrix} \quad (3.11)$$

因此,称 $\Theta$ 为轨迹的结构矩阵,同样的,它也可以解释为在 $m$ 一窗口出现的所有图形对作相关的结果,这种相关具有很大的冗余度,导致了 $\Theta$ 有低秩。

从式(3.8)可以证实 $\Theta$ 最多有 $m$ 个 $\{\sigma_i\}$ 是非零的,因此,可以避免当 $m$ 很大时对 $\Theta$ 的正交化困难。

为此,当 $\sigma_i \neq 0$ 时,对式(3.8)作转置运算,然后左乘 $X$ ,再结合式(3.10),

可以得到由向量 $s_i$ 推导出向量 $c_i$ 的表达式:

$$Xc_i = \sigma_i s_i \quad (3.12)$$

利用向量集 $\{s_i\}$ 的正交性,类似于式(3.10),可以得到如下特征值方程:

$$Ac_i = \sigma_i^2 c_i \quad (3.13)$$

上式中 $A = X^T X$ 是 $m \times m$ 的实对称矩阵,用轨迹的定义可以表示为:

$$A = \frac{1}{M} \sum_{i=1}^M x_i x_i^T \quad (3.14)$$

该式中 $A$ 表示了 $x_i x_i^T$ 的时间平均,因此即为向量集 $\{x_i\}$ 中的元素在整个轨迹上作平均运算的方差矩阵,也就是 $m$ 一窗口内所有元素对的时间相关。用原始时间序列表示如下:

$$A = M^{-1} \begin{bmatrix} \sum_{i=1}^M v_i v_i & \sum_{i=1}^M v_i v_{i+1} & \cdots & \sum_{i=1}^M v_i v_{i+m-1} \\ \vdots & \vdots & & \vdots \\ \sum_{i=1}^M v_{i+m-1} v_i & \sum_{i=1}^M v_{i+m-1} v_{i+1} & \cdots & \sum_{i=1}^M v_{i+m-1} v_{i+m-1} \end{bmatrix}$$

由以上分析可以看出,由于嵌入维 $m$ 与轨迹上重构向量的个数 $M$ 相比之下要小很多,因此对比于方程(3.10),方程(3.13)更容易处理。

现在讨论 $\Theta$ 的秩,从方程(3.10)到方程(3.13)的推导过程可以看出,结构矩阵 $\Theta$ 和方差矩阵 $A$ 的非零特征值是相同的,即 $\Theta$ 的秩 $=A$ 的秩 $=$



$n' \leq n$ 。因此空间  $R^M$  可以分解  $n'$  维的子空间和它的正交补空间,  $n'$  维子空间由向量集  $\{s_i | i = 1, 2, \dots, n'\}$  展开, 该向量集利用式 (3.8) 对  $x_i$  作相应的平均从而得到确定的  $c_i \in R^m$ , 而由向量集  $\{s_i | i = n'+1, \dots, m\}$  展开的正交补空间是轨迹矩阵  $X$  的内核, 其映射是嵌入空间的原点。

完备正交基  $\{s_i\}$  构造了整个轨迹上所有可能的平均值, 而对其进行分解的意义在于只有那些与  $n'$  维子空间有关的才反映了嵌入空间  $R^m$  中非平凡向量, 也就是说, 从整个轨迹最多可以构造出嵌入空间内  $n'$  个线性无关的向量组。因此, 可以假定  $A$  的秩  $n'$  便是包含嵌入流形的子空间的维数。但注意到轨迹矩阵  $X$  一般都要受到噪声源的影响, 以下将重点讨论这种噪声影响的结果。

### § 3.3.4 奇异值分解与噪声

为了研究噪声的影响, 需要讨论特征向量和相关的奇异谱。考虑  $m \times m$  的正交矩阵  $C$  ( $C = (c_1, c_2, \dots, c_m)$ ), 和对角矩阵  $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_m)$  (其中假设  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m$ ), 利用这些标记, 方程 (3.13) 可以写为:

$$AC = C\Sigma^2 \quad (3.15)$$

由  $A$  的定义有:

$$(XC)^T(XC) = \Sigma^2 \quad (3.16)$$

矩阵  $XC$  是轨迹矩阵在  $\{c_i\}$  基上的投影。由于  $\{c_i\}$  是通过对角化方差矩阵得到的, 因此这一结果说明了在该向量基上轨迹的各个分量是不相关的。当我们不考虑  $(m, \tau)$  一窗口的一般性时, 仍可得到这种预期的结果, 这就表明每个  $\sigma_i^2$  是轨迹在相应向量  $c_i$  上的均方投影, 因而奇异谱  $\{\sigma_i^2\}$  就包含了所探究的嵌入空间的有用信息。在对其进行平均意义上的研究, 可以把轨迹看作是  $m$  维的椭球体,  $\{c_i\}$  给出了主轴方向,  $\{\sigma_i\}$  则给出了对应主轴的长度。由上一部分讨论知道, 轨迹流形被限制在维数为  $A$  的秩的子空间内, 但在有噪声的环境中需要对其进行一定的合理限制, 因为噪声在存在可能涂满整个确定

性态,而在较小的或为零的 $\sigma_i$ 相关的方向上,噪声占优势。因此正如前文所言,在由轨迹流形的确定分量探究嵌入空间的子空间维数时, $A$ 的秩只是提供了合理的上界。

像线性代数中熟知的那样,上述形式可以用来表达奇异线性映射的奇异值分解,在信息理论中这种思想的重要性已经在不同的应用中进行了讨论,而在这里,我们感兴趣的是轨迹矩阵的奇异值分解:

$$X = S\Sigma C^T \quad (3.17)$$

式中 $S$ 表示结构矩阵 $\Theta$ 的 $M \times m$ 特征向量矩阵,具有 $n'$ 个非零特征值,因此 $C$ 和 $S$ 的向量即为轨迹矩阵 $X$ 的奇异向量,对角矩阵 $\Sigma$ 的元素就是相应的奇异值。

为了举例说明噪声的影响,我们考虑下列具有噪声分量 $\xi_i$ 的时间序列的简单模型: $v_i = \bar{v}_i + \xi_i$ ,引入上划线表示确定性分量。对于与 $\bar{v}_i$ 无关的白噪声来说,该时间序列的自相关函数可以表示为 $\langle v_i v_j \rangle = \langle \bar{v}_i \bar{v}_j \rangle + \langle \xi^2 \rangle \delta_{ij}$ ,式中的角括弧表示时间平均运算算子。一般来说,在统计平稳的无限时间序列的极限情况下,该时间序列的方差矩阵 $A$ 具有Toeplitz结构: $A_{ij} = g(|i-j|T_s)$ ,其中 $g(\cdot)$ 表示连续时间序列的自相关函数。因此,在上述的极限情况下,该时间序列的方差矩阵可作如下分解: $A = \bar{A} + \langle \xi^2 \rangle I_m$ ,其中 $I_m$ 表示 $m \times m$ 单位矩阵。这样,轨迹矩阵 $X$ 的奇异值作一致的移位:

$$\sigma_i^2 = \bar{\sigma}_i^2 + \langle \xi^2 \rangle, \quad i = 1, 2, \dots, m \quad (3.18)$$

式中 $\bar{\sigma}_i^2$ 表示矩阵 $\bar{A}$ 的相应特征值。这样噪声的结果使轨迹矩阵的所有特征值变为非零,因而需要引入一种方法来区分这两种类型所产生的影响。

在白噪声的简单情况下,非零平台的存在是一个显著的特征,可以用来区分系统中的确定分量,而在更一般的情况下,只包含实验噪声的时间序列的独立观测量使对该时间序列在向量集 $\{c_i\}$ 上的均方根投影计算变为可能,

将这种投影计算结果与包含确定性信号的时间序列的奇异值进行比较,可以定义一种与每个奇异向量相关联的信噪比。这种技术即使在非白噪声的情况下也可以对那些噪声控制的奇异值进行区分,但由于对噪声分量进行分离测

量并非总是可能的，因此在信号处理的研究中人们把兴趣都放在了发展一种称为关联有效（cross-validation）的技术上，利用此技术，数据本身的内部一致性可以用来估计噪声级。

假定已经用适当的方法对奇异谱进行了划分，我们进一步来讨论它对嵌入空间的影响。考虑矩阵  $p^{(i)}$ ：  $p^{(i)} = \delta_{ij} \delta_{jk}$ ，它们代表了基向量  $\{c_i\}$  上的投影算子，利用这些投影算子可以重新构造投影到嵌入空间相应子空间上的投影算子：

$$Q = \sum_{\sigma_i > \text{noise}} p^{(i)} \quad (3.19)$$

$$P = \sum_{\sigma_i > \text{noise}} p^{(i)} \quad (3.20)$$

将恒等式  $P + Q = I_m$  代入方程 (3.17) 得到：

$$X = \bar{X} + \Delta X \quad (3.21)$$

$$\text{式中} \quad \bar{X} = SP\Sigma C^T \quad (3.22)$$

代表轨迹矩阵中隐含的确定分量，而

$$\Delta X = SQ\Sigma C^T \quad (3.23)$$

代表轨迹矩阵中的噪声控制部分。这种划分排除了实验本身内在的噪声影响，在信号处理领域中称为排除带外噪声，而这里相当于对数据进行超采样处理从而能够实现对窗口那更多的点上进行噪声平均。

从现在起，我们把注意力转移到简化的轨迹矩阵  $\bar{X}$ ，因为它包含了能从实验中获得的所有确定轨迹的一切信息，将式 (3.12) 代入式 (3.22) 可以得到：

$$\bar{X} = \sum_{\sigma_i > \text{noise}} (Xc_i)c_i^T \quad (3.24)$$

该表达式中的各个分量均可以通过方差矩阵的对角化获得，而且它给出了矩阵  $\bar{X}$  与描绘相轨迹的方法论直接相关的解释，式中  $c_i^T$  表示了嵌入空间中指向标准基的坐标轴，而  $(Xc_i)$  则表示了一个列向量，它包含了在基  $\{c_i\}$  内轨迹

上各分量的第  $i$  个分量的时间序列。

显然如此构造的  $\bar{X}$  是一个  $M \times m$  矩阵, 它由限制在嵌入空间  $R^m$  中维数  $d \leq m$  的确定性子空间内的轨迹流形所组成 (其中  $d$  表示高于噪声平台的奇异值  $\{\sigma_i\}$  的个数), 直接定义了限制在该子空间中的那些向量, 我们用方括弧来标记这些向量, 因此被限制在确定性子空间中的矩阵  $\bar{X}$  便成了  $M \times d$  的长方形阵, 其第  $j$  行可以表示为  $[x_j^T c_1, x_j^T c_2, \dots, x_j^T c_d]$ 。而如果实验噪声不是白化的, 就有必要对向量集  $\{c_i\}$  重新标记以使其前  $d$  个向量可以展开为确定性子空间。

### § 3.4 基于状态空间重构的混沌特征参数估计

#### § 3.4.1 状态空间重构的参数选择

在进行状态空间重构时, 首先需要合理地选择重构参数, 主要是延迟时间  $\tau$  和嵌入维数  $m$ 。Takens 定理在实际应用中存在一定的局限性, 这是因为定理对数据的要求隐含着没有噪声的影响, 且长度为无限。

延迟时间是影响重构吸引子质量的关键因素之一, 而且重构轨迹的动力学特征量对它相当敏感。如果延迟时间  $\tau$  取得太小, 相邻元素间的相关性太大, 则重构轨迹被压缩在嵌入空间的主斜线附近, 导致有用信息的丢失; 如果延迟时间  $\tau$  取得过大, 则状态转移轨迹在嵌入空间会呈现极为复杂的运动形态, 而这反映的往往不是系统的真实情况<sup>[98]</sup>。在大量的文献中<sup>[98]-[104]</sup>, 人们在延迟时间  $\tau$  和嵌入维数  $m$  的选择上倾注了大量的精力, 并取得了一定的成效, 且方法不一, 而且针对这两个参数的选择给出了大量的解释。其中较常见的有相关函数法, 交互信息法等。选择样本信号自相关函数的第一个过零点作为延迟时间, 可以使相邻元素之间的相关性最小, 并且这在水声信号处理中是一种常用的方法<sup>[105]-[107]</sup>。因此, 本文中也采用了这一方法确定延迟时间  $\tau$ 。

在确定嵌入空间的维数时, 由前面的 Takens 定理表述, 我们明确了嵌入空间的维数应该满足关系式  $m > 2d + 1$ , 这里  $d$  为原动力系统的自由度数。从实用的角度讲, 由于计算量等原因, 嵌入维数不能太高, 但嵌入维数如果太小, 容纳不下原来的吸引子, 会使所有点挤压在一起, 出现轨道交叉、重

叠。

### § 3.4.2 吸引子的关联维和最大 Lyapunov 指数估计算法

分形维数可以对混沌吸引子复杂的几何形态进行定义和描述。在第二章中已经提及, Grassberger 和 Procaccia<sup>[108][109]</sup>发展了一种实用算法实现对一维时间序列的关联维计算。算法描述如下:

对于一个给定的时间序列  $\{v_i, i = 1, 2, \dots, N\}$ , 根据嵌入理论, 经过合理地选择重构参数即延迟时间  $\tau$  和嵌入维数  $m$  后, 可以构造出  $M = N - (m-1)\tau$  个延迟向量  $\{x_i, i = 1, 2, \dots, M\}$ , 从而重构出状态空间轨迹矩阵  $X$ :

$$X = [x_1, x_2, \dots, x_M]^T \quad (3.25)$$

上式中  $x_i = [v_i, v_{i+\tau}, \dots, v_{i+(m-1)\tau}]^T$ , ( $i = 1, 2, \dots, M$ );  $[\cdot]^T$  表示转置运算。我们定义相关积分:

$$C(\varepsilon) = \frac{1}{M^2} \sum_{i,j=1}^M H(\varepsilon - \|x_i - x_j\|) \quad (3.26)$$

式中  $H$  是 Heaviside 函数:

$$H(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases} \quad (3.27)$$

$\varepsilon$  表示度量的正数,  $\|\cdot\|$  可以为任何一种范数, 工程文献中为了计算方便多采用欧拉范数。关联维数可以由下式求得:

$$D_2 = \lim_{\varepsilon \rightarrow 0} \ln C(\varepsilon) / \ln(\varepsilon) \quad (3.28)$$

关联维与相关积分的关系是建立在能量定律的基础之上的, 在  $\varepsilon$  足够小的前提下结果是有效的, 即可以通过在坐标上  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线确定关联维的数值大小。在符合能量定律的区域上该曲线将显示为一条直线, 它的斜率就是所估算的关联维  $D_2$ , 可以通过最小均方拟合得到。当嵌入维  $m$  足够大时, 对于混沌时间序列, 关联维  $D_2$  收敛于某一数值。

Lyapunov 指数是用来衡量动力学系统相邻轨迹平均发散率的一个物理量。最大 Lyapunov 指数  $\lambda_1$ , 表明了混沌系统对初始状态的依赖程度, 以及

距离很近的相点之间演化轨迹的发散程度。很多人对如何计算 Lyapunov 指数进行了大量的研究<sup>[110]~[114]</sup>, 本文采用 Wolf 等人<sup>[114]</sup>发展的算法, 其基本思想如下:

对于给定的时间序列  $\{v_i, i=1, 2, \dots, N\}$ , 根据嵌入理论, 重构的吸引子上  
的状态点可以表示为  $x_i = [v_i, v_{i+r}, \dots, v_{i+(m-1)r}]$ , 则  $\{x_i, i=1, 2, \dots, M\}$  确定了重  
构的状态空间的轨迹形状。为了估计最大 Lyapunov 指数, 我们观察一对相互  
靠近的轨迹的长期演化结果。选择基准轨迹, 记其初始点为  $x_1$ , 考虑与该初  
始点最靠近的相点, 它们之间的距离用符号表示为  $L(1)$ , 称为初始长度。假  
设时间序列  $v_n$  足够长, 则针对基准轨迹上的任一点, 都存在一个与之相邻点

并满足条件  $L(i) < d, i=1, 2, \dots$ , 其中  $d$  表示嵌入空间  $R^m$  中某一小球的半径,  
并假设  $d$  远远小于所重构出的吸引子的扩充范围。以所有这些假设为基础,  
对于刚刚提到的初始长度, 经过一次平均轨迹时间后, 将演化为长度可能大  
于  $d$  的  $L(2)$ , 然后将该非基准数据点用与基准数据点  $x_2$  相靠近的点替换, 并  
使其满足条件  $L(2) < d$  和保持相同的方向。不断的重复该过程直至用完所有  
的状态点为止, 则最大 Lyapunov 指数  $\lambda_1$  便可估计为:

$$\lambda_1 = \frac{1}{K} \sum_{i=1}^K \ln \frac{L'(i+1)}{L(i)} \quad (3.29)$$

式中  $K$  表示所有的替换次数。该方法的重要之处在于它通过简单的替换来保  
持方向和替换向量的最小化, 用以观察单个主轴向量的长期演化行为, 以此  
来达到估计最大 Lyapunov 指数的最终目的。

### § 3.4.3 Lorenz 模型的仿真估计

为了比较延迟方法和 PCA 方法, 我们分别用这两种方法对关联维数进行  
仿真分析。Lorenz 微分方程可以描述为:

$$dx/dt = \sigma(y - x) \quad (3.30a)$$

$$dy/dt = x(R - z) - y \quad (3.30b)$$

$$dz/dt = xy - bz \quad (3.30c)$$

式中参数作如下选择:  $\sigma = 16.0$ ,  $R = 45.92$ ,  $b = 4.0$ 。用龙格-库塔法求  
解上式, 时间间隔选为 0.01, 产生 1000 个点, 利用前面讨论过的算法, 对关  
联维和最大 Lyapunov 指数分别进行估计。

对于关联维, 由 G-P 算法可知, 只要得到  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线, 便可对

于直线段部分进行最小二乘拟合求得斜率,从而得到相应的关联维估计值。对以上产生的 1000 个点进行处理,得到如图 3-2(a)所示的  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线,拟合其直线段部分,估计出其关联维的值约为 2.0636。对于最大 Lyapunov 指数,观察其随时间的演化趋势,得到如图 3-2(b)所示的曲线,其收敛值 1.9939 即为所估计的最大 Lyapunov 指数。




图 3-2 关联维和 Lyapunov 指数曲线




图 3-3 信噪比为 10、5、0 时 PCA 得到的奇异谱

通过前文的讨论可知: PCA 从能量的角度出发,得到的奇异谱显示出噪声平台,对混沌控制部分和噪声控制部分进行了划分,而且在信噪比不太低的情况下,噪声平台以上的奇异值个数就显示出混沌系统隐含的独立变量的个数,由这些奇异值对应的特征向量所展开的空间将包含更多的混沌信息,并对附加噪声有一定的抑制作用,最大的奇异值对应的奇异向量所展开的空

间将具有最大的信噪比改善。为了说明这一点,仿真数据采用 Lorenz 混沌模型的  $x$  分量作为混沌信号,与正态分布的白噪声混合所构成的时间序列。图 3-3 分布显示了在不同信噪比下的奇异谱,图(a)(b)(c)对应的信噪比分别为 10、5、0,其中延迟时间  $\tau=1$ ,选择嵌入维  $m=20$ 。由图可观察到明显的“平台”,且信噪比越低,噪声平台越高,但噪声平台以上的奇异值个数是 3,这与 Lorenz 模型的独立变量个数相符。

接下来我们用 PCA 方法分别计算关联维和最大 Lyapunov 指数。仿真信号仍用 Lorenz 混沌模型的  $x$  分量与正态分布的白噪声叠加所构成的时间序列,取信噪比分别为 20, 10, 5 和 0 dB。选择重构参数时,取延迟时间为 1,嵌入维数为 20,图 3-4(a)(b)分别表示了不同信噪比条件下进行 PCA 处理前后的  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线。在图(a)中,随着信噪比的降低,  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线中的直线段部分下移,而斜率随之急剧增大,这是由于噪声的存在掩盖了曲线上反映混沌信号的斜率较小的部分;而从图(b)中可以看出,经过 PCA 处理后的  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线中的直线部分变得平坦,而且直线段的区间变长,随着信噪比的降低,曲线的变化不是很大,这说明 PCA 对信噪比变化具有很强的鲁棒性,能够在较低的信噪比条件下抑制噪声,突出其混沌特性。表 3-1 中列出了对图 3-4 中曲线的直线段区域拟合得到的关联维的估计值,通过比较可以看出,经 PCA 处理后得到的结果更接近于真实值。

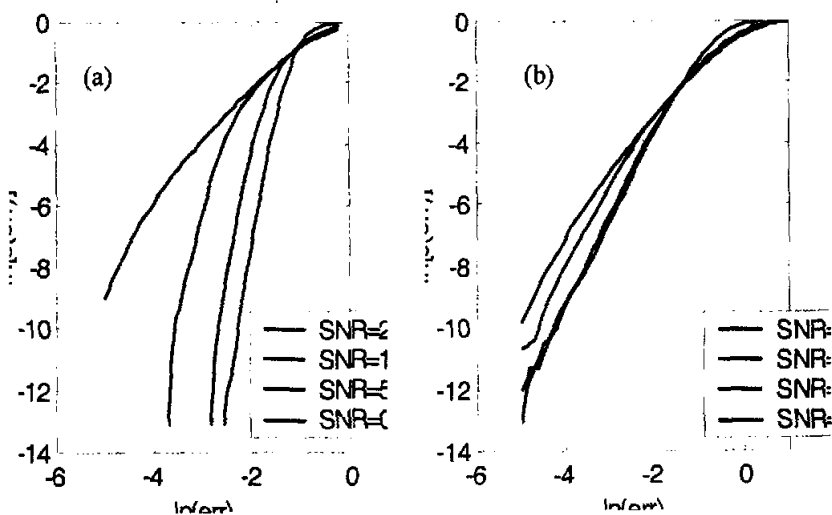


图 3-4 PCA 处理前(a)、后(b)的  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线

其次分析最大 Lyapunov 指数,它是衡量动力学系统相邻轨迹平均发散率的一个物理量,也就是表明了混沌系统对初始状态的依赖程度。前文已经估计出 Lorenz 模型的最大 Lyapunov 指数  $\lambda_1$  的最大值约为 1.9939,而对于正态



分布的高斯白噪声的研究发现, 其最大 Lyapunov 指数  $\lambda_1$  趋近于零, 当存在噪声时, 由于噪声的影响,  $\lambda_1$  的值有减小的趋势。为了证实 PCA 在保持最大 Lyapunov 指数的作用, 表 3-2 中列出了在信噪比分别为 20, 10, 5, 0dB 时, 最大 Lyapunov 指数  $\lambda_1$  经 PCA 处理前后的变化情况。

显然, 从前边对关联维和最大 Lyapunov 指数分析, 证实了 PCA 在抑制噪声、保持混沌特征方面的有效性。

表 3-1 不同信噪比下 PCA 处理前后的关联维估计值

	SNR = 20	SNR = 10	SNR = 5	SNR = 0
PCA 处理前	6.9097	7.1337	7.1940	7.7004
PCA 处理后	2.0774	2.2019	2.1446	2.1891

表 3-2 不同信噪比下 PCA 处理前后的最大 Lyapunov 指数估计值

	SNR = 20	SNR = 10	SNR = 5	SNR = 0
PCA 处理前	1.9209	1.3443	0.7641	0.5137
PCA 处理后	1.9668	1.8598	1.6941	0.9971




图 3-5 发射信号的波形与频谱

### § 3.4.3 实测宽带回波的混沌参数估计

本文以莱蒙湖底不同沉积物的反射回波作为研究对象,这五类湖底沉积物分别为沙砾石、岩石、卵石、沙、淤泥。该湖区为浅水区,将具有恒定束宽的宽带换能器由测量船吊放到水下垂直照射湖底,距离湖底平均距离为11m,实验在湖面相对平静条件下进行,发射信号为一宽带矩形包络线性调频脉冲信号,脉冲宽度为1ms,调频宽度20KHZ~140KHZ,采样频率为1MHZ,各类回波每组有36个样本,每类有4~5组样本,采样点2000~3000个。发射信号的波形及频谱如图3-5所示,五类典型沉积物的反射回波如图3-6所示。




图3-6 不同湖底沉积物的反射回波

(自上而下依次为沙砾石、岩石、卵石、沙、淤泥)

分析实测回波信号的混沌性态,最终目的是要提取出有效的混沌特征参数,这些参数可以用来实现目标识别。我们根据前文的分析,知道PCA提供了更加稳定可靠的估计算法,突出其混沌性。

对于实测回波信号,其真实的关联维数是未知的,因此仅仅依靠某一个嵌入维数来计算并不能可靠地反映其估计的真实性。但根据前文的分析,混

沌信号的关联维随着嵌入维的增加将保持相对稳定，而不会随嵌入维的增加而线性增加。以下就以此为依据，观察关联维随嵌入维的变化趋势，图 3-7 显示了各类回波的  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线结果，而  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线中各曲线所代表的嵌入维数分别为 9, 12, 15, 18, 21, 24, 27, 30。图中(a)到(e)分别对应如图 3-6 所示的五类回波，根据图 3-7 中的  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线结果可以计算出如表 3-3 所示的关联维随嵌入维数的变化趋势。




图 3-7 五类回波的  $\ln C(\varepsilon) \sim \ln(\varepsilon)$  曲线

表 3-3 五类回波的关联维随嵌入维的演化结果

	嵌入维							
	9	12	15	18	21	24	27	30
沙砾石	3.3101	3.2304	3.3617	3.4076	3.3390	3.3344	3.3122	3.2707
岩石	2.4107	2.3084	2.4225	2.5734	2.5717	2.7799	2.7785	2.7010
卵石	2.9444	3.0370	3.1102	3.1470	3.1538	3.1950	3.2819	3.2518
沙	3.0225	2.9636	2.8741	2.8306	2.8209	3.2660	3.1994	2.9933
淤泥	2.8256	2.8165	2.8332	3.0639	2.9628	2.8745	2.9224	2.8748

接下来分析它们的最大 Lyapunov 指数。图 3-8 显示了各类回波的最大 Lyapunov 指数  $\lambda_1$  演化图, (a)到(e)分别是沙砾石、岩石、卵石、沙、淤泥的回波。表 3-4 列出了得到的最大 Lyapunov 指数  $\lambda_1$ 。

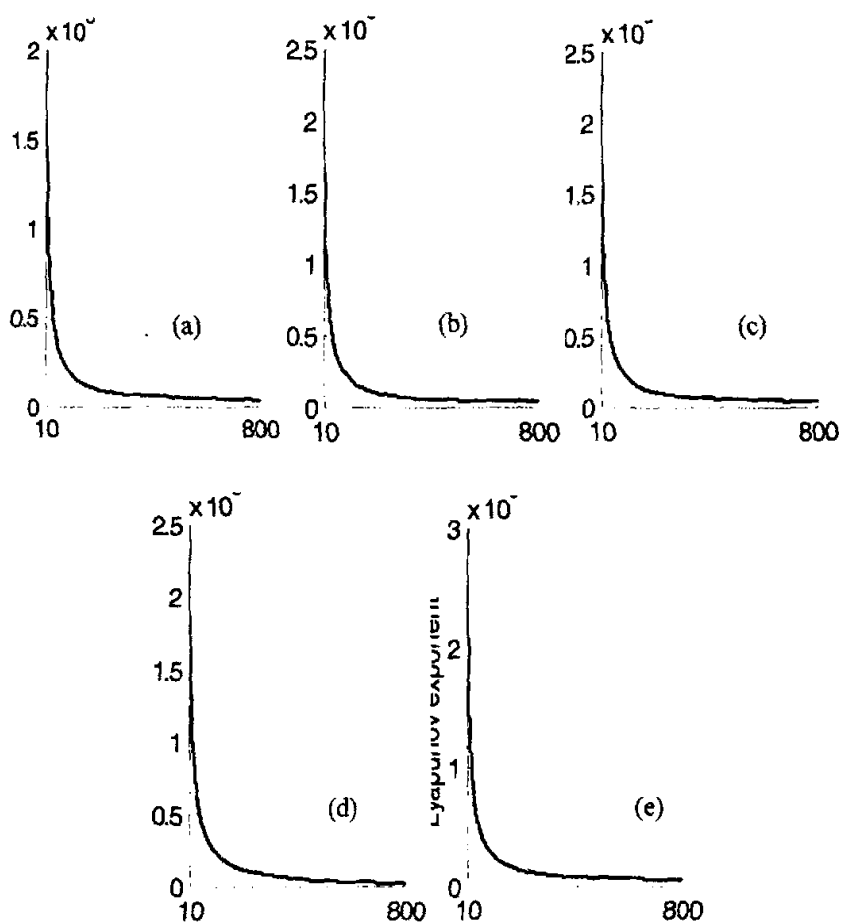


图 3-8 五类回波的最大 Lyapunov 指数演化曲线

表 3-4 五类回波的最大 Lyapunov 指数估计值

	沙砾石	岩石	卵石	沙	淤泥
$\lambda_1$	$3.8326 \times 10^3$	$4.7230 \times 10^3$	$4.9346 \times 10^3$	$2.2722 \times 10^3$	$5.7609 \times 10^3$

许多文献指出最大 Lyapunov 指数  $\lambda_1$  只能表明混沌性态的存在, 而不能用作其它应用的根据。

### § 3.5 基于状态空间重构与 K-L 变换的特征提取

前文已经提到, 在水声信号的处理中, 由于无法获得系统的状态方程, 也就难以直接观测系统的内部行为, 而我们所能采集到的只是系统的一个观测变量的输出, 是系统状态转移轨迹经过某种变换后的一维输出, 表现为时间序列的形式, 反映的只是系统的外部特征。但是, 一维观测序列中包含了系统状态向量的大量信息, Parkard<sup>[94]</sup> 和 Takens<sup>[95]</sup> 的研究工作表明, 通过某种变换 (即经过状态空间重构) 可以将一维序列变换到一个高维空间中, 并且将保留原系统的所有信息, 这意味着, 在时间序列中无法直接观测到的信息, 利用状态空间重构的方法能够反映出来。基于状态空间重构的混沌信号处理方法在雷达信号处理<sup>[25]</sup>与水声信号处理<sup>[6]</sup>领域中的应用已经取得了一定的成效。

以上这些研究工作表明, 基于状态空间重构的混沌信号处理方法可以用于信号的特征提取。文献[12]通过分形维数和 Lyapunov 指数说明了回波信号具有混沌特性; 同时文中采用状态空间重构的方法对回波信号进行特征提取和分析, 但对于特征值的构成有一定随机性, 效果并不能保证稳定。本文提出一种基于状态空间重构与 K-L 变换相结合的特征提取方法, 对五类湖底回波进行了仿真, 仿真结果表明该方法具有较好的分类效果, 并具有一定的稳定性<sup>[115]</sup>。

#### § 3.5.1 特征提取和目标识别的步骤

(1) 由于同样的发射信号, 不同湖底沉积物的反射信号不尽相同, 而且各类回波的时间起点也不尽相同, 因此, 首先对回波信号进行预处理, 使得各类回波的时间起点和数据长度相同, 并进行能量归一化, 得到时间序列  $\{v_i\}, i=1, 2, \dots, N$ 。

(2) 根据得到的回波时间序列, 选择其自相关函数的第一个过零点

为延迟时间  $\tau$ , 选择足够大的嵌入维数  $m$ , 得到轨迹矩阵  $X$  (如(3.6)式所示); 为了减少计算量, 我们按(3.14)式构造轨迹的方差矩阵  $A = X^T X$ , 而不是构造(3.11)式的结构矩阵  $\Theta = XX^T$ ; 将方差矩阵  $A$  进行奇异值分解, 由(3.15)式和(3.16)式可得:

$$A = C \Sigma^2 C^T \quad (3.31)$$

式中  $C$  是  $m \times m$  的正交矩阵, 对角矩阵  $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_m)$ , 其中

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m$ , 则  $\{\sigma_1^2, \sigma_2^2, \dots, \sigma_m^2\}$  构成了  $A$  的奇异谱, 作为我们所要提取的特征。

(3) 对于未知的系统, 一般选取的嵌入维数比较大, 这样使得通过状态空间重构技术获得的特征向量维数较高, 这就要求将高维特征向量压缩为低维特征向量, 以利于减轻分类器的存储量与计算量。为此, 可采用 § 2.5 介绍过的 K-L 特征压缩器, 来降低特征维数。




图 3-9 5 类湖底回波的特征分布

+沙砾石回波 ●岩石回波 ◇淤泥回波 □沙回波 △卵石

(a) 图是 5 类回波的特征分布, (b) 图是其中 3 类回波的特征分布

(4) 选择嵌入维为 30, 压缩到 3 维。

### § 3.5.2 仿真结果

图 3-9 是 5 类回波的 3 维特征分布图, 其中(a)图是 5 类回波的特征分布, 从中可以看到有 3 类回波的特征似乎有一定的重叠, 于是在(b)图是画出了这 3 类回波的特征分布。由此可以看出, 5 类回波具有明显的类内紧致性和类间可分性。

## § 3.6 本章小结

状态空间重构是混沌信号处理的基础, 而状态空间重构方法的选择直接影响到有效的提取混沌特征参数。本章首先从状态空间重构的方法入手, 利用 Takens 嵌入定理, 介绍了重构方法的理论基础。在 § 3.3 中, 详细讨论了主元分析方法(PCA)在抑制噪声方面的分析原理和实现算法, 利用 Lorenz 模型作为研究对象进行了仿真, 分别用延迟重构方法和 PCA 方法来估算不同信噪比下 Lorenz 模型的关联维和最大 Lyapunov 指数, 仿真结果说明了 PCA 方法从能量的角度出发, 在一定的程度上滤除了噪声, 突出了混沌性态。利用 PCA 方法对实测回波数据进行了分析, 估算并提取了五类回波的混沌特征参数: 关联维和最大 Lyapunov 指数。在 § 3.5 中, 提出了基于状态空间重构与 K-L 变换相结合的特征提取方法, 对文献[12]中用的方法进行了改进, 提取了相对稳定有效的特征。

## 第四章 小波域特征提取的方法研究

### § 4.1 引言

小波变换是近十几年新发展起来的一种数学工具,是继一百多年前的傅立叶(Fourier)分析之后的又一个重大突破,它对无论是古老的自然学科还是新兴的高新应用技术学科均产生了强烈的冲击。

长期以来,傅立叶变换一直是处理这方面问题最重要的工具,并且已经发展了一套内容非常丰富并在许多实际问题中行之有效的办法。但是,用傅立叶变换分析处理信号的方法也存在着一定的局限性与弱点,傅立叶变换提供了信号在频率域上的详细特征,但却把时间域上的特征完全丢失了,也就是说只有频率分辨率而没有时间分辨率。傅立叶变换只适应于确定性的平稳信号,对时变的非平稳信号不能充分描述,由于傅立叶变换的上述缺陷,人们一直在寻求新的方法。针对傅立叶变换的这一弱点,在 40 年代法国学者 Gabor 提出了“加窗傅立叶变换”的概念,加窗傅立叶变换具有时频局部化的特点;但是,加窗傅立叶变换窗口的形状和大小一经选定就保持不变,与频率无关,熟知在研究高频信号的局部性质时窗口应开得小一些,而在研究低频信号的局部性质时窗口应开的大一些,也就是说窗口大小应随频率而变。窗口不随频率而变,这是加窗傅立叶变换的一个严重缺点。

80 年代后期发展起来的小波变换继承和发展了 Gabor 变换局部化的思想,同时又克服了窗口大小不随频率变化的缺点。小波变换是一种信号的时间—尺度(时间—频率)分析方法,它具有多分辨率分析(Multiresolution Analysis)的特点,而且在时频两域都有表征信号局部特征的能力,是一种时间窗和频率窗都可以改变的时频局部化分析方法。即在低频部分具有较高的频率分辨率和较低的时间分辨率,在高频部分具有较高的时间分辨率和较低的频率分辨率,被称之为分析信号的显微镜。因此,小波分析在很多领域得到了广泛的应用。

本章利用小波分析的理论,如小波变换、小波多分辨率分析和小波包分解等,对实测回波信号进行特征提取,并结合第三章的回波混沌特征进行分类识别。

### § 4.2 常用小波函数介绍

与标准傅立叶变换相比,小波分析中所用到的小波函数不具有唯一性,即小波函数具有多样性。但小波分析在工程应用中,一个十分重要的问题是最优小波基的选择问题,这是因为用不同的小波基分析同一个问题会产生不



同的结果。不同的信号、不同的研究目的对于小波函数的要求各不相同,譬如,要求小波函数具有正交性、一定的对称性和光滑性等,这些要求经常矛盾,需要在应用中合理予以取舍。所以基于小波变换的特征提取一个重要的问题是小波函数的选择问题,但对于特征提取和目标识别而言,如何选择最佳的小波基没有一个普适的标准,这一直是一个公开的问题<sup>[61]</sup>。目前主要是通过用小波分析方法处理信号的结果来判断小波基的好坏,并由此选定小波基。

小波函数一般具有以下性质:

(1) 定义域是紧支撑的,也就是说函数具有速降特性,以便获得空间的局域化和快的计算速度;

(2) 消失矩,即  $\int_{-\infty}^{\infty} t^k \psi(t) dt = 0$ , 小波函数的消失矩阶数越高,利于逼近信号中的平滑部分,它对压缩非常有用;

(3) 正则性,它对信号或图象的重构获得较好的平滑效果非常有用。

经过十多年的发展,科学家们已经设计出了几种在工程技术领域有非常重要应用的小波函数,如 Harr 小波、Daubechies 小波系、Biorthogonal 小波系、Morlet 小波以及 Mexican Hat 小波等等,在这里只简单介绍文中用到的一些小波函数。

(1) Harr 小波,它是在小波分析中最早用到的一个具有紧支撑的正交小波函数,同时也是最简单的一个函数。

(2) Daubechies 小波系,由 Daubechies 构造,具有紧支撑的不对称小波,具有正交性,在给定支撑宽度内有较高的消失矩,  $N$  阶 Daubechies 小波用  $dbN$  表示,滤波器的长度为  $2N$ , 支撑宽度为  $2N-1$ , 且消失矩为  $N$ 。Daubechies 小波基由于其良好的逼近性和稳定性,得到了广泛应用。

### § 4.3 二进离散小波变换

连续小波变换最初是由 Morlet 等人于 1984 年提出的,从理论上讲,连续小波变换的尺度和平移是连续变化的,尺度、平移的连续性使得时间尺度网格较二进离散网格更为细致,有利于提取信号中频率接近的成分,但其最大的缺点是其庞大的计算量和很大的数据量。在实际运用中,尤其是在计算机上实现时,连续小波变换必须加以离散化。但这一离散化是针对连续的尺度参数  $a$  和连续平移参数  $b$  的,而不是针对时间变量  $t$  的。

在连续小波中,考虑函数:

$$\psi_{a,b}(t) = |a|^{-1/2} \psi\left(\frac{t-b}{a}\right) \quad (4.1)$$

这里  $a, b \in R$ , 且  $a \neq 0$ ,  $\psi$  是容许的, 为了方便起见, 总限制  $a$  只取正值, 相容性条件就变为

$$C_{\psi} = \int_{-\infty}^{\infty} \frac{|\hat{\psi}(\omega)|^2}{|\omega|} d\omega < \infty \quad (4.2)$$

通常, 把连续小波变换中尺度参数  $a$  和平移参数  $b$  的离散化公式分别取作  $a = a_0^j$ ,  $b = ka_0^j b_0$ , 这里  $j \in Z$ , 扩展步长  $a_0 \neq 1$  是固定值。然而, 怎样选择  $a_0$  和  $b_0$  呢? 为了使小波变换具有可变化的时间和频率分辨率, 适应待分析信号的非平稳性, 我们很自然地需要改变  $a$  和  $b$  的大小, 以使小波变换具有“变焦距”的功能。换言之, 在实际中采用的是动态的采样网格。最常用的是二进制的动态采样网格, 即  $a_0 = 2$ ,  $b_0 = 1$ , 每个网格对应的尺度为  $2^j$ , 而平移为  $2^j k$ 。由此得到的小波

$$\psi_{j,k}(t) = 2^{-j/2} \psi(2^{-j}t - k) \quad j, k \in Z \quad (4.3)$$

称为二进制小波。

如果  $\psi_{m,n}(t)$  满足正交条件

$$\int \psi_{m,n}(t) \psi_{p,q}(t) dt = \begin{cases} 1 & m=p, n=q \\ 0 & \text{其它} \end{cases} \quad (4.4)$$

则  $\psi_{m,n}(t)$  为二进正交小波。

二进小波对信号分析具有变焦距的作用。假定有一放大倍数  $2^{-j}$ , 它对应为观测到信号某部分的内容。如果想进一步观看信号更好的细节, 就需要增加放大倍数即减小  $j$  值; 反之, 若想了解信号更粗的内容, 则可以减小放大倍数, 即加大  $j$  值。在这个意义上, 小波变换称之为数学显微镜。二进离散小波变换只是对尺度参数进行了离散化, 而对时间域上的平移量保持连续变换, 因此二进离散小波不破坏信号在时间域上的平移不变量。

## § 4.4 基于多分辨分析的特征提取

Mayer 于 1986 年创造性地构造出具有一定衰减性的光滑函数, 其二进制

伸缩与平移构成了  $L^2(R)$  的规范基, 才使小波得到真正的发展。1988 年 Mallat 在构造正交小波基时提出了多分辨分析 (Multiresolution Analysis, MRA) 的概念, 从空间的概念上形象地说明了小波的多分辨率特性, 将此之前的所有正交小波基的构造法统一起来, 给出了正交小波的构造方法以及正交小波变换的快速算法, 即 Mallat 算法, 使小波变换在实际工程中得到广泛的应用。Mallat 算法在小波分析中的地位相当于快速傅立叶变换算法在经典傅立叶分析中的地位。

#### § 4.4.1 信号的多分辨正交小波分解

在第二章中已经对多分辨分析进行了定义, 其与人类视觉有惊人的相似。例如人在观察某一目标的时候, 不妨设他所处的尺度为  $j$  (或  $2^j$ ), 观察目标所获得的信息为  $U_j$ , 当他走进目标, 即尺度增加到  $j+1$  (或  $2^{j+1}$ ), 他观察目标所获得的信息  $U_{j+1}$  应该比尺度  $j$  下获得的信息更为丰富, 即  $U_j \subset U_{j+1}$ , 尺度越大, 距离越近, 信息越丰富。反之, 当他远离目标时, 即尺度减少到  $j-1$  (或  $2^{j-1}$ ), 他观察目标所获得的信息  $U_{j-1}$  应该比尺度  $j$  下获得的信息更为减少, 尺度越小, 距离越远, 信息越稀少。

通过 Mallat 算法, 可以得到多分辨分解的数学表达式:

$$\begin{cases} A_j f = \sum_k h(k-2n) A_{j-1} f \\ D_j f = \sum_k g(k-2n) A_{j-1} f \end{cases} \quad (4.5)$$

其中, 序列  $A_j f$  和  $D_j f$  分别称为信号  $f$  的逼近信号和细节信号。由于采用的小波函数的正交特性, 序列  $A_j f$  和  $D_j f$  的长度是分解前序列  $A_{j-1} f$  的一半, 因此信号经正交小波分解后数据量并未增加。

设以  $V_j$  表示多分辨分解中的低频部分  $A_j$ ,  $W_j$  表示分解中的高频部分  $D_j$ , 多分辨分析将信号空间分解为一个逼近空间和多个细节空间的直和:

$$V_0 = \left( \bigoplus_{j=1}^J W_j \right) \oplus V_1, \text{ 且每一个逼近空间等于下一个逼近空间与下一个细节空}$$

间的直和:  $V_{j+1} = V_j \oplus W_j$ 。信号的多分辨率分析将信号分解到具有不同分辨率的频率通带内, 且这种分解是正交的, 各频带之间无相关性。

### § 4.4.2 特征向量的构成

如何从多分辨率分解后的逼近信号和细节信号中构造有利于目标识别的特征信息? 这一直是人们关心的问题。通过对一些文献中基于多分辨率正交小波变换的特征提取方法的分析和比较, 可以得出以下一些认识<sup>[52][116]</sup>:

首先, 不同的尺度下, 即不同分辨率下的逼近信号(逼近系数)和细节信号(小波系数), 表征了不同频带中的信号成份, 但它们本身是时间序列, 与原始信号一样, 不同的样本间具有很大的变异性, 不适合作为特征。

其次, 若根据先验知识, 选择某个或几个尺度下的逼近信号或细节信号, 再对其做功率谱分析, 以谱估计参数构成特征向量。这种做法与直接对信号作功率谱估计的特征提取方法类似, 不同的样本特征存在较大的变异性, 特征维数较高, 要达到较高的正确识别率, 须借助人工神经网络分类器, 在网络规模和运算时间上需较大开销。

尽管人们可以选择感兴趣的子带信号从中提取特征, 但由于先验知识的欠缺, 具体哪些子带中包含有较多可用于识别的特征信息, 只能通过大量理论和实验研究才能确定; 而且单纯的选择某个子带, 必然会影响特征信息的完整性。有人将小波系数与逼近系数全部利用, 来构造特征空间, 这样所有各尺度上的信息没有丢失, 但无疑信息是冗余的, 而且不具有时移不变性, 识别的效果也不理想。

信号的正交小波表达是对信号的一个完备表达, 它所表征的是信号在各个频带内的信号分量, 因而从中所提取的特征量应该能完整地体现信号的特征。

定义各子带的能量为

$$en_j = \sum_{n=1}^{N/2^j} |D_j f(n)|^2, j=1, 2, \dots, J \quad (4.6a)$$

$$en_{j+1} = \sum_{n=1}^{N/2^{j+1}} |A_j f(n)|^2 \quad (4.6b)$$

则  $\{en_j, j=1,2,\dots,J+1\}$  构成信号的特征向量, 其中  $J$  表示小波多分辨分解的最大分解尺度。

#### § 4.4.3 特征提取与分类

为了验证该方法, 本文以 § 3.4.3 所述的莱蒙湖底不同沉积物的反射回波作为研究对象, 这五类湖底沉积物分别为沙砾石、岩石、卵石、沙、淤泥。每类有 2 组样本, 每组有 36 个样本, 选取其中的一组作为训练样本, 即总共有 180 个训练样本; 然后选取每类目标的另外一组作为测试样本, 即总共有 180 个测试样本。

具体的基于小波多分辨分析的特征提取与识别过程的流程图如图 4-1 所示。其中对回波信号先作预处理: 使得各类回波的时间起点和数据长度相同, 并进行能量归一化。特征提取部分, 主要是指选择那些能量相对集中的尺度空间能量组成特征向量。这样既能充分利用回波先验信息, 使目标回波的主要能量特征得以增强, 又能减小特征维数。但如果先验信息不明确或者减小特征维数导致分类能力降低, 那么仍应将所有尺度空间能量组成最终的特征向量。在本文中, 采用 K-L 变换来降低特征维数。




图 4-1 基于小波多分辨的特征提取与识别过程的流程图

多分辨分析对信号进行多层次分解, 在不同分辨率下描述信号的特征, 因此在信号的多分辨分析过程中影响分解结果的有两个参数: 分解层数和小波函数。在接下来的部分, 我们就来确定分解层数和使用的小波基这两个因素对分类效果的影响, 同时分析不同湖底介质的分类以及特征维数的降低对识别结果的影响。

##### 1) 分解层数的影响

对信号进行多少级分解, 即需要多少维特征向量就可以达到理想的分类效果, 在实际应用中需要通过实际数据来确定。对五类湖底回波信号进行 3~

7级小波分解, 采用的小波函数是4阶 Daubechies 小波(db4), 分类器采用最近邻分类器, 得到的识别结果由表 4-1 给出。

表 4-1 分解尺度为 3~7 的识别率

分解尺度 $J$ 特征维数	3 4	4 5	5 6	6 7	7 8
沙砾石	50.00%	58.33%	61.11%	61.11%	61.11%
岩石	83.33%	83.33%	83.33%	83.33%	83.33%
卵石	88.89%	86.11%	86.11%	86.11%	86.11%
沙	75.00%	86.11%	86.11%	86.11%	86.11%
淤泥	86.11%	91.67%	91.67%	91.67%	91.67%
平均识别率	76.67%	81.11%	81.67%	81.67%	81.67%

由表 4-1 的结果可以推断, 分解尺度不宜太小, 太小则对信号频带划分过于粗略, 损失有益的特征, 影响分类效果。就所分析的五类湖底回波信号而言, 分解尺度为 5 或 6 时就可以达到较好的分类效果。

## 2) 小波函数的影响

小波函数的选取, 对特征的提取和识别的结果有重要的影响。对五类回波信号经小波多分辨分解到 5 层, 小波函数选为 *haar*、*dbN* ( $N=1,2,\dots,10$ )。




图 4-2 在不同小波函数下的识别结果

五类回波在每个小波函数下的平均正确识别率如图 4-2 所示, 分类器采用最

近邻分类器。

由图 4-2 可知，当小波函数为 *db4* 时的平均正确识别率最高为 81.67%；当小波函数是 *db2* 时，其相应的平均正确识别率最低为 74.44%。

3) 不同湖底介质的分类

接下来讨论不同湖底介质的分类。沙砾石、岩石、卵石、沙、淤泥五类回波信号经 6 级 *db4* 小波分解后，得到 7 维特征向量  $\{en_j, j = 1, 2, \dots, 7\}$ ，采用最近邻分类器进行分类识别，结果如表 4-2 所示。

表 4-2 五类回波的识别结果

	测试 样本数	分为该类的数目					正确 识别率	平均 识别率
		沙砾石	岩石	卵石	沙	淤泥		
沙砾石	36	22	1	0	13	0	61.11%	81.67%
岩石	36	1	30	5	0	0	83.33%	
卵石	36	0	1	31	4	0	86.11%	
沙	36	3	0	2	31	0	86.11%	
淤泥	36	3	0	0	0	33	91.67%	




图 4-3 五类回波的 3 维特征分布图

○沙砾石   ▽岩石   ●卵石   +沙   □淤泥

由表 4-2 可以看出，进行 5 类回波的识别时，对沙砾石回波的识别率不高，

只有61.11%，而其它四类都达到了80%以上，对淤泥回波的识别率甚至达到了91.67%。为了进行更为细致的分类识别，我们画出了五类回波特征分布的直观图。图4-3表示沙砾石、岩石、卵石、沙、淤泥五类回波信号经6级db4小波分解后，对所构成的7维特征向量 $\{en_j, j=1,2,\dots,7\}$ 进行特征压缩后得到的3维分布图。由此图可以看出，①如果排除沙砾石，其它四类的界限较为明显，图4-4是这四类回波的特征分布图；②沙砾石与沙回波的特征分布存在较为明显的重叠部分，岩石与卵石虽然大部分能明显区分开，但也有少部分难以识别开来，可以将沙砾石与沙回波归为一类，和岩石、卵石、淤泥这三类回波一起，作为四类进行识别；或者将沙砾石与沙回波归为一类，岩石与卵石回波归为一类，淤泥回波作为单独的一类，进行三类识别；③如果将沙砾石、沙、淤泥回波归为一大类，而将岩石和卵石回波归为另一大类，则这两大类的界限很明显；




图4-4 四类回波的3维特征分布图

▽岩石 ●卵石 +沙 □淤泥

为此，可以得到以下分析结果，其中都采用了最近邻分类器进行分类。表4-3表示岩石、卵石、沙、淤泥这四类回波的识别结果，平均识别率达到了91.67%；表4-4表示将沙砾石与沙归为一类（记为A），和岩石、卵石、淤泥的识别结果，平均识别率为91.67%；A中沙砾石和沙回波的识别率分别为61.11%、91.67%；表4-5表示了将沙砾石与沙回波归为一类（记为A），岩石与卵石回波归为一类（记为B），淤泥回波作为单独的一类，进行三类识别，得到平均识别率是95.37%；B中岩石与卵石回波的识别率分别为86.11%、



97.22%；表 4-6 表示了将沙砾石、沙、淤泥回波归为一大类（记为  $C$ ），而将岩石和卵石回波归为另一大类（记为  $B$ ），进行两类识别的识别结果，得到的平均识别率是 98.61%； $C$  中沙砾石、沙、淤泥回波的识别率分别为 61.11%、91.67%、91.67%。

表 4-3 岩石、卵石、沙、淤泥四类回波的识别结果

	测试 样本数	分为该类的数目				正确 识别率	平均 识别率
		岩石	卵石	沙	淤泥		
岩石	36	31	5	0	0	86.11%	91.67%
卵石	36	1	31	4	0	86.11%	
沙	36	0	2	34	0	94.44%	
淤泥	36	0	0	0	36	100%	

表 4-4  $A$ 、岩石、卵石、淤泥四类的识别结果

	测试 样本数	分为该类的数目				正确 识别率	平均 识别率
		$A$	岩石	卵石	淤泥		
$A$	36	33	0	1	2	91.67%	91.67%
岩石	36	0	31	5	0	86.11%	
卵石	36	2	1	33	0	91.67%	
淤泥	36	1	0	0	35	97.22%	

表 4-5  $A$ 、 $B$ 、淤泥三类的识别结果

	测试 样本数	分为该类的数目			正确 识别率	平均 识别率
		$A$	$B$	淤泥		
$A$	36	33	1	2	91.67%	95.37%
$B$	36	1	35	0	97.22%	
淤泥	36	1	0	35	97.22%	

表 4-6  $C$ 、 $B$ 两大类的识别结果

	测试 样本数	分为该类的数目		正确 识别率	平均 识别率
		$C$	$B$		
$C$	36	36	0	100%	98.61%
$B$	36	1	35	97.22%	

- 4) 特征维数的降低对识别结果的影响
- 为了说明特征维数的降低对识别结果的影响，表 4-7 列出了沙砾石、岩

石、卵石、沙、淤泥五类回波特征维数与识别结果的关系。五类回波信号经 6 级 db4 小波分解后, 得到特征向量的维数是 7, 利用 K-L 变换来降低特征维数。

表 4-7 特征维数与识别结果的关系

特征维数	7	6	5	4	3
沙砾石	61.11%	61.11%	61.11%	52.78%	52.78%
岩石	83.33%	83.33%	83.33%	83.33%	83.33%
卵石	86.11%	86.11%	86.11%	88.89%	88.89%
沙	86.11%	86.11%	86.11%	83.33%	83.33%
淤泥	91.67%	91.67%	91.67%	88.89%	88.89%
平均识别率	81.67%	81.67%	81.67%	79.44%	79.44%

由表 4-7 可知, 当特征维数降低至 5 时, 平均识别率仍能达到最大值 81.67%; 当特征维数降低至 4 时, 平均识别率只有 79.44%。同时可以看到, 当特征维数为 7、6、5 时, 平均识别率都是最大值 81.67%。

## § 4.5 基于小波包分析的特征提取

小波包方法正是在多分辨率基础上构成的一种更精细的正交分解方法。小波多分辨分析没有对信号的高频部分序列进行再分解, 因此不能提高高频部分的频率分辨率, 而由 Colfman 和 Wickerhauser 提出的小波包分析<sup>[117]</sup>正好弥补了这一不足, 它比小波多分辨分析具有更好的局部化功能, 分解更加精细, 可以根据被分析信号本身的特点, 自适应地选择频带, 确定信号在不同频段的分辨率, 因此小波包具有更广泛的应用价值。

### § 4.5.1 信号的小波包分解

假定给定正交镜像滤波器  $h = h_n$ ,  $g = g_n$  满足条件:

$$\begin{cases} \sum_n h_{n-2k} h_{n-2l} = \delta_{kl} \\ \sum_n h_n = \sqrt{2} \\ g_k = (-1)^k h_{1-k} \end{cases} \quad (4.7)$$

其中当  $k=l$  时,  $\delta_{kl}=1$ ;  $k \neq l$  时,  $\delta_{kl}=0$ 。按照双尺度关系, 定义一列递

归函数  $\{W_k\}_{k=0}^{\infty}$ :

$$\begin{cases} W_{2l}(x) = \sum_k h(k)W_l(2x-k) \\ W_{2l+1}(x) = \sum_k g(k)W_l(2x-k) \end{cases} \quad (4.8)$$

由上式可见, 如果选择  $W_0(t)$  作为正交小波的尺度函数  $\varphi(t)$ , 那么  $W_1(t)$  就是相应的正交小波函数  $\psi(t)$ 。则由此定义的函数系  $\{W_n(t)\}_{n \in N}$  称为正交尺度函数  $W_0 = \varphi$  确定的正交小波包。

$H$ 、 $G$  分别为低通和高通镜像滤波器, 设离散化的小波包分解系数序列为  $x_p^{n,s}$  ( $s$  为尺度因子), 由以上的小波包算法, 可以得到信号  $x(t)$  的小波包分解的递推算法, 即

$$\begin{cases} x_p^{2n,s+1} = \sum_j x_j^{n,s} h_{j-2p} \\ x_p^{2n+1,s+1} = \sum_j x_j^{n,s} g_{j-2p} \end{cases} \quad (4.9)$$

其中  $x_p^{n,s} = \int 2^{s/2} W_n(2^s t - p) x(t) dt$ ,  $p \in N$ 。

小波包分解和正交小波分解非常类似, 只是对信号的高频部分实行了与低频部分相同的进一步分解。每次分解相当于同时进行低频和高频滤波, 进一步分析出低频和高频两部分, 这样一直下去, 使低频和高频都能达到很精细的程度。小波包分解的实质是让信号通过  $g_k$ 、 $h_k$  这对高低通组合滤波器同时进行二抽一采样, 从而把信号分解到不同的频段上。

#### § 4.5.2 最优小波包分解

但是, 将信号分为各频带子信号时, 随着分解方法不同, 各个频段的划分也不同。容易证明, 对信号按  $J$  级二进小波包分解时, 有  $2^{J-1}$  种方法, 同

时也存在相同数量的小波包基。这就产生了一个问题：如何根据实际问题，选择合适的小波包基？

最佳基算法由 Coifman 和 Wickerhauser<sup>[117]</sup>提出，提出的目的是为了信号压缩的需要。对于信号压缩，衡量变换的标准是看这种变换能否有效将信号的能量集中在尽可能少的几个系数上。最优基都是相对于一种标准  $\mu$  而言的，这个标准用来评价基函数的性能和比较基函数的有效性。这样，我们需要一种数学化的准则  $\mu$  来衡量这种有效性，通常这种准则被称为“信息代价”函数。相对于“信息代价”函数  $\mu$  的最优基就是使得“信息代价”函数最小的一组基函数。

信息代价函数  $\mu$  的选择可以有多种形式，经常用到的“信息代价”函数（熵和能量）有四种形式<sup>[118]</sup>，用  $x$  表示信号， $x_i$  表示信号  $x$  在一个正交小波包基上的分解系数：

(1) shannon 熵

$$\mu(x_i) = -x_i^2 \log(x_i^2), \quad \mu(x) = -\sum_i x_i^2 \log(x_i^2) \quad \text{约定 } 0 \log(0) = 0$$

(2)  $l^p$  范数 ( $1 \leq p < 2$ )

$$\mu(x_i) = |x_i|^p, \quad \mu(x) = \sum_i |x_i|^p$$

(3) 对数能量熵

$$\mu(x_i) = \log(x_i^2), \quad \mu(x) = \sum_i \log(x_i^2) \quad \text{约定 } \log(0) = 0$$

(4) 阈值熵

如果  $|x_i| > \varepsilon$ ，则  $\mu(x_i) = 1$ ；其余  $\mu(x_i) = 0$ ，则  $\mu(x) = \sum \mu(x_i)$  为信号大

于阈值  $\varepsilon$  的时间点的个数。

由此可以得出，信号分布越均匀，其熵值越小；信号越分散，其熵值越大。我们将一信号按照前述小波包基进行分解，同时对分解后的子信号计算其熵值，如果分解后的二段子信号的熵值和大于分解前的熵值，认为分解前的子信号已经分布很均匀，没有必要再分解下去了，于是，分解停止；否则，认为分解前的子信号分布不均匀，有必要进行区别，即有必要继续分解，于是，保留本次分解。通过以上步骤，完成了对一信号以此熵值最小为准则进行的最优小波包分解。由此获得的最佳子树比初始树要小得多，如图 4-5 所示，其中(a)是初始完整树结构图，(b)是经最优小波包分解后得到的最佳子树结构图。




图 4-5 小波包分解结构图

### § 4.5.3 特征向量的构成

长度为  $N$  的信号经过  $J$  层小波包分解后得到  $JN$  个小波包分解系数，即使经过最优基选择后，还有至少  $N$  个分解系数，尤其信号的长度较长时，所得的特征维数是相当大的<sup>[61]</sup>。原始特征维数过高时，特征投影需要计算高维矩阵的逆，其计算量很大，且稳定性较差。如何从小波包中构造特征向量呢？本文采用以下几种方法。

#### 1) 以小波包能量谱为特征

小波变换的能量与原始信号的能量之间存在着等价关系，这样用小波包能量谱来表示原始信号中的能量分布是可靠的，可以用小波包各子带能量谱作为信号的特征<sup>[118]-[121]</sup>。

对信号应用小波包变换，得到固定尺度  $j$  上的小波包系数序列：

$$\{x_{j,n,k}\}, j \in [0, J], n \in [0, 2^j - 1], k \in [0, N/2^j - 1]$$

其中， $J$  表示最大分解尺度。由于在尺度  $j$  下，也就是在同一层，各个子带的频带宽度相同，因此可以选取各个子空间（频带）内信号的平方和作为能量的标志。

尺度  $j$  下各子带的能量可以通过下式求得：

$$T_{j,n} = \sum_k x_{j,n,k}^2 \quad (4.10)$$

则  $\{x_{j,n}, n=0,1,\dots,2^j-1\}$  构成特征向量。

### 2) 以最佳子空间熵值为特征

前边提到的熵, 在信息论中, 可以理解为随机信号序列的不定性表现。熵越小, 信号序列的不定性程度越低, 从而该序列代表的信息量状态也就越稳定。

目标回波经采样后可得到时域内的随机序列, 利用小波包分解, 可将该时域随机信号序列映射为时间尺度域各子空间内的随机系数序列。此即表明, 按小波包分解得到的最佳子空间内随机系数序列的不定性程度最低, 在小波包变换域内的目标信息状态最为稳定。这种小波包分解结果中所包含的最稳定的信息状态可视为目标回波包含的特征状态。而不同种类目标对应的特征状态, 可由各自对应的最佳子空间的熵值及熵值总和来衡量。

在实际特征提取时, 各个回波的最佳小波包基的选取不可预见, 对应的二叉树结构各异, 即便是同一类目标的回波, 其二叉树的结构也略有不同。因此, 为了能得到同一的特征向量形式, 同时充分利用不同二叉树的结构信息及所有最佳子空间对应熵值, 可以以尺度为基准, 将每一尺度下属于最佳子空间的熵值求和, 以和值作为该尺度下的特征量, 并将所有尺度下的特征量依尺度分解顺序组合在一起, 形成最终的特征向量。

### 3) 以小波包 AR 谱为特征

对信号建立 AR 模型, 利用 Burg、Marple 等几种算法, 可以准确地计算信号的模型参数, 从而可以实现对信号的参数估计、谱分析等。AR 模型的优点在于能够对短数据进行分析, 且具有计算量小、谱估计的分辨率高等优点, 是现代谱估计中重要的方法之一, 在信号处理中得到广泛地应用。

AR 模型要求被分析的信号必须是平稳的、零均值的、正态分布的随机过程。对于非平稳信号而言, 一般的分析方法是首先对信号进行分段, 分段以后的信号可以近似地认为在每一帧中是平稳的, 因而可以建立 AR 模型。小波包分解能够将信号分解为一系列带宽相同、中心频率不同的成分。考虑到信号的小波包分解的特点, 我们试用小波包首先对信号进行分解, 然后对小波包分解的各个分量建立 AR 模型。

假设信号在固定尺度  $j$  上的小波包分解为:

$$\{x_{j,n,k}\}, j \in [0, J], n \in [0, 2^j - 1], k \in [0, N/2^j - 1]$$

则其 AR 模型为:

$$x_{j,n,k} = -\sum_{i=1}^p a_{n,i} x_{j,n,k-i} + u_k \quad (4.11)$$

其中  $p$  是 AR 模型的阶数,  $u_n$  是当前的激励白噪声,  $a_{n,i}$  是各阶的系数。利用 AR 模型参数  $\{a_{n,i}, n \in [0, 2^j - 1], i = 1, 2, \dots, p\}$  来构成特征向量。

#### § 4.5.4 特征提取与分类

与 § 4.4.3 一样, 仍以 § 3.4.3 所述的莱蒙湖底不同沉积物的反射回波作为研究对象, 这五类湖底沉积物分别为沙砾石、岩石、卵石、沙、淤泥。每类有 2 组样本, 每组有 36 个样本, 选取其中的一组作为训练样本, 即总共有 180 个训练样本; 然后选取每类目标的另外一组作为测试样本, 即总共有 180 个测试样本。

具体的基于小波包分析的特征提取与识别过程的流程图与图 4.1 相似, 只是将小波多分辨分析这一步换为小波包分析。与多分辨分析相类似, 小波包分析对信号进行多层次分解, 在不同分辨率下描述信号的特征, 因此在信号的小波包分析过程中影响分解结果的有两个参数: 分解层数和小波函数。在接下来的部分, 我们就来确定分解层数和使用的小波基这两个因素对分类效果的影响, 同时分析不同湖底介质的分类以及特征维数的降低对识别结果的影响。

表 4-8 以小波包能量谱为特征, 分解层数  $J$  的影响

层数 $J$	4	5	6	7	8	9
$K$ 值	6	6	2	2	2	2
沙砾石	72.22%	66.67%	63.89%	72.22%	72.22%	75.00%
岩石	80.56%	83.33%	91.67%	83.33%	75.00%	77.78%
卵石	77.78%	83.33%	94.44%	100%	88.89%	83.33%
沙	94.44%	94.44%	100%	100%	94.44%	94.44%
淤泥	100%	100%	100%	100%	100%	97.22%
平均	85.00%	85.56%	90.00%	91.11%	86.11%	85.56%

##### 1) 分解层数的影响

为了确定分解层数  $J$  对特征提取和识别结果的影响, 对五类湖底回波信号进行 3~9 级小波包分解, 分别提取小波包能量谱特征、最佳子空间熵值特

征和小波包  $AR$  谱特征。采用的小波包函数是 4 阶 Daubechies 小波(db4); 熵标准采样  $shannon$  熵; 分类器采用  $K$  近邻分类器,  $K$  从 1 取到 50, 找到使得平均正确识别率最高的  $K$  值; 得到的识别结果由表 4-8~表 4-10 给出。

表 4-9 以最佳子空间熵值为特征, 分解层数  $J$  的影响

层数 $J$	3	4	5	6	7	8
$K$ 值	6	4	9	6	19	8
沙砾石	63.89%	63.89%	63.89%	63.89%	58.33%	55.56%
岩石	63.89%	63.89%	41.67%	52.78%	27.78%	44.44%
卵石	72.22%	72.22%	83.33%	72.22%	83.33%	88.89%
沙	61.11%	72.22%	61.11%	61.11%	72.22%	50.00%
淤泥	86.11%	83.33%	88.89%	88.89%	88.89%	88.89%
平均	69.44%	71.11%	67.78%	67.78%	66.11%	65.56%

表 4-10 以小波包  $AR$  谱为特征, 分解层数  $J$  的影响

层数 $J$	2	3	4	5	6	7
$K$ 值	5	4	9	7	5	8
沙砾石	72.22%	66.67%	36.11%	41.67%	61.11%	61.11%
岩石	80.56%	83.33%	75.00%	77.78%	66.67%	72.22%
卵石	94.44%	72.22%	83.33%	77.78%	77.78%	33.33%
沙	83.33%	72.22%	94.44%	72.22%	55.56%	77.78%
淤泥	66.67%	66.67%	83.33%	50.00%	25.00%	19.44%
平均	79.44%	72.22%	74.44%	63.89%	57.22%	52.78%

由表 4-8 可以推断, 分解层数不宜太小或太大, 太小则对信号频带划分过于粗略, 损失有益的特征; 太大则会由于对频带刻画过于精细而引入不必要的变异性, 影响分类效果。就所分析的湖底回波数据而言, 分解到第 6 或 7 层即可达到较好的分类效果, 平均识别率已经达到 90% 以上。在表 4-9 中, 分解层数为 4 时, 五类回波的平均识别率最高, 为 71.11%。在表 4-10 中,  $AR$  模型的阶数取为 3, 分解尺度较小时, 五类回波的识别结果还可以, 随着分解尺度的增大 (大于 4), 平均识别率逐渐降低。由表 4-8~表 4-10 可以看出, 提取不同的特征 (就前文提到的三种特征), 为了获得最佳的识别结果, 分解的层数并不是一样的。

## 2) 小波函数的影响

小波函数的选取, 对特征的提取和识别的结果有一定的影响。对五类回



波信号经小波包分解到 7 层, 小波函数选为 *haar*、*dbN* ( $N=1,2,\dots,12$ ), 提取小波包能量谱作为特征。提取最佳子空间熵值为特征时, 小波包分解到第 4 层, 小波函数也选为 *haar*、*dbN* ( $N=1,2,\dots,12$ )。




图 4-6 在不同小波函数下的识别结果

五类回波在每个小波函数下的平均正确识别率如图 4-6 所示, 分类器采用  $K$  近邻分类器,  $K$  从 1 取到 50, 图中的结果都是采用识别效果最好的  $K$  值。图(a)的结果是以小波包能量谱为特征, 从图中可以看出, 当小波函数为 *db4* 时的平均正确识别率最高, 为 91.11%; 当小波函数是 *db2* 时, 其相应的平均正确识别率最低, 为 79.44%。图(b)的结果是以最佳子空间熵值为特征, 从图中可以看出, 当小波函数为 *db9* 时的平均正确识别率最高, 为 77.78%; 当小波函数是 *haar* 小波或 *db1* 小波时, 其相应的平均正确识别率最低, 为 68.83%。

### 3) 不同湖底介质的分类

接下来讨论不同湖底介质的分类。以 § 3.4.3 所述的莱蒙湖底不同沉积物的反射回波作为研究对象, 分别采用 § 4.5.3 所述的三种特征提取方法来提取五类回波信号的特征, 并进行分类识别。其中, 分类器采用  $K$  近邻分类器,  $K$  从 1 到 50 取值, 采用平均正确识别率最高的  $K$  值。

#### i) 以小波包能量谱为特征

对五类回波进行 7 级 *db4* 小波包分解后, 提取第 7 级各子带的能量谱为特征, 计算得到 128 维的特征向量;  $K$  近邻分类器,  $K$  值从 1 取到 50, 选取识别效果最好的  $K$  为 2。识别结果如表 4-11 所示。由表可知, 对沙砾石和岩石的识别效果相对差些, 识别率分别为 72.22%、83.33%; 而对卵石、沙和淤泥这三类的识别率都是 100%, 识别效果非常理想。另外, 将提取的特征

用于对沙砾石和岩石进行两类识别时，识别率分别为100%和97.22%

表 4-11 以小波包能量谱为特征的五类回波识别结果

	测试 样本数	分为该类的数目					正确 识别率	平均 识别率
		沙砾石	岩石	卵石	沙	淤泥		
沙砾石	36	26	1	1	6	2	72.22%	91.11%
岩石	36	1	30	4	1	0	83.33%	
卵石	36	0	0	36	0	0	100%	
沙	36	0	0	0	36	0	100%	
淤泥	36	0	0	0	0	36	100%	

ii) 以最佳子空间熵值为特征

对五类回波进行 4 级 db9 小波包分解，计算形成 4 维特征向量。最佳子空间的选取过程中，具体的信息代价函数取为 shannon 熵。K 近邻分类器，K 值从 1 取到 50，选取识别效果最好的 K 为 5。识别结果如表 4-12 所示。

表 4-12 以最佳子空间熵值为特征的五类回波识别结果

	测试 样本数	分为该类的数目					正确 识别率	平均 识别率
		沙砾石	岩石	卵石	沙	淤泥		
沙砾石	36	24	1	1	6	4	66.67%	77.78%
岩石	36	3	26	4	3	0	72.22%	
卵石	36	0	4	32	0	0	88.89%	
沙	36	10	0	0	26	0	72.22%	
淤泥	36	3	0	0	1	32	88.89%	

表 4-13 以最佳子空间熵值为特征的三类回波识别结果

	测试 样本数	分为该类的数目			正确 识别率	平均 识别率
		$A_1$	$A_2$	淤泥		
$A_1$	36	33	0	3	91.67%	94.44%
$A_2$	36	1	35	0	97.22%	
淤泥	36	2	0	34	94.44%	

由表 4-12 可以看出，在五类识别中，该特征对沙砾石、岩石、沙的分类效果较差，而对卵石和淤泥的分类效果好些，达到了 88.89%；同时可以看出，沙砾石有 16.67% 的样本被错误地分成沙，沙也有 27.78% 的样本被错误地分成沙砾石，类似的，岩石和卵石之间的误分率都达到了 11.11%。

基于以上的结果,我们将沙砾石和沙归为一类(记为 $A_1$ ),岩石和卵石归为一类(记为 $A_2$ ),淤泥为一类,进行三类识别,结果如表 4-13 所示,其中 $K$ 近邻分类器的 $K$ 取为 5。由表可以看出,对三类回波的识别率都超过了 90%,平均的识别率是 94.44%。同时,对 $A_1$ 中的沙砾石和沙进行两类识别,识别率分别为 80.56%、72.22%;对 $A_2$ 中的岩石和卵石进行两类识别,识别率分别为 91.67%、88.89%。

表 4-14 岩石、卵石、沙、淤泥四类回波的识别结果

	测试 样本数	分为该类的数目				正确 识别率	平均 识别率
		岩石	卵石	沙	淤泥		
岩石	36	27	3	6	0	75.00%	88.19%
卵石	36	4	32	0	0	88.89%	
沙	36	0	0	34	2	94.44%	
淤泥	36	0	0	2	34	94.44%	

如果我们排除沙砾石,对岩石、卵石、沙和淤泥这四类回波进行识别,结果如表 4-14 所示,其中 $K$ 近邻分类器的 $K$ 取为 8。由表可知,对岩石、卵石、沙、淤泥的识别率分别为 75.00%、88.89%、94.44%、94.44%,平均识别率达到了 88.19%。

iii) 以小波包 AR 谱为特征

对五类回波进行 2 级 db4 小波包分解后,对第 2 级各子带建立 3 阶 AR 模型,利用模型参数构成 6 维特征向量;对于 $K$ 近邻分类器, $K$ 值从 1 取到 50,选取识别效果最好的 $K$ 为 5。识别结果如表 4-15 所示。

表 4-15 以小波包 AR 谱为特征的五类回波识别结果

	测试 样本数	分为该类的数目					正确 识别率	平均 识别率
		沙砾石	岩石	卵石	沙	淤泥		
沙砾石	36	26	1	2	6	1	72.22%	79.44%
岩石	36	1	29	3	1	2	80.56%	
卵石	36	2	0	34	0	0	94.44%	
沙	36	4	0	2	30	0	83.33%	
淤泥	36	0	5	5	2	24	66.67%	

由表可以看到,利用小波包 AR 谱为特征对沙砾石、岩石、卵石、沙、淤泥五类回波的识别率分别为 72.22%、80.56%、94.44%、83.33%、66.67%,

平均识别率为 79.44%。

#### 4) 特征维数的降低对识别结果的影响

为了说明特征维数的降低对识别结果的影响,我们对沙砾石、岩石、卵石、沙、淤泥五类回波进行 7 级 db4 小波包分解后,提取第 7 级各子带的能量谱为特征,计算得到 128 维的特征向量,利用 K-L 变换来降低特征维数;采用  $K$  近邻分类器,  $K$  值从 1 取到 50,选取识别效果最好的  $K$  值。图 4-7 画出了特征维数与五类回波平均识别率的关系曲线。




图 4-7 以小波包能量谱为特征,特征维数的降低对识别结果的影响

由图可以看出,当特征被压缩至 21 维以下时,平均识别率低于 80%;压缩为 22 维时,平均识别率达到 86.67%;维数为 116 时,平均识别率才超过 90%,是 90.56%;当维数是 117 时,其平均识别率超过了利用所有特征时的识别率达到了 91.67%;当维数是 120 时,其平均识别率达到了最高的识别效果,为 92.22%。

考虑到小波包分解层数对识别结果的影响,以最佳子空间熵值和小波包 AR 谱为特征时,提取的特征维数不高,因而不考虑特征维数的降低对识别结果的影响。

## § 4.6 基于小波和分形理论的特征提取

前文已经提到,小波变换的实质是对原始信号做滤波,具有所谓的“恒 Q”特性。因此,各尺度时间内的平滑信号和细节信号能提供原始信号的时

频域信息，特别是提供不同频域上信号的构成信息。若把不同分解尺度上信号的能量求解出来，则可以将这些能量值按尺度排列形成特征向量供识别用。这就是基于小波变换提取多尺度空间能量的基本原理<sup>[60]</sup>。

对于经同一发射信号激发的水下目标回波，所包含的能量频谱分布与目标的大小、形状和类型密切相关。因此，小波分解后尺度空间上的能量分布是目标的本质特征，可用于识别。文献[28]中利用小波变换对空气动力性噪声坦克和直升机声信号就进行了特征提取。

回波信号已经被证明在一定程度上具有混沌特性<sup>[12]</sup>。分形理论是描述混沌信号的一种有效手段，定量刻画分形特征的参数是分形维。关联维是一种最常用的分形维。文献[6]就利用关联维检测混沌噪声背景中的信号。有关关联维  $D_2$  的定义和算法在第三章作了说明，不同的回波其关联维  $D_2$  有一定的差异。

基于以上的说明，在对实际采集的湖底回波进行特征提取和分类识别时，我们利用回波的不同尺度下的小波子空间的能量特征  $\{en_j, j=1,2,\dots,J+1\}$  和分形维  $D_2$  构成特征向量，为了充分利用关联维特征，我们引入一个加权因子  $\lambda$ ，这样构造出特征向量  $\{\lambda \times D_2, (1-\lambda) \times en_j, j=1,2,\dots,J+1\}$ 。

所采用的数据仍以 § 3.4.3 所述的莱蒙湖底不同沉积物的四类反射回波作

表 4-16 多尺度空间能量为特征时，四类回波的识别结果

	测试 样本数	分为该类的数目				正确 识别率	平均 识别率
		岩石	卵石	沙	淤泥		
岩石	36	31	5	0	0	86.11%	91.67%
卵石	36	1	31	4	0	86.11%	
沙	36	0	0	36	0	100%	
淤泥	36	0	0	2	34	94.44%	

表 4-17 多尺度空间能量加关联维特征，四类回波的识别结果

	测试 样本数	分为该类的数目				正确 识别率	平均 识别率
		岩石	卵石	沙	淤泥		
岩石	36	32	4	0	0	88.89%	95.14%
卵石	36	0	34	2	0	94.44%	
沙	36	0	0	36	0	100%	
淤泥	36	0	0	1	35	97.22%	

为研究对象,这四类湖底沉积物分别为岩石、卵石、沙、淤泥。每类有2组样本,每组有36个样本,选取其中的一组作为训练样本,即总共有144个训练样本;然后选取每类目标的另外一组作为测试样本,即总共有144个测试样本。

我们比较了基于小波变换提取的多尺度空间能量特征、基于小波和分形理论方法提取的特征,小波函数都采用 $db4$ 小波,都分解到第6层,都采用 $K$ 近邻分类器, $K$ 都取为6。基于小波变换提取的多尺度空间能量特征,得到的特征向量是7维,平均识别率是91.67%,其具体识别结果如表4-16所示。基于小波和分形理论方法提取的特征,包括小波子空间的能量和关联维 $D_2$ ,得到的特征向量是8维,加权因子 $\lambda$ 取为0.4,平均识别率达到了95.14%,其具体的识别结果如表4-17所示。从表4-16和表4-17可以看出,考虑关联维特征后,平均识别率从91.67%提高到了95.14%,识别效果得到了较大的改善。

## § 4.7 本章小结

本章介绍了基于小波多分辨分析和小波包分析的小波域特征提取方法,以及将提取的特征对莱蒙湖底反射回波进行识别的情况;分析了分解层数、小波函数对识别结果的影响,详细讨论了不同湖底回波的识别,同时研究了通过K-L变换降低特征维数及其对识别结果的影响。

在本章里,提出了两种新的特征提取方法,一种是小波包AR谱的特征向量构造方法,针对这种特征提取方法详细分析了分解层数、小波函数等对水下回波信号识别结果的影响。最后,提出了基于小波和分形理论的特征提取方法,并对反射回波进行了特征提取和分类识别,得到了较高的分类准确率(平均为95.14%),比多尺度空间能量特征的识别率提高了3.47%,仿真结果表明该方法是有用的。

## 第五章 小波多分辨分形特征研究

### § 5.1 引言

由于水下环境和水声信号的非平稳性,如何从水声信号中提取稳定而又有效的特征一直是目标识别研究的热点,也是难点。目前,对水下回波信号进行处理和分析的方法很多,不同的分析方法可以获得不同的特征参数。如通过对时域信号的过零点分布、峰间幅值分布、波长差分布等方面的特性分析,可以得到波形结构多维特征向量<sup>[54][122]</sup>;信号谱估计的特征提取方法<sup>[53][123]</sup>,如经典谱估计方法、现代谱估计方法和高阶谱估计方法;时间-频率分析特征提取,如 Wigner-Ville 分布、加窗傅立叶变换等等。但是,由于水下回波信号的复杂性,目前也需要寻找一些新的特征分析方法,从水下回波中提取更多有效的特征表示。

近年来随着非线性科学的迅猛发展,非线性分析手段日渐成熟,利用非线性的方法来分析水下回波信号成为水下目标特征提取的一个新的、可行的手段。分形理论(Fractal Theory)是非线性科学中的一个极为活跃的重要分支,在水声信号处理领域已经得到了一定的应用<sup>[14]</sup>。在 70 年代提出的分形理论是非线性学科中的一个前沿课题,80 年代以来,已经渗透到图像处理、模式识别等领域,且随着各个领域的应用研究而不断完善和发展。分形直接从非线性复杂系统本身入手,从未经简化和抽象的研究对象去认识其内在的规律,这一点与传统的线性近似理论方法有本质的区别<sup>[1][3][122]</sup>,这已经引起人们足够的研究兴趣,有很多人对分形理论进行研究。

小波分析(Wavelet Analysis)是调和分析几十年来工作的结晶,被誉为“数学显微镜”,是傅立叶分析发展史上里程碑式的进展,是信号处理领域的一个优秀的分析工具。它克服了基于 FFT 的谱估计固定时频窗的不足;信号的多尺度分解不仅可在“放大”了的时频尺度上观察信号的时频特性,还可看到时频特性在不同尺度上的演变规律。它在图像压缩、信号检测、生物医学信号分析等一系列科技领域中得到了许多应用,理论分析和应用领域都得到了发展和拓展<sup>[84][87][124]</sup>。

利用小波分析方法来进行分形研究也作过一些尝试<sup>[125]</sup>,基于小波的分形分析方法已经在文献[74][126][127]中提出来过,刘代志等利用分形的观点对核爆信号和地震信号进行小波分析,并进行了核爆地震模式识别试验,取得了较好的识别效果<sup>[128]</sup>。根据这些工作,本章尝试用分形理论和小波变换相结合的方法来提取水下回波信号的新特征—小波多分辨分形特征。首先,介绍了这一特征提取方法的基本思路和原理,接着并通过计算机仿真对 5 类湖底回波信号进行了特征提取和分类识别,仿真结果表明了提取的特征参数是合

适的、可行的,从而为水下回波的分类识别提供了新的特征提取方法和新的特征参数。

## § 5.2 基本思路与方法原理

分形是一种具有分数维的集合。分形维数  $D$  是刻画分形集合的主要特征量,不管这个集合是离散的还是连续的。分形分析的关键是用不同的维数对分形集合进行测量,以便求出相应的分形维数  $D$ 。水下回波信号已经被证明具有混沌特性,可以求出其分形维特征,如前文提到的关联维特征。通过对水下回波信号的分析处理来进行模式识别,是想通过这种波形分析来提取某些特征参数,用来构制模式识别判据,以达到对不同水下回波信号进行自动识别的目的。

分形研究中的两大问题:(1) 研究对象是否具有分形特征?(2) 在一定的分辨率下,其分形维数  $D$  是多少?同时,在分形分析中,关键是找到无标度区间,以便估算相应的分形维数。因此,分形的无标度区间是一个重要的特征,然而要找出无标度区间,必须进行信号的尺度分解。本章提出的结合小波变换和分形理论的方法,就是循着下面的思路,来对水下回波信号进行分形分析:(1) 利用小波变换对水下回波信号进行不同尺度的分解,用分解后不同尺度上的小波系数求得不同尺度的信号能量,进而探讨信号能量与分解尺度的关系,求取相应的特征参量;(2) 利用这些特征参量作为水下回波模式识别的特征参数,构制相应的判据,进行识别检验,最后选定合适的特种参数。

### § 5.2.1 分形维的定义

为了便于理解多分辨分形特征的概念,我们先介绍分形维的定义(在第二章作过一些介绍)。根据不同的需要,可以定义多种分形维,相应地也有不同的计算和测量分形维的方法。数学家们已经发展出了十多种不同的维数,如拓扑维、Hausdorff 维、盒子维、关联维等等。虽然分形维的定义有很多种,但是基本上都是基于“变尺度  $\delta$ —覆盖”的思想,每次测量均忽略尺度小于  $\delta$  时集合的不规则性,都是考察当  $\delta \rightarrow 0$  时测量值变化的状况。我们引入常用的关联维的定义。

$C(r, m)$  表示相关积分,其定义为

$$C(r, m) = \frac{1}{[N(m)]^2} \sum_{i,j=1}^{N(m)} H(r - d_{ij}^{(m)}) \quad (5.1)$$



公式(5.1)中  $m$  表示嵌入维,  $N(m)$  表示当嵌入维为  $m$  时所有重构向量的个数,  $r$  表示尺度,  $H(\bullet)$  表示 Heaviside 函数, 其定义为

$$H(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases} \quad (5.2)$$

公式(5.1)中  $d_y^{(m)}$  的定义为

$$d_y^{(m)} = \|v_i^{(m)} - v_j^{(m)}\| \quad (5.3)$$

式中  $v_i^{(m)}$  表示重构向量;  $\|\bullet\|$  表示范数。

如果在  $r$  的某个区间(无标度区间)上, 相关积分  $C(r, m)$  与尺度  $r$  之间存在着幂指数关系:

$$C(r, m) \sim r^D \quad (5.4)$$

对上式两边取对数后, 用最小二乘法拟合一直线, 其斜率即为关联维  $D$ 。则关联维  $D$  可以通过下式求得:

$$D = \lim_{r \rightarrow 0} \frac{\log C(r, m)}{\log r} \quad (5.5)$$

必须提及一下, 在许许多多实际应用中, 并不存在严格的规则来确定某个量是否能合理地被当成一个分形维。我们有如此多的定义, 很多时候并不能说出已经求出的分形维到底与哪个理论上的定义相一致, 这时候决定一个维数可否被接受将更多地由经验和直觉所确定。但是仍有几点是肯定的, 为确定一个量能否作为分形维, 我们应当寻找它的某种类型的比例性质; 它要有着易于理解的自然表达; 同时也要满足分形维的性质<sup>[1]</sup>。

### § 5.2.2 小波多分辨能量分形特征

我们知道, 利用小波变换对一个信号作多分辨分析, 实际上是将这个信号分解成不同尺度上的逼近信号和不同分辨率上(尺度)的细节信号, 它相当于对信号分别作低通滤波和高通滤波。当然, 完全可以用滤波器组来进行同样的信号分解。但是, 小波变换中的尺度因子不仅影响滤波器的带宽, 而且影响滤波器的中心频率, 所以, 利用小波变换进行信号分解有着独特的效果。以二进小波分解为例, 尺度因子是  $a = 2^j$ ,  $j$  表示尺度下标。当分解尺度  $j = 1$  时, 尺度较小, 时间窗很窄, 时间分辨率高, 能反映出原始信号的细

节；随着尺度  $j$  的增大，频率窗变得越来越宽，频率分辨率也随之逐渐增高，能反映信号中的低频成份。信号每分解一次，每次剥去原始信号中的一部分高频成份，剥去的信息构成细节成份，即所谓的细节信号。毫无疑问，不同尺度上的逼近信号和细节信号与尺度有密切的关系。正是基于这样的认识，我们把不同尺度 ( $j = 1, 2, \dots$ ) 上的逼近信号和细节信号的能量当成分解尺度的函数，同时参考上一节分形中有关分形维的定义，进而求得相应的特征量——一种广义的分形维。具体的计算过程如下：

设  $x[n]$  ( $n = 1, 2, \dots, N$ ) 是水下回波经采样后的离散信号， $A_0 = \{x[n]\}$ ；由小波多分辨率分析可知，在分解尺度  $j = 1, 2, \dots, m$  下的逼近信号与细节信号可由  $A_0 = \{A_{0,n}\}$  递推求得，令求得的  $j$  级分辨逼近系数为  $A_j = \{A_{j,k}\}$ ，细节信号的系数  $D_j = \{D_{j,k}\}$ ， $A_{j,k}$  与  $D_{j,k}$  可由以下递推公式求得：

$$A_{jk} = \sum_{n=1}^N h_{n-2k} A_{j-1,n} \quad (5.6)$$

$$D_{jk} = \sum_{n=1}^N g_{n-2k} A_{j-1,n} \quad (5.7)$$

式中  $h_n$  和  $g_n$  分别是低通滤波器和高通滤波器的序列值。信号的多分辨率分解可由图 5-1 表示。




图 5-1 信号多分辨率分解框图

设  $E_A(j)$  和  $E_D(j)$  分别表示在分解尺度  $j$  下的逼近系数  $\{A_{j,k}\}$  和细节信号的系数  $\{D_{j,k}\}$  的能量函数，则

$$E_A(j) = \sum_k A_{j,k}^2 \quad (5.8)$$

$$E_D(j) = \sum_k D_{j,k}^2 \quad (5.9)$$

令  $j=1,2,\dots,J$ ,  $J$  为最大分解尺度, 这样可以求得  $J$  个尺度上的  $E_A$ 、 $E_D$ 。如果在某一尺度区间(即无标度区间)上  $E_A(j)$ ,  $E_D(j)$  与尺度  $j$  有以下幂指数关系:

$$E_A(j) \sim a_j^{D_A}, \quad E_D(j) \sim a_j^{D_D} \quad (5.10)$$

其中尺度因子  $a_j = 2^j$ , 则可以通过双对数坐标上的直线拟合求出  $D_A$  和  $D_D$ 。

由(5.10)式与(5.4)式相比较可以看出,  $D_A$  和  $D_D$  这两个参量与分形维的定义类似, 故我们可以称之为能量分形的分形维数。

通过  $E_A(j) \sim a_j^{D_A}$  拟合可以求出  $D_A$ , 如图 5-2(a)所示; 在拟合  $E_D(j) \sim a_j^{D_D}$  的过程中,  $E_D(j)$  出现一个峰值(如图 5-2(b)所示), 我们采用两条直线来拟合峰值两边的数据, 求得两个  $D_D$ , 分别记为  $D_{D1}$  和  $D_{D2}$ 。  $D_A$ ,  $D_{D1}$  和  $D_{D2}$  实际上是一种广义分形维。同时发现, 所有被处理的样本的细节信号能量均存在这种现象, 且峰值出现的尺度位置  $a^*$  也可作为一种类似于  $D_A$ 、 $D_D$  的特征量用于模式识别。当然, 这个尺度位置不一定是整数, 而是利用  $E_D$  在各个尺度上的值经拟合求极值的方法求得的。




图 5-2 某个回波的能量分形特征

这样, 通过对水下回波信号的处理与分析, 提取了两类特征量: (1) 能量分形特征量  $D_A$ 、 $D_D$ 、 $D_{D1}$  和  $D_{D2}$ ; (2) 细节信号能量的极值点对应的尺度

位置  $a^*$ 。




## § 5.3 计算结果与讨论

### § 5.3.1 特征的提取

以 § 3.4.3 所述的莱蒙湖底不同沉积物的反射回波作为研究对象, 这五类湖底沉积物分别为沙砾石、岩石、卵石、沙、淤泥。发射信号为一宽带矩形包络线性调频脉冲信号, 脉冲宽度为  $1ms$ , 调频宽度  $20KHZ \sim 140KHZ$ , 采样频率为  $1MHZ$ 。每类有 2 组样本, 每组有 36 个样本, 每个样本的数据长度取为 2000, 选取其中的一组作为训练样本, 即总共有 180 个训练样本; 然后选取每类目标的另外一组作为测试样本, 即总共有 180 个测试样本。

图 5-2 描述了某个水下回波信号的典型能量分形特征。图 5-2(a)显示了逼近信号能量的对数  $\log E_A(j)$  与对数尺度  $\log 2^j$  的关系, 在区间  $j \in [3, 8]$  范围内拟合该曲线, 可以得到  $D_A$  的值。图 5-2(b)显示了细节信号能量的对数  $\log E_D(j)$  与对数尺度  $\log 2^j$  的关系, 在区间  $j \in [2, 7]$  范围内拟合该曲线, 可以得到  $D_D$  的值。在图 5-2(b)中, 容易发现对应于尺度  $j=3$  有一个峰值, 因此在峰值的两侧, 分别对尺度区间  $j \in [1, 3]$  与  $j \in [3, 7]$  进行曲线拟合, 获得两个特征量  $D_{D1}$ 、 $D_{D2}$ 。而且, 在尺度区间  $j \in [1, 8]$  进行二次曲线拟合, 可以获得能量峰值所对应的尺度位置  $a^*$ 。

图 5-2 的曲线实际上可以看作是能量谱。逼近信号的能量  $E_A(j)$  随尺度  $a_j$  的增加而减少, 这一点是不难理解的, 因为随着尺度  $a_j$  的增加, 从原始信号中剥去的信号成分 (构成细节信号) 越来越多, 相应地, 留下来的信号 (构成逼近信号) 的能量就越来越少。而细节信号的能量谱随尺度  $a_j$  变化出现一个峰值, 似乎可以这样解释: 不同频率的信号能量是不一样的, 水下回波信号振幅谱都存在所谓的峰值频率  $f^*$  和谱的陡度。在离散小波变换中, 二进小波函数实际上是一个恒  $Q$  滤波器, 随着尺度  $j$  的增加, 其中心频率和带宽都以 2 倍减小, 这样功率谱的峰值频率  $f^*$  就会出现在某个尺度下的小波函数的



通频带里, 这说明了峰值频率  $f^*$  对应于细节信号具有最大能量的尺度位置  $a^*$ 。因而可以这么说, 不同尺度的细节信号的能量是不一样的, 出现这一峰值是自然的, 峰值位置所对应的尺度  $a^*$  与峰值频率  $f^*$  相当,  $D_{D1}$ 、 $D_{D2}$  则反映出该峰值两边能量谱的陡度以及能量谱曲线的对称性。因此, 把  $a^*$ 、 $D_{D1}$ 、 $D_{D2}$  作为特征量来进行水下回波的识别是合适的。图 5-3~图 5-5 画出了两类回波信号的特征量  $D_A$ 、 $D_D$  和  $a^*$  的直方图, 其中图 5-3(a)、5-4(a)、5-5(a)描述的是沙砾石回波信号的特征量, 图 5-3(b)、5-4(b)、5-5(b)描述的是岩石回波信号的特征量。

### § 5.3.2 特征加权

本文引入文献[129]介绍的在纹理分类中的一种特征加权方法。对于某一类水下回波信号, 所提取的特征通常是随机变量, 相对于其均值有一定的离散性。这种特征的离散性可以作为该特征描述相应回波信号的精确性的一种度量。某个特征的离散程度越小, 它对相应回波信号的描述就越精确, 反之则相反。如果我们将这种特征对回波信号描述的精确性与它在分类中所起的作用联系起来, 即加强回波信号描述精确度大的特征在分类中的作用, 而减弱描述精确度小的特征的作用, 那么分类性能将会得到改善。由于随机变量的离散性可以由方差描述, 因此, 这种作用的改变可以通过对特征根据其方差进行加权来实现。

现在假设训练样本集中某一类回波的样本数为  $N$ , 特征矢量为  $X_i = [x_{i,1}, x_{i,2}, \dots, x_{i,D}]^T$ ,  $i = 1, 2, \dots, N$ , 特征集方差矢量  $s^2 = [s_1^2, s_2^2, \dots, s_D^2]^T$ , 其中  $D$  为特征维数, 则

$$s_d^2 = \frac{1}{N-1} \sum_{i=1}^N \left( x_{i,d} - \bar{x}_d \right)^2, \quad d = 1, 2, \dots, D \quad (5.11)$$

式中  $\bar{x}_d$  为特征  $x_{i,d}$ ,  $i = 1, 2, \dots, N$  的均值;

$$\bar{x}_d = \frac{1}{N} \sum_{i=1}^N x_{i,d} \quad (5.12)$$

用式 (5.11) 对特征  $x_{i,d}$  进行加权, 得到加权后的特征  $x_{i,d}^w$

$$x_{i,d}^w = \frac{x_{i,d}}{s_d}, \quad i = 1, 2, \dots, N \quad (5.13)$$

进一步, 可得到加权后的特征矢量  $X_i^w$ 。

由 (5.13) 式可以看出, 特征加权使特征矢量中离散程度 ( $s_d^2$ ) 较小的特征相对增大, 而离散程度 ( $s_d^2$ ) 较大的特征相对减小, 也就是说, 离散程度较小的特征在分类中的作用加强了, 而离散程度较大的特征在分类中的作用减弱了。

实际上, (5.13) 式的运算就是将每一类回波信号的各个特征  $x_{i,d}$  的方差归一化了。

### § 5.3.3 分类识别与分析

按照前文的方法, 我们可以提取出如下特征量:  $D_A$ 、 $D_D$ 、 $a^*$ 、 $D_{D1}$  和  $D_{D2}$ , 但如何判断这些特征量的辨别力呢? 我们使用单一特征量进行分类识别, 根据识别率的高低来判断某个特征量的辨别力。在识别前, 我们对特征量按前一节的方法进行特征加权, 分类器使用  $K$  近邻分类器,  $K \in [1, 50]$ 。表 5-1 是使用单一特征量对水下回波的识别结果。

表 5-1 使用单一特征的识别结果

	沙砾石	岩石	卵石	沙	平均识别率
$D_A$	77.78%	94.44%	61.11%	91.67%	81.25%
$D_D$	63.89%	88.89%	83.33%	97.22%	83.33%
$a^*$	72.22%	86.11%	100%	100%	89.58%
$D_{D1}$	19.44%	47.22%	88.89%	69.44%	56.25%
$D_{D2}$	69.44%	77.78%	52.78%	25.00%	56.25%

由表 5-1 可见, 特征量  $D_A$ 、 $D_D$  和  $a^*$  提供了更多的判别信息, 对四类回波的平均识别率都超过 80%, 因而优于特征量  $D_{D1}$ 、 $D_{D2}$ 。其中, 特征量  $a^*$  的识别效果最好, 平均识别率达到了 89.58%;  $D_A$ 、 $D_D$  具有几乎一样的识别效果。

接下来, 讨论一下不同特征组合的辨别力, 先进行特征加权, 然后使用  $K$  近邻分类器进行分类识别,  $K \in [1, 50]$ , 如表 5-2 所示。

表 5-2 使用组合特征的识别结果

	沙砾石	岩石	卵石	沙	平均识别率
$D_A, D_D$	75.00%	94.44%	86.11%	100%	88.89%
$D_A, a^*$	100%	100%	100%	100%	100%
$D_D, a^*$	94.44%	88.89%	100%	100%	95.83%
$D_A, D_D, a^*$	100%	100%	100%	100%	100%

由表 5-2 可以看出,  $D_A$  与  $a^*$  的组合识别效果最好, 使得四类回波的识别率都达到了 100%;  $D_A$  与  $D_D$  的组合识别效果最差, 平均识别率也达到了 88.89%。

从信号能量的角度看, 上述的能量分形特征  $D_A$ 、 $D_D$ 、 $D_{D1}$  和  $D_{D2}$ , 与分形维数 (如关联维), 有相似之处, 因而我们称之为广义分形维。而小波分解尺度与频率类似, 所以它们之间可能存在某种关系, 具体是何种关系尚需进一步的研究。

上述的能量分形特征  $D_A$ 、 $D_D$ 、 $D_{D1}$  和  $D_{D2}$  以及特征量  $a^*$  揭示了信号能量随频率或尺度的变化, 因此它们之间可能存在着某些内在的联系。因为逼近信号在较低尺度能更好地刻画一个信号的特征, 特征量  $D_A$  可以用来评价较低尺度下的能量, 而细节信号在较高尺度能更好地刻画信号的特征, 特征量  $D_D$  可以用来评价较高尺度下的能量。由于特征量  $a^*$  是细节信号能量最大值对应的尺度位置, 所以  $a^*$  揭示了尺度信息, 而且这些尺度包含了峰值频率附近功率谱的陡度信息。简而言之, 特征量  $a^*$  有两部分信息组成: 一是峰值频率, 二是陡度; 所以  $a^*$  的辨别力最高。



## § 5.4 本章小结

本章尝试将分形理论和小波变换相结合,应用分形的思想,来提取水下回波信号的新特征—小波多分辨能量分形特征(广义分形维特征),并介绍了这一特征提取方法的基本思路和方法原理,这是一个新的研究领域。通过该方法提取出来的小波多分辨能量分形特征分别有:  $D_A$ 、 $D_D$ 、 $D_{D1}$ 、 $D_{D2}$  以及  $a^*$ , 并将它们作为水下回波模式识别的特征参量。我们先使用单一特征量进行分类识别,根据识别率的高低来判断某个特征量的辨别力,由表 5-1 可见,特征量  $D_A$ 、 $D_D$  和  $a^*$  的平均识别率都超过了 80%, 提供了比  $D_{D1}$  和  $D_{D2}$  (平均识别率都是 56.25%) 更多的判别信息; 接下来, 文中讨论了不同特征组合的辨别力, 由表 5-2 可以看出,  $D_A$  与  $a^*$  (或加  $D_D$ ) 的组合识别效果最好 (达到了 100%), 而  $D_A$  与  $D_D$  的组合识别效果相对较差。从这些仿真结果可以得到, 将  $D_A$ 、 $D_D$  和  $a^*$  作为特征参量是合适的, 从而为水下回波的识别提供了新的特征提取方法和新的特征参数。

## 第六章 小波神经网络研究

### § 6.1 引言

从 1943 年 McCulloch 和 Pitts 首次提出 MP (McCullough-Pitts) 神经元模型, 到上个世纪 80 年代中期 Rumelhart 等人 PDP (Parallel Distributed Processing) 的出版, 世界范围内兴起了神经网络的研究热潮。前向多层神经网络是一种最为广泛应用的神经网络模型, 用于训练前馈网络最常用的学习方法是 BP 算法, 实践证明 BP 神经网络具有强大的空间映射能力。小波自 1984 年 Grossmann 和 Morlet 首次提出以来, 已经成为信号处理的强有力工具, 小波分析被认为是傅立叶分析的突破性进展。由于小波具有良好的时频局部特性和变焦特性, 而神经网络具有自学习、自适应性、强鲁棒性和推广能力的特点, 如何把小波和神经网络结合起来, 一直是人们关注的问题。

目前小波与神经网络的结合表现有以下两个途径: 一个途径是辅助式结合, 比较典型的是先利用小波变换对分析信号进行预处理, 提取信号的小波特征, 再将特征量输入神经网络处理, 数据经过小波变换的压缩, 能有效地减少神经网络的输入层单元数, 如图像处理<sup>[130]</sup>、数据分类<sup>[131]</sup>、心电信号的检测<sup>[132]</sup>。小波与前馈网络结合是小波与神经网络结合的主要形式, 除此之外, 小波还可以与其它神经网络相结合, 例如用 Kohonen 网络实现对信号的自适应小波分解<sup>[133]</sup>, RBF 网络与小波的结合<sup>[134]</sup>等等。另一种途径是嵌套式结合, 即把小波变换的运算融入到神经网络中去, 形成所谓的小波神经网络<sup>[63]</sup>。这是两者结合的主要方式, 其中小波与前馈神经网络的结合又是最主要的研究方向<sup>[71]</sup>。

传统的前向多层神经网络是基函数神经网络, 一般采用 sigmoid 函数作为基函数。小波函数的伸缩和平移构成了  $L^2(R)$  空间上的标准正交基, 而小波神经网络就是用非线性小波基来代替通常的 sigmoid 函数作为神经网络的神经元函数, 生成了一个与径向基函数网络在结构上相似的网络。因此, 小波神经网络可看作是以小波函数为基底的一种函数连接型网络, 也可认为是 RBF 网络的推广, 但它又具有一般前馈网络和 RBF 网络所不同的特点, 在神经网络研究领域中具有巨大的潜力<sup>[135]</sup>。

关于小波神经网络的研究最早可以追溯到 1992 年。Zhang Qinghua<sup>[63]</sup>在 1992 年提出小波神经网络的概念, 他利用了一种由小波伸缩和平移得到的小波元函数作为神经元函数, 构造出了第一个被称为小波神经网络的前馈神经网络, 并给出了用于网络训练的算法—随机梯度算法。随后, 小波神经网络得到了进一步的发展。1993 年, Bakshi<sup>[136]</sup>提出了用正交小波函数作为神经

元的激励函数,提出了正交小波神经网络及其学习算法,其基本思想是依据多分辨分析理论,用小波分解对样本进行分析,网络一部分隐结点取为尺度函数,另一部分隐结点取为小波函数,采用逐级学习的方法来训练网络。Bakshi 将小波函数和尺度函数共同应用于小波网络之中,充分利用了二者互补的特性,给出了网络的全局误差和局部误差的指标,并应用于混沌时间序列的预报。Zhang Jun<sup>[138]</sup>等人研究了前人的小波网络模型,提出了另一种正交小波神经网络,其基本思想是选用正交且具有类紧支特性的 Lemarie-Meyer 尺度函数对函数进行逼近。焦李成教授在其 1995 年出版的著作《神经网络的应用与实现》中,从理论上对小波神经网络进行了较为详细的论述<sup>[137]</sup>。

相比于传统的前向网络,由于小波神经网络具有逼近能力更强、网络学习收敛速度更快、网络结构更简单等特点,自从小波神经网络的概念和模型提出以后,就引起了人们的广泛研究兴趣,并对其模型和算法进行了改进。何振亚等人<sup>[69]</sup>结合时延神经网络和小波分析概念,提出了自适应时延小波神经网络,对同一类存在不同时延的多个信号用同一个超小波进行逼近,并给出了一种基于时间竞争的学习算法。何强等人<sup>[70]</sup>针对模板和样本信号周期不同时网络参数差异较大的问题,对网络结构进行了修正,提出了自适应周期小波神经网络。丁宇新等<sup>[139]</sup>针对小波网络神经元个数过多、网络学习收敛速度较慢的问题,在时频分析基础上引入了能量密度的概念,提出了基于能量函数的小波神经网络。张钺<sup>[140][141]</sup>针对小波网络高维映射学习所用神经元数目过多和维数灾难,提出了区间小波神经网络。焦李成等人研究了小波网络与模糊逻辑的结合,用隶属函数表示权重值,构造模糊权值、模糊输出的小波网络<sup>[142]</sup>。虽然紧支正交小波神经网络具有比自适应小波神经网络更快的学习速率和更高的稳定性,但由于至今未构造出具有解析形式的紧支集正交小波函数(除连续性较差的 Haar 小波外),其网络模型难以在实际中得到应用。蔡文生等据此在紧支集正交小波神经网络模型的基础上,用具有紧支集的 B-样条函数的伸缩和平移替代小波函数,提出了一种新型算法,并将其应用于化学信号的处理,实现了信号的压缩和滤噪<sup>[143]</sup>。

本章回顾了小波神经网络的概念及进展,接下来将介绍小波神经网络的原理及其学习算法,以及讨论如何确定小波神经网络的结构及其参数,并将其用于水下回波的特征提取。

## § 6.2 小波神经网络的基本原理

### § 6.2.1 数据压缩表达网络

小波变换的实质是一种不同参数空间之间的积分变换<sup>[85]</sup>。在一维信号  $f(t)$  情况下, 小波基  $h_{a,b}(t)$  可以按照下述方式产生

$$h_{a,b}(t) = \frac{1}{\sqrt{|a|}} h\left(\frac{t-b}{a}\right) \quad (6.1)$$

其中  $h(t)$  为母小波,  $|a|^{-1/2}$  为归一化系数,  $a$ 、 $b$  分别为  $h_{a,b}(t)$  的伸缩因子和平移因子, 对于信号  $f(t)$ , 其局部结构的分辨可以通过调节参数  $a$ 、 $b$ , 即调节小波基窗口的大小和位置来实现。

母小波需要满足下述条件

$$\int |h(t)|^2 dt < \infty \quad (6.2)$$

即小波仅具有有限的能量

$$\int \frac{|\hat{h}(w)|^2}{|w|} dw < \infty \quad (6.3)$$

其中  $\hat{h}(w)$  表示  $h(t)$  的傅立叶变换, 该式称为允许条件, 以确保小波的局域波行为。

小波网络是基于小波分析而构造的神经网络模型, 即用非线性小波基取代了通常的非线性 Sigmoid 函数, 其信号的表述是通过将所取代的小波基进行线性叠加来实现的。按文献[144]所示方法, 信号的自适应小波特征是通过对信号进行适应性小波表示实现的。其原理如下: 任意信号  $s(t)$  可用母小波  $h(t)$  及其子小波的加权求和近似表示, 即

$$\hat{s}(t) = \sum_{k=1}^K w_k h\left(\frac{t-b_k}{a_k}\right) \quad (6.4)$$

式(6.4)中,  $\hat{s}(t)$  为拟合信号,  $w_k$ 、 $b_k$ 、 $a_k$  分别是每一个小波的权系数、平移因子和伸缩因子,  $K$  为小波基的个数。信号的这一近似表示可以用图 6-1 所示神经网络的结构来表示, 该网络为单层结构, 仅含有一个输入和一个输出结点。

网络参数  $w_k$ 、 $b_k$  和  $a_k$  可以通过对最小均方误差能量函数  $E$  进行优化而求得

$$E = \frac{1}{2} \sum_{t=1}^T [s(t) - \hat{s}(t)]^2 \quad (6.5)$$

其中,  $T$  为信号采样点总数。




图 6-1 压缩表达小波神经网络

在一定的误差范围内, 总可以选择一组数量最少的小波基, 利用(6.4)式得到原始信号  $s(t)$  的拟合形式  $\hat{s}(t)$ 。通常, 这一组小波基的数量要比原始信号的数据量小 1~2 个数量级。因此, 集合  $V = \{w_1, b_1, a_1, \dots, w_K, b_K, a_K\}$  可以作为原始信号  $s(t)$  的压缩形式, 这就是小波神经网络对一维信号的压缩。为了获得集合  $V$ , 可以构造合适的小波神经网络, 将  $w_k$ 、 $b_k$ 、 $a_k$  作为网络的参数, 利用合适的学习算法进行反复训练, 从而获得能够体现信号特征的这些网络参数。

### § 6.2.2 数据分类网络

改变小波网络的结构可以对输入信号进行综合分类。输入层、隐层、输出层的结点数分别为  $T$ 、 $K$ 、 $N$ 。隐层的权值取为小波基函数, 输出层传递函数是 *Sigmoid* 函数, 即

$$\sigma(u) = \frac{1}{1 + e^{-u}} \quad (6.6)$$

设输入训练样本总数为  $P$ , 则对第  $p$  个样本, 第  $n$  个结点的输出可以用下式

表示:

$$O_n^p = \sigma(u_n) = \sigma \left[ \sum_{k=1}^K w_{nk} \sum_{i=1}^T s^p(i) h \left( \frac{i - b_k}{a_k} \right) \right] \quad (6.7)$$

图 6-2 给出了上式的分类小波网络结构示意图。

网络参数  $w_k$ 、 $b_k$ 、 $a_k$  可以通过下述能量函数  $E$  进行优化:

$$E = \frac{1}{2} \sum_{p=1}^P \sum_{n=1}^N (d_n^p - O_n^p)^2 \quad (6.8)$$

其中  $d_n^p$  是第  $p$  个样本, 第  $n$  个结点的理想分类输出。

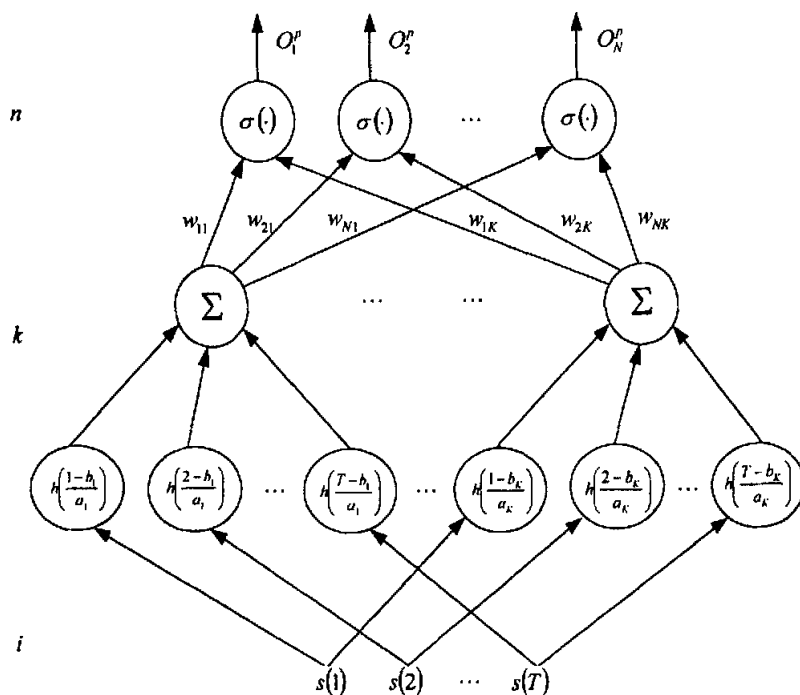


图 6-2 分类小波神经网络

### § 6.3 小波神经网络的学习算法

训练前馈神经网络最常用的学习方法是反向传播算法 (即 BP 算法), 但

BP 算法存在着众所周知的计算量大、学习收敛速度慢、局部最小的问题。Zhang Qinghua 首次提出小波神经网络模型时使用了随机梯度算法, Szu 则提出了学习速度更快的共轭梯度算法<sup>[144]</sup>。本文将采用共轭梯度算法来训练小波神经网络。

由于学习算法中要用到小波函数的一阶导数, 这就涉及到构造小波网络时选择什么类型的小波函数。根据不同的情况选择相同或不同的小波基函数是一个值得研究的问题, 目前这方面定性的研究不多。在实践中, Morlet 小波  $\cos(rt)e^{-t^2/2}$  应用领域甚广, 例如信号表示和分类<sup>[144]</sup>、特征提取<sup>[145]</sup>。在本文中, 采用下述 Morlet 小波, 取  $r = 1.75$ , 其波形如图 6-3 所示, 该小波是余弦调制的高斯波, 时频域同时分辨率高

$$h(t) = \cos(1.75t)e^{-t^2/2} \quad (6.9)$$




图 6-3 Morlet 小波( $r = 1.75$ )

下面分别针对数据压缩表达网络和分类网络分别求解网络算法:

### § 6.3.1 数据压缩表达网络

若令  $t' = \frac{t - b_k}{a_k}$ , 则式(6.5)中  $E$  的梯度分别为

$$g(w_k) = \frac{\partial E}{\partial w_k} = - \sum_{t=1}^T [s(t) - \hat{s}(t)] \cos(1.75t') e^{-t'^2/2} \quad (6.10)$$

$$g(b_k) = \frac{\partial E}{\partial b_k} = - \sum_{t=1}^T [s(t) - \hat{s}(t)] w_k \left[ 1.75 \sin(1.75t') e^{-t'^2/2} + \cos(1.75t') e^{-t'^2/2} t' \right] / a_k \quad (6.11)$$

$$\begin{aligned} g(a_k) &= \frac{\partial E}{\partial a_k} = - \sum_{t=1}^T [s(t) - \hat{s}(t)] w_k \left[ 1.75 \sin(1.75t') e^{-t'^2/2} t' + \cos(1.75t') e^{-t'^2/2} t'^2 \right] / a_k \\ &= t' g(b_k) \end{aligned} \quad (6.12)$$

采用共轭梯度法来优化网络  $w_k$ 、 $b_k$ 、 $a_k$ ，分别令  $\bar{w} = (w_1, w_2, \dots, w_K)$ ，

$\bar{g}(\bar{w}) = (g(w_1), g(w_2), \dots, g(w_K))$ ， $\bar{s}(\bar{w})^i$  为  $\bar{w}$  第  $i$  次循环搜索方向，则

$$\bar{s}(\bar{w})^i = \begin{cases} -\bar{g}(\bar{w})^i & i = 1 \\ -\bar{g}(\bar{w})^i + \frac{\bar{g}(\bar{w})^i [\bar{g}(\bar{w})^i]^T}{\bar{g}(\bar{w})^{i-1} [\bar{g}(\bar{w})^{i-1}]^T} \bar{s}(\bar{w})^{i-1} & i \neq 1 \end{cases} \quad (6.13)$$

其中， $T$  表示转置。

权重向量  $\bar{w}$  按下式进行调节

$$\bar{w}'^{i+1} = \bar{w}'^i + \alpha'_w \bar{s}(\bar{w})^i \quad (6.14)$$

同理可以定义  $\bar{s}(\bar{b})^i$ 、 $\bar{s}(\bar{a})^i$ ，并按类似公式调节  $\bar{b}$ 、 $\bar{a}$ 。

本文采用一维搜索变步长法，计算最佳步长  $\alpha'_w$ 、 $\alpha'_b$ 、 $\alpha'_a$ 。每次循环时，

按上式分别调节网络参数向量  $\bar{w}$ 、 $\bar{b}$  和  $\bar{a}$ ，直到  $E$  小于某一设定误差或循环结束为止。为了合理以及方便表示，网络每次循环后的输出误差  $E'$  用下式表达

$$E' = \frac{\sum_{t=1}^T [s(t) - \hat{s}(t)]^2}{\sum_{t=1}^T [s(t)]^2} \quad (6.15)$$



### § 6.3.2 数据分类网络

若令  $t' = \frac{t - b_k}{a_k}$ ,  $\sigma'(u) = \frac{\partial \sigma(u)}{\partial u} = \sigma(u)[1 - \sigma(u)]$ , 则

$$u_n = \sum_{k=1}^K w_{nk} \sum_{i=1}^T s^p(i) h\left(\frac{i - b_k}{a_k}\right) \quad (6.16)$$

$$g(w_{nk}) = \frac{\partial E}{\partial w_{nk}} = - \sum_{p=1}^P \sum_{n=1}^N \sum_{i=1}^T (d_n^p - O_n^p) \sigma'(u_n) s^p(i) \cos(1.75t') e^{-t'^2/2} \quad (6.17)$$

$$g(b_k) = \frac{\partial E}{\partial b_k} = - \sum_{p=1}^P \sum_{n=1}^N \sum_{i=1}^T (d_n^p - O_n^p) \sigma'(u_n) s^p(i) w_{nk} \cdot [1.75 \sin(1.75t') + \cos(1.75t') t'] e^{-t'^2/2} / a_k \quad (6.18)$$

$$g(a_k) = \frac{\partial E}{\partial a_k} = - \sum_{p=1}^P \sum_{n=1}^N \sum_{i=1}^T (d_n^p - O_n^p) \sigma'(u_n) s^p(i) w_{nk} \cdot [1.75 \sin(1.75t') t' + \cos(1.75t') t'^2] e^{-t'^2/2} / a_k = t' g(b_k) \quad (6.19)$$

可用上一节所述的共轭梯度法优化网络参数  $w_{nk}$ 、 $b_k$ 、 $a_k$ , 直到  $E$  小于某一设定误差。

### § 6.4 小波神经网络的参数确定

无论是人工神经网络还是小波神经网络, 在实际应用中, 都不可避免的要遇到参数的初始化问题。一个好的初始化参数不仅能够减小迭代次数, 加快运算速度, 还可以避免网络陷入局部极小值; 另外, 随着小波参数的增多, 小波神经网络对初始化的参数比较敏感, 这在本文的实验过程中就可以得到验证。因此在实际应用中, 人们对小波神经网络的参数初始化问题进行了大量的研究, 取得了不少成果<sup>[146]~[162]</sup>。其中, 最常见的初始化参数方法是将在权值设为零值或随机数, 伸缩、平移参数随机选取, 这样的参数初始化方法带有很大的随机性。王群仙<sup>[161]</sup>采用加权最小二乘法来学习网络权值, 利用 Davidon 最小二乘法学习伸缩参数和平移参数。Zhang Qinghua<sup>[67]</sup>提出了另一种参数初始化方法, 即用回归方法确定小波神经网络的初始值。

本文在小波分析理论的基础上采用小波逼近方法作为一种参数初始化方法, 它不同于最小二乘法和回归法, 它有可靠的理论依据, 并且可作为粗估

计方法。

在  $D \in [t_1, t_2]$ , 重写式(6.4)

$$\hat{s}(t) = \sum_{k=1}^K w_k h\left(\frac{t-b_k}{a_k}\right) \quad (6.20)$$

以  $\hat{s}(t)$  来拟合信号  $s(t)$ , 初始化参数  $w_k$ 、 $b_k$ 、 $a_k$ ,  $k=1, 2, \dots, K$ 。对于权值  $w_k$ ,

令其初值为 0, 以下讨论如何初始化  $b_k$  与  $a_k$ 。

为了初始化  $b_1$  与  $a_1$ , 在  $[t_1, t_2]$  中取一点  $p$ ,  $t_1 < p < t_2$ , (分割点  $p$  的选取方法稍后会详细说明)。令

$$b_1 = p, \quad a_1 = \lambda(t_2 - t_1) \quad (6.21)$$

其中  $\lambda > 0$  是预先选择的一个恒定值(有代表性可取  $\lambda = 0.5$ ), 这样区间  $[t_1, t_2]$  被  $p$  点分为两个子区间, 在每个子区间重复上面的步骤, 可以初始化  $(b_2, a_2)$ ,  $(b_3, a_3)$ , …, 直到所有的小波元被初始化。这样的步骤一直持续下去, 直

到所有的参数被初始化。

分割点  $p$  可按这样的方法选取, 引入如下形式的“密度”函数

$$\rho(t) = \frac{\theta(t)}{\int_1^2 \theta(t) dt} \quad (6.22)$$

其中  $\theta(t) = \left| \frac{ds(t)}{dt} \right|$ ,  $\rho(t)$  应由输入、输出观测量  $\{t, s(t)\}$  进行估计。我们称分割点  $p$  为区间  $[t_1, t_2]$  的重心,

$$p = \int_1^2 t \rho(t) dt \quad (6.23)$$

## § 6.5 实验结果

### § 6.5.1 数据压缩网络

我们首先对一个模型信号  $f$  (波形如图 6-4(a)所示) 用数据压缩小波神经网络进行压缩, 输入是时间量, 输出是  $f$ , 由于实际信号采样的时间间隔都是固定的, 因此为了计算和分析的方便, 我们可以把输入作为自然数序列  $\{1, 2, \dots, N\}$  ( $N$  为数据个数) 来处理, 这样做只是改变了时间轴上量值的表示, 并不影响数据分析和表述, 需要时通过采样率直接就可转化为实际时间。

采用 7 个小波基进行训练,  $w_k$ 、 $b_k$ 、 $a_k$  的初始值按上一节的方法进行选择, 训练结束后利用式(6.4)恢复出其波形  $\hat{f}$  (如图 6-4(b)所示), 恢复出的数据误差  $E'$  为 0.00019。将训练好的网络参数按  $b_k$  从小到大的顺序排列, 如表 6-1 所示, 可以看出恢复出的波形  $\hat{f}$  与原始信号波形  $f$  拟合得很好, 保持了原始信号的特征。

表 6-1 训练后的网络参数

$w_k$	0.934	-0.168	0.215	-0.148	0.831	1.181	0.191
$b_k$	6.370	11.831	18.288	24.666	34.848	39.767	45.598
$a_k$	4.483	0.083	9.639	-0.052	-8.281	4.118	3.929




图 6-4 原始信号(a)、逼近信号(b)

将表中的数据 and 原始数据波形进行比较, 发现  $b_k$  的值对应于波形中波峰

与波谷所对应的横坐标。在理论上,小波压缩网络实际是通过小波基的迭代来拟合波形信号的,因此在网络训练时不断调节平移因子 $b_k$ ,使小波基位置与波峰、波谷位置重合,达到误差能量的极小。利用这一特点,可以在网络初始化时将 $b_k$ 初始化为这些波峰和波谷所对应的横坐标值,使其初始值一开始就比较接近结果值以减少迭代次数。具体做法是在进行小波压缩训练前对待压缩的数据进行预处理,标注其中波峰和波谷的横坐标值作为初始的 $b_k$ 的值。按照这种方法训练网络,仿真过程中可以发现网络收敛速度快于§6.4所用的方法,可以避免 $w_k$ 、 $b_k$ 、 $a_k$ 都取为随机数的参数初始化方法出现的网络不收敛或收敛于局部极小。




图 6-5 (a)某沙砾石回波信号的频域波形 (b)其逼近信号的波形

根据前文的方法,对莱蒙湖底回波信号进行了压缩研究,首先对回波信号进行如下预处理:1)为了减少数据量,对原始记录数据进行4倍降采样,原始记录有2000个数据点,经4倍降采样后变成500个数据点的信号;2)

对降采样后的信号作 FFT 变换。然后对回波信号的频域波形利用式(6.4)进行逼近。

我们采用 23 个小波基进行训练,  $w_k$  的初始值设为 0、 $a_k$  的初始值设为 (0,20) 的随机数,  $b_k$  的初始值设为信号波形波峰与波谷对应的横坐标值, 训练结束后输出误差  $E'$  为 0.2117。图 6-5 给出了某个沙砾石回波信号的频域波形图 (图 6-5 (a)) 及其逼近信号的波形图 (图 6-5 (b))。可以看出, 逼近信号能够很好地保持原有信号的特征, 特别是能够较为准确地反映信号频域波形峰的位置和强度。小波基个数的选取是一个十分重要的问题, 个数太多, 虽然能使收敛速度加快, 但所需参数要增加, 压缩比要降低; 相反, 个数太少, 压缩比可以增大, 但使收敛速度变慢甚至不收敛。经过实验, 我们选择了 23 组是比较合适的, 这样回波信号就可以用 23 组  $w_k$ 、 $b_k$  和  $a_k$  共 69 个参数表示出来, 从而实现了信号的压缩表征, 效果是令人满意的。

### § 6.5.2 数据分类网络

以 § 3.4.3 所述的莱蒙湖底不同沉积物的反射回波作为研究对象, 这五类湖底沉积物分别为沙砾石、岩石、乱石、沙、淤泥。发射信号为一宽带矩形包络线性调频脉冲信号, 脉冲宽度为 1ms, 调频宽度 20KHZ ~ 140KHZ, 采样频率为 1MHZ。每类有 2 组样本, 每组有 36 个样本, 每个样本的数据长度取为 2000, 对其进行 4 倍降采样处理, 选取其中的一组作为训练样本, 即总共有 180 个训练样本; 然后选取每类目标的另外一组作为测试样本, 即总共有 180 个测试样本。

表 6-2 五类回波识别结果

	测试 样本数	分为该类的数目					正确 识别率	平均 识别率
		沙砾石	岩石	卵石	沙	淤泥		
沙砾石	36	25	1	3	5	2	69.44%	71.67%
岩石	36	1	27	5	2	1	75.00%	
卵石	36	5	0	29	1	1	80.56%	
沙	36	6	1	3	25	1	69.44%	
淤泥	36	1	4	6	2	23	63.89%	

利用数据分类小波神经网络对这五类湖底回波信号进行了分类, 其中输

入是回波信号；隐层节点数为 23；输出层有 5 个节点，当第  $i$  个节点为 1，其余为 0 时表示输入信号被分成第  $i$  类。分类结果如表 6-2 所示。

由表 6-2 可以看出，平均识别率为 71.67%，其中网络对卵石回波的识别率最高，达到了 80.56%；而对淤泥回波的识别率最低，只有 63.89%。

由于在神经网络的模型中引入了小波变换使得对信号特征的提取更有效。在数据分类网络的第一层中实际是引入了一个线性算子，而这一层的权值是一系列的小波函数。在基本小波函数确定的情况下，权值的大小是由小波的尺度和平移因子决定的。所以在小波网络中的学习参数实际是小波的尺度和平移因子及后级网络的权值。第一层相当于是求取信号的小波级数。不同于一般的求取小波级数后取某一阶小波级数的方法，在这个模型中，不是人为地取定某一阶的小波级数，而是学习的方法自适应地确定某些小波级数。从滤波器的角度来看这个问题，如果说人为取定小波级数的过程是人为给出一个确定的滤波器的过程，那么这个模型的方法是通过网络的自学习确定一组自适应的滤波器的过程。从时间—频率分析的角度说，人为地确定某一阶小波级数的方法实际是在时间—频率相平面的某一给定的频带上取定了该频带上的所有窗口，这些窗口的大小和形状均相同；而这个模型的方法，可以在整个相平面上的各个频带上自动的选取不同大小的时频窗。正因为这种自适应的能力，使得小波网络对信号的特征提取更有效。

接下来我们分析小波网络的推广能力。所谓的推广能力，可以简单理解为系统识别训练集合以外样本的能力，又称之为泛化能力。类比于自动控制中的鲁棒性，即系统能够较好地容忍小的扰动，在神经网络中，我们可以这样理解推广能力：在网络正确分类所有训练样本的前提下，推广能力可以认为是系统容忍输入微小变化的能力。从数学上讲，输出随输入变化而改变的程度越小，即导数越小，则推广能力越高。对于式(6-7)的网络输出方程，可写出以下的偏导数公式：

$$\frac{\partial O_n}{\partial s_i} = \frac{\partial O_n}{\partial u_n} \left( \sum_{k=1}^K w_{nk} h \left( \frac{i-b_k}{a_k} \right) \right) = O_n (1-O_n) \left( \sum_{k=1}^K w_{nk} h \left( \frac{i-b_k}{a_k} \right) \right) \quad (6.24)$$

从上式可以看出小波函数的作用：当  $i$  远离  $b$  时，窗函数的值会迅速衰减。由于特征提取是在各个时频窗内进行的，因此窗外的信息被作为无用信息或干扰信息而被抑制。可以发现，上式的小波函数将保证网络对真正的特征保持敏感，并将其作为分类的依据，同时忽略干扰性信息的不良影响，从而为提高网络的推广能力提供了可能性。

但是利用数据分类小波神经网络对回波信号进行处理时，由于该网络仅把时域信号在一组固定的伸缩因子  $a$  和平移因子  $b$  的小波基上进行内积运算（如式(6-7)可以看出），也就是说每改变一次伸缩因子  $a$ ，只有一个平移因子

$b$  对应, 没有更精细地进行运算, 因而其分类能力不是很好。

正如一般的采用梯度下降算法学习的小波网络一样, 在这个模型中, 由于在神经网络中引入了小波算子, 使得采用如式(6-8)的能量函数振荡得更剧烈。

为了更直观地表现这个问题, 我们设计一个最简单的网络。该网络由一个输入节点、一个隐层节点和一个输出节点组成。网络的输出可以由式(6-7)简化而来:

$$O = \sigma \left( w_1 \times h \left( \frac{i - b_1}{a_1} \right) s \right) \quad (6.25)$$

这个简单网络的能量公式如下:

$$E = (d - O)^2 \quad (6.26)$$

为了便于显示能量函数在权值空间上的情况, 我们不妨只看  $i = 0$ 、只有一个输入的情况。不妨令公式(6.25)中的  $s = 1$ ,  $\frac{b_1}{a_1} = -w_2$ , 则公式(6.25)变为:

$$O = \sigma(w_1 \times h(w_2)) \quad (6.27)$$

为了便于显示, 在能量公式(6.26)中不妨令  $d = 0$ 。为了比较, 我们画出了小波网络和 BP 网络的能量函数, 图 6-6 显示了小波网络在全局最小附近的能量函数, 图 6-7 显示了 BP 网络在全局最小附近的能量函数。




图 6-6 小波网络的能量函数




图 6-7 BP 网络的能量函数

从图中可以清楚地看到由于小波算子的引入，小波网络的能量函数振荡得更剧烈，这使得小波网络的学习过程对初始值很敏感，常造成收敛速度缓慢，并且极易落入局部最小。

这些因素使得小波网络对五类水下回波的分类识别结果不是很理想。

## § 6.6 本章小结

本章回顾了小波神经网络的概念及进展，重点介绍了数据压缩网络与数据分类网络这两种类型小波神经网络的原理及其学习算法，以及讨论如何确定小波神经网络初始化参数的方法，将其用于水下回波的特征提取，并对识别结果进行了分析。

1) 在小波网络中，一个好的初始化参数不仅能够减小迭代次数，加快运算速度，还可以避免网络陷入局部极小值，文中对参数的初始化方法进行了改进，标注原始信号波峰和波谷的横坐标值作为初始的  $b_k$  的值，按照这种方法训练网络，发现网络收敛速度加快，可以避免网络出现不收敛或收敛于局部极小。

2) 由于小波算子的引入，使得小波网络对信号的特征提取能力更有效以及提高了小波网络的推广能力，但是由于小波算子的引入和采用梯度下降学



习算法，小波网络的能量函数振荡得很剧烈，这使得小波网络的学习过程对初始值很敏感，常造成收敛速度缓慢，并且极易落入局部最小，这些因素使得小波网络对五类水下回波的分类识别结果不是很理想。本章的研究说明了小波神经网络在水下回波信号的特征提取和分类识别上有一定的应用价值，但识别效果不是很理想。

3) 需要指出的是，网络参数的初始值和小波基的数目对网络训练有很大的影响。

4) 采用不同的母小波、误差能量函数和优化网络的算法，有可能会减小训练误差，以及加快网络收敛速度。

## 第七章 结论与展望

### § 7.1 引言

水下目标的识别技术不仅在民用上具有一定的经济价值,而且在国防建设上也具有重要的军事价值。它是现代水下电子对抗的基础,也是水下电子对抗中的一个重要的环节,在世界各国都倍受重视。因此,世界各发达国家在这一领域都投入了大量的人力物力进行研究,并取得了一定的成果。尽管混沌与分形理论、小波分析理论等新方法在目标识别领域的文章日益增多,但基本上都属于起步阶段,而应用于实际的水下目标识别还需要长期并深入的研究工作;况且,我国在这方面起步晚,而在国外这属于“敏感技术”,我们很难获得其关键技术。所以,本论文所进行的水下目标识别的相关技术研究便是以此为背景所进行的该课题的初步研究工作,也是一项富有探索性、也有着实际意义的工作。

### § 7.2 本文的主要研究内容与结论

本论文对混沌与分形信号处理技术以及小波分析理论在水声信号的特征提取、分类识别中的应用进行了较深入地研究。本论文的主要研究内容和得出的基本结论可以归纳如下:

- (1) 对混沌理论进行了系统的阐述,对混沌理论的形成历史和发展概况作出了全面的总结,而在对混沌特性进行定量分析时着重探讨了吸引子的分形维数和 Lyapunov 指数的定义与计算。
- (2) 对混沌信号处理的基本方法——状态空间重构技术作了详细地分析,并对涉及的参数进行了选择与确定;讨论了主元分析方法(PCA)在抑制噪声方面的分析原理和实现算法,利用 Lorenz 模型作为研究对象进行了仿真,不同信噪比(SNR)下的仿真结果说明了 PCA 方法从能量的角度出发,在一定程度上抑制了噪声、突出了混沌性态。利用 PCA 方法对实测回波数据进行了分析,估算并提取五类回波的混沌特征参数。
- (3) 提出了基于状态空间重构与 K-L 变换相结合的特征提取方法,对文献[12]中的方法进行了改进,提取了相对稳定有效的特征,仿真结果表明该方法具有较好的分类识别效果。
- (4) 利用小波理论对小波域的特征提取方法进行了研究。①分析了基于多分辨分析的特征提取,以各子带的能量构成信号的特征向量,讨论了多分辨分析的分解层数与使用的小波函数这两个因素对分类效

果的影响,分析了五类回波信号的分类以及特征维数的降低对识别结果的影响;②小波包分析是在多分辨分析基础上对其没有分解的高频部分进一步分解,有更高的频率分辨率,所以接下来研究了基于小波包分析的特征提取,介绍了几种从小波包中构造特征向量的方法:以小波包能量谱为特征、以最佳子空间熵值为特征、以小波包  $AR$  谱为特征,讨论了小波包分析的分解层数与使用的小波函数这两个因素对五类回波的识别结果的影响,用以上三种方法提取的特征对五类回波信号进行了分类识别,说明了特征维数的降低对识别结果的影响。

- (5) 提出了基于小波和分形理论的特征提取方法,比较了基于小波变换提取的多尺度空间能量特征、基于小波和分形理论方法提取的特征,仿真结果表明,考虑关联维特征后,平均识别率从 91.67% 提高到了 95.14%, 识别效果得到了较大的改善。
- (6) 探讨了小波多分辨分析与分形理论相结合,应用分形的思想,提取水下回波信号的广义分形维特征——小波多分辨分形特征,并对五类回波信号进行了特征提取和分类识别,仿真的结果说明了提取的特征参数是合适的、可行的,从而为水下回波的特征分类识别提供了新的特征提取方法和新的特征参数。
- (7) 介绍了小波神经网络的概念,分析了小波神经网络的原理及其算法,讨论了如何确定小波神经网络的初始化参数,并将其用于水下回波信号的特征提取。

### § 7.3 本文的主要贡献

本论文的主要贡献有以下几点:

- (1) 详细讨论了主元分析方法(PCA)在抑制噪声方面的分析原理和实现算法,通过 Lorenz 混沌模型的分析验证了 PCA 在抑制噪声、保持混沌特征的有效性,将 PCA 方法应用于水下回波信号的混沌特征参数的提取。
- (2) 提出了基于状态空间重构与  $K-L$  变换相结合的特征提取方法,对文献[12]中的方法进行了改进,提取了相对稳定有效的特征,仿真结果表明该方法具有较好的分类识别效果。
- (3) 基于多分辨分析的特征提取中,详细分析了分解层数、小波函数以及特征维数的降低对水下回波信号的识别结果的影响。
- (4) 基于小波包分析的特征提取中,提出了三种特征向量的构造方法:以小波包能量谱为特征、以最佳子空间熵值为特征、以小波包  $AR$  谱

为特征;详细分析了分解层数、小波函数以及特征维数的降低对水下回波信号的识别结果的影响。

- (5) 提出了基于小波和分形理论的特征提取方法,仿真结果表明该方法是有有效的。
- (6) 探讨了小波多分辨分析与分形理论相结合,应用分形的思想,提取水下回波信号的广义分形维特征——小波多分辨分形特征,为水下回波的特征分类识别提供了新的特征提取方法和新的特征参数。
- (7) 将小波神经网络应用于水下回波信号的特征提取与分类识别,并提出了小波神经网络的参数初始化的改进方法。

## § 7.4 进一步的工作

本论文的研究工作表明,混沌与分形信号处理技术、小波分析理论在水声信号的特征提取与分类识别具有一定的应用前景。但是在以下几个方面还有待进一步探讨的必要:

- (1) 对作为混沌特征参数的吸引子维数(比如文中的关联维数)展开更深入的研究,寻找快速有效的算法。因为在该参数的估计中,需要确定线性段的范围,因此准确的标定线性段将成为关联维的精确估计创造更加稳定的前提条件。
- (2) 探讨了小波多分辨分析与分形理论相结合,应用分形的思想,文中提取了水下回波信号的新特征参数——小波多分辨分形特征,但是对其理论基础需作进一步的分析。
- (3) 对小波神经网络的参数初始化需作进一步的研究。研究过程中发现小波网络对小波系数初值选取比较敏感,而小波参数初始化目前还缺少严格的理论指导。
- (4) 参考小波分析与神经网络相结合的小波神经网络、混沌理论与神经网络相结合的混沌神经网络<sup>[163]~[165]</sup>,可以考虑小波神经网络与分形理论的结合,尝试构造分形小波网络。

## 参考文献

1. 王东生, 曹磊. 混沌、分形及其应用. 合肥: 中国科学技术大学出版社, 1995
2. 谢和平, 薛秀谦. 分形应用中的数学基础和方法. 北京: 科学出版社, 1998
3. 敖力布, 林鸿溢. 分形学导论. 内蒙古: 内蒙古人民出版社, 1996
4. Henry D I, Abarbanel. Chaos in ocean ambient noise. J.Acoust.Soc.Am., 1996, 99(3): 1527-1539
5. Theodore W, Frison, Henry D I, Abarbanel et al. Nonlinear analysis of environment distortions wave signals in the ocean. Pro. of the IEEE, J. Acoust. Soc. Am., 1996, 99(1): 139-146
6. Haykin S. Detection of signals in chaos. Pro. of the IEEE, 1995, 83(1): 94-122
7. 章新华, 张晓明, 林良骥. 船舶辐射噪声的混沌现象研究. 声学学报, 1998, 23(2): 134-140
8. Wright J, Schult R L. Recognition and classification of nonlinear chaotic signals. CHAOS, 1993, 3(3): 295-304
9. Lo T, Leung H, Litva J et al. Fractal characterisation of sea-scattered signals and detection of sea-surface targets. IEE Proceedings-F, 1993, 140(4): 243-250
10. 高翔, 陆信人, 陈向东. 舰船辐射噪声的分形布朗运动模型. 声学学报, 1999, 24(1): 19-28
11. 陈向东, 宋爱国, 高翔等. 基于相空间重构理论的舰船辐射噪声非线性特性研究. 声学学报, 1999, 24(1): 12-18
12. 杨凤. 混沌与分形信号处理方法及目标识别技术研究. 西安: 西北工业大学博士学位论文. 1999
13. Yang S, Li Z S, Wang X L. Vessel radiated noise recognition with fractal features. Electronics Letters, 2000, 36(10): 1-2
14. 陈捷. 基于分形与混沌理论的水下目标特征提取研究. 西安: 西北工业大学博士学位论文. 2000
15. 陈捷, 陈克安, 孙进才. 基于多重分形的舰船噪声特征提取. 西北工业大学学报, 2000, 18(2): 241-244
16. Tan T, Yan H. Face recognition by fractal transformations. ICASSP'1999, vol.6: 3537-3540
17. Tao Y, Lam WCM, Tang YY. Extraction of fractal feature for pattern recognition. 15<sup>th</sup> ICPP'2000, vol.2: 527-530
18. Tang YY, Tao Y. Feature extraction by fractal dimensions. ICDAR'1999,

- 217-220
19. Tao Y, Lam CEM, Tang YY. Feature extraction using wavelet and fractal. *Pattern Recognition Letters*, 2001, 22:271-287
  20. Tang YY, Tao Y, Lam ECM. The application of fractal analysis to feature extraction. *ICIP'1999*, vol.2: 875-879
  21. Lang AZR, Soemintapura K, Kinsner W. Multifractal processing of speech signals. *ICICS'1997*, 527-531
  22. Karanikas C. The Hausdorff dimension of very weak self-similar fractals described by the Haar wavelet system. *Chaos, Solitons and Fractals*, 2000, 11: 275-280
  23. Asgari S, Nguyen TQ, Sethares WA. Wavelet-based fractal transforms for image coding with no search. *ICIP'1997*, vol.2: 302-305
  24. 刘代志, 邹红星, 韦荫康等. 分形分析与核爆地震模式识别. *模式识别与人工智能*, 1997, 10(2): 153-158
  25. 鲜明, 庄钊文, 肖顺平等. 雷达目标回波信号的混沌、多重分形分析与识别. *国防科技大学学报*, 1998, 20(2): 60-64
  26. 鲜明, 庄钊文, 肖顺平等. 基于混沌、多重分形理论的雷达信号分析和目标识别. *电子科学学刊*, 1998, 20(4): 433-439
  27. 苏菲, 谢维信, 董进. 分形几何在雷达杂波分析中的应用. *信号处理*, 1998, 14(1): 82-85
  28. 丁庆海, 庄志洪, 祝龙石等. 混沌、分形和小波理论在被动声信号特征提取中的应用. *声学学报*, 1999, 24(2): 197-203
  29. 李后强、汪富泉. 分形理论及其在分子科学中的应用. 北京: 科学出版社, 1997
  30. 殷志云、梅炽. 混沌理论与分形理论在热工过程中的应用. *常德师范学院学报*, 2000, 13(2): 57-61
  31. 赵松年, 熊小芸. 子波变换与子波分析. 北京: 电子工业出版社, 1997
  32. 程正兴, 武铁敦. 小波的发展与应用. *微机发展*, 1994, 5: 8-10
  33. 李慧芬, 蒋向前, 李柱. 小波理论的发展及其在表面功能评定中的应用. *现代计量测试*, 2001, 5: 5-8
  34. 费佩燕, 刘曙光. 小波分析应用的进展与展望. *纺织高校基础科学学报*, 2001, 14(1): 72-78
  35. Mallat SG. A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Trans. on Pattern Analysis and Machine Intelligence*, 1989, 11(7): 674-693
  36. Wickerhauser MV. *Lectures on wavelet packet algorithms*. 1991

37. Davis GM. A wavelet-based analysis of fractal image compression. IEEE Trans. on Image Processing, 1998, 7(2): 141-154
38. Antoine JP, Barache D, Cesar RM et al. Multiscale shape analysis using the continuous wavelet transform. ICIP'1996, 1(1): 291-294
39. Lee CS, Choi CH, Choi JY et al. Feature extraction algorithm based on adaptive wavelet packet for surface defect classification. ICIP'1996, 2(1): 673-676
40. Taweel S, Darwish AM. Texture segmentation using Shanon wavelet. ICIP' 1998, 3: 343-347
41. Shusterman E, Feder M. Analysis and synthesis of 1/f processes via Shannon wavelets. IEEE Trans. on Signal Processing, 1998, 46(6): 1698-1702
42. Mallat S, Zhong S. Characterization of signals from multiscale edges. IEEE Trans. on PAMI, 1992, 14(7): 710-732
43. Luo JS, Sha JC, Huang JH et al. Fast algorithm of wavelet decomposition and reconstruction for the fractal signals. ICSP'1998, vol.1: 300-304
44. Lopez JE, Tenney RR, Deckert JC. Fault detection and identification using real-time wavelet feature extraction. Proceedings of the IEEE-SP International Symposium on Time-Frequency and Time-Scale Analysis, 1994: 217-220
45. Chen WR, Qian QQ, Wang XR. Wavelet neural network based transient fault signal detection and identification. ICICS'1997, vol.3: 1377-1381
46. Cheung A, Chui CK, Chan AK. Spline wavelet packets and fast integral wavelet transform for the analysis of pressure and flow waves in arteries. ISSIPN'1994
47. Liang H, Nartimo I. A feature extraction algorithm based on wavelet packet decomposition for heart sound signals. Proceedings of the IEEE-SP International Symposium on Time-Frequency and Time-Scale Analysis, 1998: 93-96
48. Dokur Z, Olmez T, Yazgan E. ECG waveform classification using the neural network and wavelet transform. Proceedings of the First Joint BMES/EMBS Conference, 1999, vol.1: 273
49. 王晓菊. 被动声纳目标分类识别技术研究. 西安: 西北工业大学博士学位论文, 1999
50. 樊养余. 舰船噪声的高阶统计量特征提取及其应用. 西安: 西北工业大学博士学位论文, 1999
51. 周越. 非高斯信号的多尺度分析与特征提取研究. 西安: 西北工业大学博士学位论文, 2000

52. 赵建平. 水下目标信号的特征提取和瞬时参量估计的小波变换技术研究. 西安: 西北工业大学博士学位论文, 1998
53. S.M. 凯依著, 黄建国 等译. 现代谱估计—原理与应用. 北京: 科学出版社, 1994
54. 卢迎春, 桑恩方. 基于主动声纳的水下目标特征提取技术综述. 哈尔滨工程大学学报, 1997, 18(6): 43-54
55. 张学林. 基于小波变换的舰船辐射噪声特征提取. 西安: 西北工业大学博士学位论文, 2000
56. 章新华, 王骥程, 林良骥. 基于小波变换的舰船辐射噪声特征提取. 声学学报, 1997, 22(3): 139-144
57. 吴国清, 任锐, 陈耀明等. 舰船辐射噪声的子波分析. 声学学报, 1996, 21(4 增刊): 700-708
58. Chen CH, Lee JD, Lin MC. Classification of underwater signals using wavelet transforms and neural networks. Mathl. Comput. Modelling, 1998, 27(2): 47-60
59. 赵建平, 黄建国, 谢一清等. 用小波变换进行水下回波边缘特征提取与分类识别. 声学学报, 1998, 23(1): 31-38
60. 张静远, 张冰, 蒋兴舟. 基于小波变换的特征提取方法分析. 信号处理, 2000, 16(2): 156-162
61. 马艳. 基于小波变换的畸变信道检测和目标特征提取研究. 西安: 西北工业大学博士学位论文, 2002
62. Azimi-Sadjadi MR, Yao D, Huang Q et al. Underwater target classification using wavelet packets and neural networks. IEEE Trans. on Neural Network, 2000, 11(3): 784-794
63. Zhang QH, Benveniste A. Wavelet networks. IEEE Trans. on Neural Network, 1992, 3(6): 889-898
64. Telfer BA, Szu HH, Dobeck GJ. Adaptive wavelet classification of acoustic backscatter and imagery. Optical Engineering, 1994, 33(7): 2192-2203
65. Tollig CJG, Hoffman AJ. Wavelet neural network for classification of transient signals. COMSIG'1997. Proceeding of the 1997 South African Symposium on Communications and Signal Processing, 1997: 161-166
66. Zhang J, Walter GG, Miao YB et al. Wavelet neural networks for function learning. IEEE Trans. on Signal Processing, 1995, 43(6): 1485-1496
67. Zhang QH. Using wavelet network in nonparametric estimation. IEEE Trans. on Neural Network, 1997, 8(2): 227-236
68. 张永胜, 郁可, 吴锡琪. 基于小波神经网络的光谱数据表征与分类研究. 数



- 据采集与处理, 1998, 13(4): 393-396
69. 何振亚, 李文化, 蔚承建. 用于信号逼近的自适应时延小波神经网络. 电子科学学刊, 1998, 20(5): 604-610
70. 何强, 黄生, 毛士艺等. 用于信号逼近和分类的自适应周期小波神经网络. 信号处理, 2000, 16(1): 42-45
71. 陈哲, 冯天谨. 小波分析与神经网络结合的研究进展. 电子科学学刊, 2000, 22(3): 496-504
72. Giordano S, Miduri S, Pagano M et al. A Wavelet-based approach to the estimation of the Hurst Parameter for self-similar data. 13<sup>th</sup> International Conference on Digital Signal Processing Proceedings, 1997, vol.2: 479-482
73. Lee WH, Yoon YR. ECG data compression using wavelet and fractal interpolation. 18<sup>th</sup> Annual International Conference of the IEEE Engineering in Medicine and Biology Society, 1996:1388-1389
74. Wornell GW, Oppenheim AV. Estimation of the fractal signals from noisy measurements using wavelets. IEEE transaction on Signal Processing 1992, 40(3): 611-623
75. Lee WL, Chen YC, Hsieh KS. Ultrasonic liver tissues by fractal feature vector based on M-band wavelet transform. ISCAS' 2001, vol.2: 1-4
76. 唐巍, 李殿璞, 陈学允. 混沌理论及其应用研究. 电力系统自动化, 2000: 67-70
77. 王静, 毋茂盛, 孙玉强. 小波变换及其应用. 河南师范大学学报, 2002, 30(2): 86-89
78. 李世雄. 小波变换及其应用. 高等数学研究, 2002, 5(1): 43-45
79. 李世雄. 小波变换及其应用. 高等数学研究 (续), 2002, 5(2): 36-38
80. 王一女. 时频变换工具—小波变换及其工程应用. 沈阳大学学报, 2002, 14(2): 42-44
81. 石启星, 田金文, 柳健. 小波变换及其在信号处理中的应用. 遥测遥控, 1996, 17(3): 56-61
82. 熊小芸. 子波变换——一种新的信号处理方法. 电子技术应用, 1998, 1: 4-7
83. 李金龙. 小波变换方法及其应用. 地震, 2001, 21(3): 91-97
84. 崔锦泰, 程正兴译. 小波分析导论. 西安: 西安交通大学出版社, 1995
85. 秦前清, 杨宗凯. 实用小波分析. 西安: 西安电子科技大学出版社, 1995
86. 程正兴. 小波分析算法与应用. 西安: 西安电子科技大学出版社, 1998
87. 李建平. 小波分析方法的应用. 重庆: 重庆大学出版社, 1999
88. 边肇祺, 张学工. 模式识别. 北京: 清华大学出版社, 2000

89. 蔡元龙. 模式识别. 西安: 西北电讯工程学院出版社, 1986
90. 沈清, 汤霖. 模式识别导论. 长沙: 国防科技大学出版社, 1998
91. 戴延中. 基于时频分析的宽带信号处理应用研究. 西安: 西北工业大学博士学位论文, 2001
92. 冯瑞林. 基于时频分析目标回波识别方法研究. 西安: 西北工业大学硕士学位论文, 2001
93. 徐秉铮, 张百灵, 韦岗. 神经网络理论与应用. 广州: 华南理工大学出版社, 1994
94. Packard N H et al. Geometry from a time series. *Phys. Rev. Lett.*, 1980, 45: 712-716
95. Takens F. Detecting strange attractors in turbulence. *Lecture Notes in Mathematic*, 1981, 898: 366-381
96. Broomhead D S, King G P. Extracting qualitative dynamics from experimental data. *Physica D*, 1986, 20: 217-236
97. Fraser A M. Information and entropy in strange attractor. *IEEE Transaction on Information Theory*, 1989, 35(2): 245-262
98. Casdagli M, Eubank S, Farmer JD et al. State space reconstruction in the presence of noise. *Physica D*, 1991, 51: 52-98
99. Roux J C, Simoyi R H, Swinney H L. Observation of a strange attractor. *Physical D*, 1983, 8: 257-266
100. Fraser A M, Swinney H L. Independent coordinates for strange attractors from mutual information. *Physical Review A*, 1986, 33: 1134-1140
101. Cenys A, Pyragas K. Estimation of the number of degrees of freedom from chaotic time series. *Phys. Lett. A* 1988, 129: 227
102. Liebert W, Schuster H G. Proper choice of the time delay for the analysis of chaotic time series. *Phys. Lett. A* 1988, 142: 107-111
103. Abarbanel H D, Brown R, Kadtke J B. Prediction and system identification in chaotic nonlinear systems: time series with broadband spectra. *Phys. Lett. A* 1989, 18: 401-408
104. Rosenstein M T et al. Reconstruction expansion as a geometry-based framework for choosing proper delay time. *Physica D*, 1994, 73: 82-98
105. 林嘉宇, 王跃科, 黄芝平等. 语音信号相空间重构中时间延迟的选择—复相关法. *信号处理*, 1999, 15(1): 220-225
106. 孙海云, 曹庆杰. 混沌时间序列建模及预测. *系统工程理论与实践*, 2001, 5: 106-109
107. 李亚安, 徐德民. 非线性动力系统的状态空间重构. *船舶工程*, 2000, 5:

- 47-50
108. Grassberger P, Procaccia I. Measuring the strangeness of strange attractor. *Physica D* 1983, 9:189-208
  109. Grassberger P, Procaccia I. Dimension and entropy of strange attractors from a fluctuating dynamic approach. *Physica D* 1984, 13: 34-54
  110. Reggie B, Paul B. Computing the Lyapunov spectrum of a dynamical system from an observed time series. *Physical Review A* 1991, 43(6): 2787-2806
  111. Kantz H. A robust method to estimate the maximal Lyapunov exponent of a time series. *Phys. Lett. A* 1994, 185: 77-83
  112. Rosenstein MT et al. A practical method of calculating largest Lyapunov exponents from small data sets. *Physica D* 1993, 65: 117-127
  113. Stoop R, Parisi J. Calculation of Lyapunov exponents avoiding spurious elements. *Physica D* 1991 50: 89-94
  114. Wolf A, Swift JB, Swiney HL et al. Determining Lyapunov Exponents from A Time Series. *Physica D* 1985, 16: 285-317
  115. 余秋星, 李志舜. 基于状态空间重构与 K-L 变换的特征提取. *西北工业大学学报*, 2003, 21(2): 211-213
  116. Zhang XH, Wang JC, Lin LJ. Wavelet Transform Based Spectrum Analysis. *Proc. of ICSP'96, Beijing*
  117. Colfman RR, Wickerhauser MV. Entropy-based algorithms for best basis selection. *IEEE Transaction on Information Theory*, 1992, 38(2): 713-718
  118. 胡昌华等. 基于 MATLAB 的系统分析与设计——小波分析. 西安: 西安电子科技大学出版社, 1999
  119. 贺银芝, 沈松 等. 小波包分解及其能量谱在发动机连杆轴承故障诊断中的应用. *振动工程学报*, 2001, 14(1): 72-75
  120. Yen G G, Lin K C. Wavelet packet feature Extraction for Vibration Monitoring. *IEEE Trans on Industrial Electronics*, 2000, 47(3): 650-667
  121. Averbuch A, Hulate E, Zheludev V, Kozlov I. A Wavelet Packet Algorithm for Classification and Detection of Moving Vehicles. *Multidimensional Systems and Signal Processing*, 2001, 12: 9-31.
  122. 景志宏, 林钧清, 钱建立 等. 水下目标识别技术的研究. *舰船科学技术*, 1999, 4: 38-44
  123. 张贤达. 时间序列分析——高阶统计量方法. 北京: 清华大学出版社, 1999
  124. 刘贵亮, 邸双亮. 小波分析及其应用. 西安: 西安电子科技大学出版社, 1992
  125. 余秋星. 基于混沌与分形的信号检测. 西安: 西北工业大学硕士学位论文

- 文, 2001
126. Flandrin P. Wavelet analysis and synthesis of fractional Brownian motion. *IEEE Transaction on Information and Theory*, 1992, 38(2): 910-917
  127. Wornell GW. A Karhunen-Loeve-like expansion for  $1/f$  processes via wavelets. *IEEE Transaction on Information and Theory*, 1990, 36(7): 859-861
  128. 刘代志, 邹红星, 韦荫康 等. 分形分析与核爆地震模式识别. 模式识别与人工智能, 1997, 10(2): 153-158
  129. 吴高洪, 章毓晋, 林行刚. 利用特征加权进行基于小波变换的纹理分类[J]. 模式识别与人工智能, 1999, 12(3): 262-267
  130. Denk T, et al. Combining neural networks and the wavelet transform for image compression. *Proc. IEEE ICASSP*, 1993, 1: 637-640
  131. Szu H, Yang X, Telfer B, et al. Neural network and wavelet transform for scale-invariant data classification. *Phys. Rev. E*, 1993, 48(2): 1497-1501
  132. Kalayci T, Ozdamar O, Erdol N. The use of wavelet transform as preprocessor for the neural network detection of ECG spike. *Proc. IEEE Southeast Conference*, 1994:1-3
  133. Cheng Qiming, Tian Jilei, Zhang Shujing, et al. The application of neural network to wavelet decomposition of surface EMC signal. *Proc. Of IJCNN*, Beijing, 1992, 1: 889-892
  134. Mukherjee S, Nayar SK. Automatic generation of RBF networks using wavelets. *Pattern Recognition*, 1996, 29(8): 1369-1383
  135. 张红英, 吴斌. 小波神经网络的研究及其进展. *西南工学院学报*, 2002, 17(1): 8-11
  136. Bakshi BR, Stephanopoulos G. Wavelets as basis functions for localized learning in a multi-resolution hierarchy. *International Joint Conference on Neural Network*, 1992, 2: 140-145
  137. 焦李成. 神经网络的应用与实现. 西安: 西安电子科技大学出版社, 1995
  138. Zhang Jun, Walter G, Miao Y, et al. Wavelet neural networks for function learning. *IEEE Trans. on Signal Processing*, 43(6): 1485-1497
  139. 丁宇新, 沈雪勤. 基于能量密度的小波神经网络. *计算机学报*, 1997, 20(9): 832-838
  140. 高协平, 张钹. 区间小波神经网络(I)——理论与实现. *软件学报*, 1998, 9(3): 217-221
  141. 高协平, 张钹. 区间小波神经网络(II)——理论与实现. *软件学报*, 1998, 9(4): 246-250
  142. 王岭, 焦李成. 区间估计的 FWNN 及其区间学习算法. *电子学报*, 1998,

- 26(4): 41-45
143. 蔡文生, 于芳, 邵学广等. 基于小波神经网络的新型算法用于化学信号处理. 高等学校化学学报, 2000, 21(6): 855-859
144. Szu H, Telfer B, Kadambe S. Neural network adaptive wavelets for signal representation and classification. Optical Engineering, 1992, 31(9): 1907-1916
145. 张艳宁, 孙进才, 孙玉兰, 等. 一种基于自适应子波神经网络的船舶噪声分类方法. 西北工业大学学报, 1997, 15(1): 120-124
146. 陈哲, 冯天谨, 陈刚. 一种基于 BP 算法学习的小波神经网络. 青岛海洋大学学报, 2001, 31(1): 122-128
147. 李红雷, 肖登明, 赵杰, 等. 神经网络诊断变压器故障的新方法. 高压电器, 2000, 6: 12-15
148. 赵莉萍, 王建华, 邹伟. 基于小波神经网络的舰载雷达目标识别方法. 华东船舶工业学院学报, 1999, 13(1): 8-12
149. 张永胜, 刘爱萍, 郁可. 脑电信号数据压缩及棘波识别的小波神经网络方法. 生物医学工程杂志, 1999, 16(2): 172-176
150. 刘伟, 李金屏, 熊建辉, 等. 小波神经网络在红外光谱数据压缩中的应用. 科学通报, 1997, 42(8): 824-827
151. 王阿明, 刘天放, 王绪. 用于图像与模式识别的小波神经网络模型. 中国矿业大学学报, 2002, 31(5): 383-386
152. 李金屏, 王凤涛, 杨波. BP 小波神经网络快速学习算法研究. 系统工程与电子学报, 2001, 23(8): 72-75
153. 王泰华, 葛云萍, 余发山. 小波神经网络用于非线性函数逼近的研究. 西南民族学院学报, 2003, 29(1): 38-40
154. 赵学智, 邹春华, 陈统坚, 等. 小波神经网络的参数初始化研究. 华南理工大学学报, 2003, 31(2): 77-80
155. 张茁生, 刘贵忠, 刘峰, 等. 一种自适应小波网络的构造及其学习算法. 中国科学, E 辑, 2001, 31(2): 172-181
156. 刘泓, 莫玉龙. 小波神经网络逼近非线性函数算法. 应用科学学报, 1998, 16(2): 163-169
157. 王美玲, 张长江, 付梦印, 等. 一种用于非线性函数逼近的小波神经网络算法仿真. 北京理工大学学报, 2002, 22(3): 274-278
158. 刘建春, 王正欧. 一种非线性时变系统小波网络辨识算法. 系统工程学报, 2002, 17(5): 401-406
159. 李银国, 张邦礼, 曹长修. 小波神经网络及其结构设计方法. 模式识别与人工智能, 1997, 10(3): 197-205
160. 王雪. 小波神经网络与递归小波神经网络. 西安: 西北工业大学硕士学

位论文, 1999

- 161. 王群仙, 陈增强, 袁著祉. 基于小波网络的非线性系统建模与控制. 控制与决策, 1999, 14(4): 359-363
- 162. 张增芳, 陈瑞中, 齐保谦, 等. 基于小波神经网络的心电数据压缩研究. 广西工学院学报, 2002, 13(1): 12-16
- 163. 黄洁. 混沌神经网络的研究现状及应用. 信息工程学院学报, 1997, 16(2): 24-31
- 164. 石园丁, 王建华. 混沌神经网络的研究进展. 微机发展, 2002, 6: 33-36
- 165. 王朝晖, 刘玉辉. 混沌神经网络的主要模型及其研究趋势. 唐山大学学报, 2003, 16(1): 7-9

## 致 谢

本论文是我对三年多的学习和工作的总结。在此,向所有曾经给予我关心和帮助的人们表达最诚挚的谢意。

首先,向我的导师李志舜教授致以深深的敬意,感谢李教授在这段时间里所给予我的指导和教诲,本文的工作也凝聚着李教授的心血和付出。李教授敏锐而深刻的学术洞察力,严谨扎实的工作作风,孜孜不倦的钻研精神,使我敬佩不已,给我树立了学习的榜样,使我获益匪浅。在生活中,李教授是一位慈祥的长者,平易近人。在此,谨向恩师李教授表示最衷心的感谢和最诚挚的敬意。

李教授领导的课题组,是一个团结向上的集体,在这里,我学到了大量的实践经验和专业知识,养成了良好的团队协作精神。在此,向课题组的田琬逸教授、严胜刚副教授、梁红老师、吴振纲老师、王新宏副教授等老师表示感谢。

感谢徐丰博士和刘东博士,多次与他的讨论使我受到了很多启发;与马艳博士后、李霞博士、张安民博士、钱斌博士、戴征坚博士、刘云博士、杨长生博士、刘建国博士、李强博士、杜金香硕士等师兄弟同窗数载、相互交流,使我受益不浅,感谢他们在本论文完成过程中和日常的学习生活中所给予我的关心与帮助。

深深感谢我的父母,在我二十年的求学生涯中他们给予了我无微不至的关怀、无言的支持,为我付出了太多太多,而我却无以回报。最后,感谢女友黄婷硕士,为我的论文工作提供了有力的支持。

## 作者在攻读博士学位期间发表的论文

1. 余秋星、李志舜. 舰船辐射噪声的特征提取方法. 鱼雷技术, 2002 年第 2 期
2. 余秋星、李志舜. 基于混沌与分形的主动水声信号检测. 西北工业大学第六届研究生学术活动年会论文集, 2001 年
3. 余秋星、李志舜. 基于小波变换的舰船辐射噪声检测. 西北工业大学学报, 2002 年第 4 期
4. 余秋星、李志舜. 基于状态空间重构与 K-L 变换的特征提取. 西北工业大学学报, 2003 年第 2 期
5. 余秋星、符新伟、李志舜. 基于小波变换的主动水声信号检测. 声学技术, 2003 年第 2 期
6. 余秋星、李志舜. 利用小波和分形理论进行水下回波的特征提取. 电子与信息学报, 2003 年第 6 期
7. 余秋星、李志舜、符新伟. 舰船噪声的状态空间重构与特征压缩. 系统仿真学报, 2003 年第 8 期
8. 符新伟、余秋星、李志舜. 利用多分辨分形特征进行目标识别. 电子与信息学报, 2003 年第 11 期



## 西北工业大学 学位论文知识产权声明书

本人完全了解学校有关保护知识产权的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属于西北工业大学。学校有权保留并向国家有关部门或机构送交论文的复印件和电子版。本人允许论文被查阅和借阅。学校可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。同时本人保证，毕业后结合学位论文研究课题再撰写的文章一律注明作者单位为西北工业大学。

保密论文待解密后适用本声明。

学位论文作者签名：余秋星

2004年7月5日

指导教师签名：李超

2004年7月5日

---

## 西北工业大学 学位论文原创性声明

秉承学校严谨的学风和优良的科学道德，本人郑重声明：所呈交的学位论文，是本人在导师的指导下进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容和致谢的地方外，本论文不包含任何其他个人或集体已经公开发表或撰写过的研究成果，不包含本人或他人已申请学位或其它用途使用过的成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

本人学位论文与资料若有不实，愿意承担一切相关的法律责任。

学位论文作者签名：余秋星

2004年7月5日